

Министерство образования и науки Российской Федерации

ТОМСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
СИСТЕМ УПРАВЛЕНИЯ И РАДИОЭЛЕКТРОНИКИ (ТУСУР)

Л. И. Синчинова

ТЕОРИЯ ВЕРОЯТНОСТЕЙ И МАТЕМАТИЧЕСКАЯ СТАТИСТИКА

Учебное пособие

Томск
«Эль Контент»
2016

УДК 519.2(075.8)

ББК 22.17я73

С 387

Рецензенты:

Перемитина Т. О., канд. техн. наук, научный сотрудник
Научно-исследовательского информационного центра Института химии нефти
Сибирского отделения Российской академии наук;
Гриценко Ю. Б., канд. техн. наук, доцент кафедры автоматизации обработки
информации ТУСУРа.

Синчинова Л. И.

С 387 Теория вероятностей и математическая статистика : учебное пособие /
Л. И. Синчинова — Томск : Эль Контент, 2016. — 110 с.

ISBN 978-5-4332-0160-6

Учебное пособие предназначено для студентов, обучающихся с применением дистанционных образовательных технологий. В данном учебном пособии рассмотрены основные теоретические и практические вопросы теории вероятностей и математической статистики. Может быть использовано при освоении курса «Теория вероятностей и математическая статистика» студентами различных специальностей и направлений.

УДК 519.2(075.8)

ББК 22.17я73

ISBN 978-5-4332-0160-6

© Синчинова Л. И., 2016
© Оформление.
ООО «Эль Контент», 2016

ОГЛАВЛЕНИЕ

Введение	5
1 Основы теории вероятности	7
1.1 События и операции над ними	7
1.1.1 Пространство элементарных исходов	7
1.1.2 Виды событий	9
1.1.3 Операции над событиями	10
1.2 Вероятность события	11
1.2.1 Понятие вероятности	11
1.2.2 Способы определения вероятности события	12
1.2.3 Правила сложения и умножения вероятностей	14
1.2.4 Формула полной вероятности. Формула Байеса	16
2 Случайные величины	19
2.1 Дискретные случайные величины	19
2.1.1 Закон распределения дискретной случайной величины	19
2.1.2 Операции над случайными величинами	22
2.1.3 Числовые характеристики случайных величин	25
2.1.4 Биномиальное распределение	27
2.2 Непрерывные случайные величины	30
2.2.1 Понятие непрерывной случайной величины	30
2.2.2 Числовые характеристики непрерывной случайной величины	31
2.2.3 Равномерное распределение	32
2.2.4 Нормальное распределение	34
3 Описательная статистика	36
3.1 Основные понятия описательной статистики	36
3.1.1 Задачи математической статистики	36
3.1.2 Генеральная совокупность и выборка	37
3.2 Способы представления статистических данных	38
3.2.1 Дискретный ряд величин	38
3.2.2 Непрерывный (интервальный) ряд величин	41
3.3 Числовые характеристики выборки	44
3.3.1 Характеристики положения	45
3.3.2 Характеристики рассеяния	46

4	Предельные теоремы и важные законы распределения	48
4.1	Теорема Чебышева и теорема Бернулли	48
4.2	Нормальное распределение и центральная предельная теорема	49
4.3	Распределения математической статистики	54
4.3.1	Стандартное нормальное распределение	54
4.3.2	Распределение «хи-квадрат»	55
4.3.3	Распределение Стьюдента	56
4.3.4	Распределение Фишера	57
5	Статистическое оценивание	59
5.1	Точечная оценка параметров генеральной совокупности	59
5.2	Интервальное оценивание параметров	62
5.2.1	Доверительный интервал и доверительная вероятность	62
5.2.2	Интервальное оценивание генерального среднего	63
5.2.3	Интервальное оценивание генеральной доли	66
6	Проверка статистических гипотез	69
6.1	Постановка задачи	69
6.2	Проверка гипотез о параметрах распределения	73
6.2.1	Гипотезы о генеральном среднем и генеральной дисперсии .	73
6.2.2	Сравнение параметров генеральной совокупности	76
6.2.3	Гипотезы о генеральной доле	78
6.3	Непараметрические гипотезы	81
6.3.1	Проверка гипотез о виде распределения	81
6.3.2	Проверка гипотезы об однородности данных	83
7	Корреляционный и регрессионный анализ	87
7.1	Основные задачи	87
7.2	Коэффициент корреляции Пирсона	88
7.3	Ранговая корреляция	90
7.4	Регрессионные модели	91
7.5	Уравнение линейной регрессии	92
7.6	Линейная регрессия и прогноз	94
	Заключение	97
	Литература	98
	Приложение А Таблица значений функции Лапласа	99
	Приложение Б Критические точки распределения χ^2	101
	Приложение В Критические точки распределения Стьюдента	103
	Приложение Г Критические точки распределения Фишера	105
	Глоссарий	107

ВВЕДЕНИЕ

В процессе всей своей жизни человек сталкивается с событиями и явлениями, исход которых заранее не определен. Например, студент не знает, какой вопрос ему попадется на экзамене, служащий — сколько времени ему понадобится на дорогу до работы, инвестор — окупятся ли его инвестиции и т. д. Тем не менее в подобных ситуациях человеку необходимо принимать решения.

Обычно принятию решений предшествует анализ известных данных (опыт, здравый смысл, интуиция и т. п.). На основе такого анализа делаются определенные умозаключения, которые и предполагают принятие решения.

Проводя тот или иной анализ, важно еще правильно оценить результат. Иллюстрацией к этому может служить притча, приводимая Р. Фишером:

«В одной губернии разразилась эпидемия чумы. Крестьяне знали, что можно «научно» выяснить причину болезни. Они провели некое подобие корреляционного анализа и выяснили, что между количеством заболеваний в деревнях и количеством врачей существует прямая зависимость. Поэтому крестьяне решили избавиться от врачей, посчитав их причиной болезни» [5].

Поэтому необходимо знать основные идеи и методы математической статистики, условия их применения и способы оценки результатов.

Настоящее учебное пособие призвано помочь студентам в изучении основ теории вероятностей и математической статистики с тем, чтобы в процессе дальнейшего обучения использовать полученные знания и навыки для освоения профессиональных дисциплин.

Первая часть пособия посвящена теории вероятностей.

Теория вероятностей — это математическая дисциплина, изучающая закономерности, происходящие в массовых однородных случайных явлениях и процессах.

Историческое зарождение теории вероятностей связано с азартными играми, в которых требовалось обосновать то или иное решение.

Целью современной теории вероятностей является выявление общих закономерностей и зависимостей, а также оценка явлений с помощью абстрактных моделей.

Во второй части пособия рассматриваются задачи и методы математической статистики.

Математическая статистика — это раздел математики, в котором изучаются математические методы планирования экспериментов, систематизации, обработки и использования статистических данных для научных и практических выводов.

Математическая статистика использует математический аппарат и выводы теории вероятностей. Связующим звеном между теорией вероятностей и математической статистикой является закон больших чисел и так называемые предельные теоремы.

Учебное пособие состоит из семи разделов, первые три из которых посвящены теории вероятностей, а остальные четыре математической статистике. Следует отметить, что во многих случаях такое деление является условным, так как понятия теории вероятностей и математической статистики неразрывно связаны между собой.

Соглашения, принятые в книге

Для улучшения восприятия материала в данной книге используются пиктограммы и специальное выделение важной информации.



.....
Эта пиктограмма означает определение или новое понятие.
.....



.....
Эта пиктограмма означает теорему. Данный блок состоит из *Названия теоремы* (Слова Теорема и Номера теоремы) и Текста теоремы.
.....



..... Пример

Эта пиктограмма означает пример. В данном блоке автор может привести практический пример для пояснения и разбора основных моментов, отраженных в теоретическом материале.
.....



.....
Контрольные вопросы по главе
.....

Глава 1

ОСНОВЫ ТЕОРИИ ВЕРОЯТНОСТИ

1.1 События и операции над ними

1.1.1 Пространство элементарных исходов

При научном исследовании различных физических и технических задач часто приходится встречаться с особыми явлениями, которые принято называть случайными. Случайным считается явление, которое при неоднократном воспроизведении одного и того же опыта протекает каждый раз несколько по-иному.

Например, одно и то же тело несколько раз взвешивается на аналитических весах; результаты повторных взвешиваний некоторым образом отличаются друг от друга. Эти различия обусловлены влиянием многих второстепенных факторов, сопровождающих операцию взвешивания, таких, как положение тела на чашке весов, случайные вибрации аппаратуры, ошибки отсчета показаний приборов и т. д.

Таким образом, случайное явление происходит при осуществлении совокупности некоторых условий. Если совокупность условий осуществлена, то говорят, что произведен *эксперимент* или проведено *испытание*.

Результат случайного испытания невозможно предсказать, но, проводя его большое количество раз, можно прогнозировать исход. Например, при многократном подбрасывании монеты, можно заметить, что примерно в половине случаев выпадает «герб», а в половине — «решка».



.....
Простейший неразложимый результат случайного эксперимента называется элементарным исходом (обозначается ω).
.....



Пример

Например, в урне имеются черные и белые шары. Извлечение шара из урны является экспериментом, а появление шара черного или белого цвета — элементарным исходом.



Множество всех возможных взаимоисключающих исходов эксперимента называется **пространством элементарных исходов** Ω . С каждым испытанием связано свое такое пространство.



Пример

Например, эксперимент состоит в подбрасывании игральной кости. Пространство элементарных исходов — $\Omega = \{1, 2, 3, 4, 5, 6\}$.

Решение любой вероятностной задачи начинается с построения (хотя бы умозрительного) пространства элементарных исходов.



Определив пространство элементарных исходов, мы можем говорить о **случайном событии** — подмножестве пространства элементарных исходов.

В общем случае, событием является любое подмножество Ω , но чаще всего, под событием подразумевают некоторый конкретный набор исходов. Например, событие A — «выпало четное количество очков». $A = \{2, 4, 6\} \subset \Omega$.

События обычно обозначают первыми прописными буквами латинского алфавита: A , B , C и т. д.



Элементарный исход ω называется **благоприятствующим** событию A , если при исходе ω событие A происходит.

Событию A благоприятствуют исходы 2, 4, 6.

1.1.2 Виды событий

Наблюдаемые нами события можно разделить на три вида: достоверные, невозможные и случайные.

Пусть эксперимент состоит в бросании игральной кости. Напомним, что пространство элементарных исходов $\Omega = \{1, 2, 3, 4, 5, 6\}$.




.....
Событие A , которому благоприятствует любой исход эксперимента, называется **достоверным** ($A = \Omega$).
.....

В нашем эксперименте достоверное событие можно описать следующим образом: событие A — «выпадет очков от 1 до 6». $A = \{1, 2, 3, 4, 5, 6\} = \Omega$. Событие достоверно.



.....
Событие A , которому не благоприятствует ни один исход, называется **невозможным** ($A = \emptyset$). A — «выпадет очков больше шести».
.....

В пространстве Ω нет ни одного исхода, который благоприятствовал бы такому событию A , оно невозможно.



.....
Событие A является **случайным**, если ему благоприятствуют некоторые, но не все исходы эксперимента.
.....

Пример такого события приведен в п. 1.1.1.

В результате проведения эксперимента, то есть при появлении какого-либо элементарного исхода, может произойти одновременно два или более событий. Пусть эксперимент состоит в извлечении двух шаров из урны, содержащей белые и черные шары. Событие A — «оба извлеченных шара белые», событие B — «извлеченные шары одинакового цвета». Исход, при котором вынимаются два белых шара, предполагает наступление и события A , и события B .



.....
События называются **несовместными**, если в результате одного испытания они не могут произойти одновременно, в противном случае эти события **совместны**.
.....

События A и B в нашем примере являются совместными.

При построении пространства элементарных исходов часто требуется определить, являются ли события *равновозможными*, то есть имеют ли одинаковые шансы на успех [7].

Если эксперимент состоит в бросании двух монет, то событие A — «выпало два герба» и событие B — «выпала ровно одна решка» не являются равновозможными, так как первому событию благоприятствует один элементарный исход (ГГ), а второму — два (РГ, ГР).

Говорят, что события $A_1, A_2, \dots, A_n$ образуют полную группу событий (или полное пространство элементарных исходов), если в результате опыта кроме этих событий ничего не может произойти.

В предыдущем эксперименте события A — «выпала хотя бы одна решка» и B — «выпало два герба» образуют полное пространство элементарных исходов. Действительно, при любом исходе эксперимента произойдет либо событие A , либо событие B . Одновременно они произойти не могут, так как являются несовместными.

1.1.3 Операции над событиями

Во многих областях точных наук применяются символические операции над различными объектами, которые получают свои названия по аналогии с арифметическими действиями, рядом свойств которых они обладают. Таковы, например, операции сложения и умножения векторов в механике, операции сложения и умножения матриц в алгебре и т. д. Эти операции, подчиненные известным правилам, позволяют не только упростить форму записей, но в ряде случаев существенно облегчают логическое построение научных выводов. Введение таких символических операций над событиями оказывается целесообразным и в теории вероятностей.



.....
Суммой событий A и B называется событие $A+B$, которому благоприятствуют исходы, благоприятствующие хотя бы одному из событий A или B .



..... **Пример**

Например, если событие A — попадание в цель при первом выстреле, событие B — попадание в цель при втором выстреле, то событие $A+B$ есть попадание в цель вообще, безразлично при каком выстреле — при первом, при втором или при обоих вместе.



.....
Произведением событий A и B называется событие AB — множество элементарных исходов, благоприятствующих A и B одновременно.



..... **Пример**

Например, если событие A — появление туза при вынимании карты из колоды, событие B — появление карты бубновой масти, то событие AB есть появление бубнового туза. Если производится два выстрела по мишени и событие A — попадание

при первом выстреле, событие B — попадание при втором выстреле, то AB есть попадание при обоих выстрелах.



Противоположным событию A называется событие $\bar{A}$, состоящее из элементарных исходов, не благоприятствующих событию A .



Пример

Если при проведении шахматной партии событие A — «выигрыш», то $\bar{A}$ — проигрыш или ничья.

Заметим, что $A + \bar{A} = \Omega$.

1.2 Вероятность события

1.2.1 Понятие вероятности

Приведем несколько примеров событий:

- A — появление герба при бросании монеты;
- B — появление трех гербов при трехкратном бросании монеты;
- C — попадание в цель при выстреле;
- D — появление туза при вынимании карты из колоды;
- E — обнаружение объекта при одном цикле обзора радиолокационной станции;
- F — обрыв нити в течение часа работы ткацкого станка [1].

Рассматривая вышеперечисленные события, мы видим, что каждое из них обладает какой-то степенью возможности: одни — большей, другие — меньшей, причем для некоторых из этих событий мы сразу же можем решить, какое из них более, а какое менее возможно. Например, сразу видно, что событие A более возможно, чем B и D . Относительно событий C , E и F аналогичных выводов сразу сделать нельзя; для этого следовало бы уточнить условия опыта. Так или иначе, ясно, что каждое из таких событий обладает той или иной степенью возможности. Чтобы количественно сравнивать между собой события по степени их возможности, очевидно, нужно с каждым событием связать определенное число, которое тем больше, чем более возможно событие. Такое число мы назовем вероятностью события.

Таким образом, мы ввели в рассмотрение еще одно из основных понятий теории вероятностей — понятие вероятности события. Вероятность события есть численная мера степени объективной возможности этого события.

1.2.2 Способы определения вероятности события

Одно из самых распространенных определений вероятности — это *классическое определение вероятности*.



.....
Вероятностью события A называется отношение числа благоприятствующих этому событию исходов к общему числу всех возможных исходов эксперимента.

То есть вероятность события A есть

$$P(A) = \frac{m}{n}, \text{ причем } 0 \leq m \leq n,$$

где m — это число исходов, благоприятствующих событию A , n — общее число всех возможных исходов эксперимента [5].

Для определения классической вероятности события нам необходимо знать только «модель игры».



Пример

.....
Например, в урне находится 2 белых и 3 черных шара. Из урны наугад вынимается один шар. Требуется найти вероятность того, что этот шар будет белым.

Решение:

Обозначим A событие, состоящее в появлении белого шара. Общее число случаев $n = 5$; число случаев, благоприятных событию A , $m = 2$. Следовательно,

$$P(A) = \frac{2}{5}.$$

.....

Из классического определения вытекают следующие свойства вероятности:

1. Вероятность достоверного события равна 1 ($A = \Omega$, $n = m$).
2. Вероятность невозможного события равна 0 ($A = \emptyset$, $m = 0$).
3. Вероятностью случайного события является число, заключенное между 0 и 1 ($0 \leq m \leq n$).
4. Сумма вероятностей противоположных событий равна 1

$$P(A) = \frac{m}{n}, \quad P(\bar{A}) = \frac{n-m}{n} = 1 - \frac{m}{n} = 1 - P(A).$$

Используя классическое определение вероятности, мы определяем шансы на то, что событие произойдет, теоретически, не проводя эксперимент. Такая вероятность называется *априорной* (доопытной).

Другим способом определения вероятности является *статистическое* определение.



.....

Если произведена серия из n опытов, в каждом из которых могло произойти или не произойти некоторое событие A , то **частотой** события A в данной серии опытов называется отношение числа опытов, в которых произошло событие A , к общему числу произведенных опытов.

.....

Частоту события часто называют его *статистической вероятностью*. Условимся обозначать частоту (статистическую вероятность) события A знаком $P^*(A)$. Частота события вычисляется на основании результатов опыта по формуле:

$$P^*(A) = \frac{m}{n},$$

где m — число появлений события A ; n — общее число произведенных опытов.

Поскольку в данном случае вероятность определяется уже после проведения эксперимента, ее называют *апостериорной* (послеопытной). Нужно отметить, что чем больше произведено опытов, тем ближе послеопытная вероятность будет приближаться к теоретической, то есть классической, доопытной.

Иногда, при рассмотрении бесконечных множеств (площадей, временных отрезков и т. п.) удобно рассматривать *геометрическое определение вероятности*.



.....

Геометрическая вероятность события A — это отношение меры области, благоприятствующей появлению события A , к мере всей области.

.....



Пример

Найти вероятность того, что точка, случайным образом брошенная в квадрат $ABCD$ со стороной 4, попадет в квадрат $A_1B_1C_1D_1$ со стороной 3, находящийся внутри квадрата $ABCD$ [5].

Решение:

Определим событие A — «точка попадет в квадрат $A_1B_1C_1D_1$ ». Визуально это можно увидеть на рис. 1.1. Вероятность этого события определяется как отношение меры области (в данном случае площади квадрата $A_1B_1C_1D_1$), благоприятствующей событию A , к мере всей области (площади $ABCD$). Таким образом,

$$P(A) = \frac{9}{16}.$$




Рис. 1.1 – Геометрическое определение вероятности

1.2.3 Правила сложения и умножения вероятностей

Правило сложения

Вероятность суммы событий равна сумме вероятностей этих событий без вероятности их совместного наступления:

$$P(A + B) = P(A) + P(B) - P(AB).$$

Рассмотрим формулу для классического определения вероятности. Пусть пространство Ω содержит n взаимоисключающих равновероятных исходов, причем событию A благоприятствуют m_A исходов, событию B – m_B исходов, одновременному наступлению событий A и B – m_{AB} элементарных исходов. Тогда вероятности этих событий

$$P(A) = \frac{m_A}{n}, \quad P(B) = \frac{m_B}{n}, \quad P(AB) = \frac{m_{AB}}{n}.$$

Событию $A + B$ благоприятствуют все исходы, благоприятствующие A , а также все исходы, благоприятствующие B , но не благоприятствующие A . Общее количество таких исходов равно $m_A + (m_B - m_{AB})$. Вероятность события $A + B$ равна

$$P(A + B) = \frac{m_A + (m_B - m_{AB})}{n} = \frac{m_A}{n} + \frac{m_B}{n} - \frac{m_{AB}}{n} = P(A) + P(B) - P(AB).$$

Для несовместных событий их совместное наступление есть событие невозможное, его вероятность равна нулю. Поэтому только для несовместных событий вероятность суммы равна сумме их вероятностей.

$$P(A + B) = P(A) + P(B).$$

Правило умножения

Перед тем, как формулировать правило умножения вероятностей, введем еще одно важное понятие: понятие о независимых и зависимых событиях.

Событие A называется независимым от события B , если вероятность события A не зависит от того, произошло событие B или нет.



.....

События A и B называются **зависимыми**, если вероятность каждого из них зависит от того, произошло или нет другое событие. Вероятность события B , вычисленная в предположении, что событие A уже осуществилось, обозначается $P(B/A)$ и называется **условной вероятностью**.

.....



Пример

Пусть разыгрываются пять лотерейных билетов, среди которых два «счастливых». Рассмотрим события: A — «билет, извлеченный первым, — счастливый», B — «билет, извлеченный вторым, — счастливый». Влияет ли на вероятность события B наступления события A [7]?

Решение:

Если событие A произошло, то в розыгрыше осталось четыре билета, из которых один «счастливый», то есть вероятность наступления события B равна $1/4$. Если событие A не произошло, то в розыгрыше осталось снова четыре билета, но «счастливыми» из них являются уже два, то есть вероятность наступления события B равна $1/2$. Таким образом, вероятность события B зависит от того, наступило или нет событие A . События зависимы.

.....

Вероятность произведения событий A и B равна произведению вероятности одного из них на условную вероятность другого, то есть

$$P(AB) = P(B) \cdot P(A/B)$$

или

$$P(AB) = P(A) \cdot P(B/A).$$

Для независимых событий — $P(AB) = P(A) \cdot P(B)$ — вероятность произведения независимых событий равна произведению их вероятностей.



Пример

Вычислим вероятность произведения событий A и B в предыдущем примере. Сформулируем задачу: имеется пять лотерейных билетов, среди которых два «счастливых». Какова вероятность извлечения двух подряд «счастливых» билетов?

Решение:

Для события A : $m = 2$, $n = 5$, $P(A) = 2/5$.

Событие A произошло, значит, для события B : $m = 1$, $n = 4$, $P(B/A) = 1/4$.

Следовательно, вероятность выпадения двух подряд лотерейных билетов

$$P(AB) = \frac{2}{5} \cdot \frac{1}{4} = \frac{1}{10}.$$

.....

Обобщим правило умножения на случай n событий.

Вероятность произведения n зависимых событий $A_1, A_2, \dots, A_n$ равна произведению последовательных условных вероятностей:

$$P(A_1 A_2 \dots A_{n-1} A_n) = P(A_1) \cdot P(A_2 / A_1) \cdot \dots \cdot P(A_n / A_1 A_2 \dots A_{n-1}).$$

Если в задаче о лотерейных билетах мы положим, что «счастливых» билетов было три, и определим событие C — «третий извлеченный билет счастливый», то вероятность произведения трех событий будет определяться следующим образом:

Для события A : $m = 3, n = 5, P(A) = 3/5$.

Для события B : $m = 2, n = 4, P(B / A) = \frac{2}{4}$.

Для события C : $m = 1, n = 3, P(C / AB) = \frac{1}{3}$.

Вероятность произведения трех событий равна:

$$P(ABC) = \frac{3}{5} \cdot \frac{2}{4} \cdot \frac{1}{3} = \frac{1}{10}.$$

1.2.4 Формула полной вероятности. Формула Байеса



.....
Полной группой несовместных событий называется совокупность $H_1, H_2, \dots, H_n$ всех возможных несовместных событий.

Это означает, что сумма этих событий образует полное пространство элементарных исходов Ω ($H_1 + H_2 + \dots + H_n = \Omega$), а поскольку все события попарно несовместны, то их произведения пусты ($H_i H_j = \emptyset; i \neq j; i, j = 1, 2, \dots, n$).

Пусть требуется определить вероятность некоторого события A , которое может произойти вместе с одним из событий $H_1, H_2, \dots, H_n$, образующих полную группу несовместных событий. Будем эти события называть гипотезами.

Докажем, что в этом случае

$$P(A) = \sum_{i=1}^n P(H_i) P(A / H_i),$$

т. е. вероятность события A вычисляется как сумма произведений вероятности каждой гипотезы на вероятность события при этой гипотезе. Эта формула носит название формулы полной вероятности.

Доказательство. Так как гипотезы $H_1, H_2, \dots, H_n$ образуют полную группу, то событие A может появиться только в комбинации с какой-либо из этих гипотез:

$$A = AH_1 + AH_2 + \dots + AH_n.$$

Так как гипотезы $H_1, H_2, \dots, H_n$ несовместны, то и комбинации $AH_1, AH_2, \dots, AH_n$ также несовместны; применяя к ним теорему сложения, получим:

$$P(A) = P(AH_1) + P(AH_2) + \dots + P(AH_n) = \sum_{i=1}^n P(AH_i).$$

Применяя к событию AH_i теорему умножения, получим:

$$P(A) = \sum_{i=1}^n P(H_i) P(A/H_i),$$

что и требовалось доказать.



Пример

Имеются три одинаковые на вид урны; в первой урне два белых и один черный шар; во второй — три белых и один черный; в третьей — два белых и два черных шара. Некто выбирает наугад одну из урн и вынимает из нее шар. Найти вероятность того, что этот шар белый [5].

Решение:

Рассмотрим три гипотезы:

H_1 — выбор первой урны, H_2 — выбор второй урны, H_3 — выбор третьей урны, и событие A — появление белого шара.

Так как гипотезы, по условию задачи, равновозможные, то есть вероятность выбрать любую урну из трех одинакова, то

$$P(H_1) = P(H_2) = P(H_3) = \frac{1}{3}.$$

Условные вероятности события A при этих гипотезах, то есть вероятности выбрать белый шар из первой, второй и третьей урн, соответственно равны:

$$P(A/H_1) = \frac{2}{3}; \quad P(A/H_2) = \frac{3}{4}; \quad P(A/H_3) = \frac{1}{2}.$$

По формуле полной вероятности

$$P(A) = \frac{1}{3} \cdot \frac{2}{3} + \frac{1}{3} \cdot \frac{3}{4} + \frac{1}{3} \cdot \frac{1}{2} = \frac{23}{36}.$$

Предположим, что в условиях нашей задачи событие A произошло, то есть наудачу из произвольной урны вынут белый шар. Как найти вероятность того, что его извлекли, к примеру, из первой урны? Ответ на этот вопрос дает теорема гипотез или, иначе говоря, формула Байеса.

Речь идет о вероятности того, что вынутый шар, оказавшийся белым, был извлечен из первой урны ($P(H_1/A)$).

Для определения этой вероятности воспользуемся формулами умножения вероятностей.

$$\begin{aligned} P(AH_k) &= P(H_k)P(A/H_k); \\ P(AH_k) &= P(A)P(H_k/A). \end{aligned}$$

Приравняв правые части этих формул, получим:

$$P(H_k) \cdot P(A/H_k) = P(A) \cdot P(H_k/A).$$

Отсюда получим:

$$P(H_k|A) = \frac{P(H_k) \cdot P(A/H_k)}{P(A)}.$$

В знаменателе стоит полная вероятность, подставив вместо $P(A)$ ее значение по формуле полной вероятности, получим:

$$P(H_k/A) = \frac{P(H_k) \cdot P(A/H_k)}{\sum_{i=1}^n P(H_i) \cdot P(A/H_i)}.$$

Эта формула называется *формулой Байеса* и применяется для переоценки гипотез после того, как событие произошло.

Вычислим вероятность того, что извлеченный белый шар был вынут из первой урны.

$$P(H_1/A) = \frac{P(H_1) \cdot P(A/H_1)}{\sum_{i=1}^n P(H_i) \cdot P(A/H_i)} = \frac{\frac{1}{3} \cdot \frac{2}{3}}{\frac{23}{36}} = \frac{8}{23} \approx 0.35.$$

Как видно, до испытания вероятность гипотезы H_1 равнялась $1/3$, или 0.33, а после того, как стал известен результат испытания, вероятность этой гипотезы (точнее, условная вероятность) изменилась и стала равной 0.35. Таким образом, использование формулы Бейеса позволило переоценить вероятность рассматриваемой гипотезы.



Контрольные вопросы по главе 1

1. Что такое исход эксперимента? Может ли он быть один или несколько?
2. Что означает описать пространство элементарных исходов?
3. Может ли возникнуть ситуация, когда событию не благоприятствует ни один исход? Объясните ответ.
4. Дайте классическое определение вероятности.
5. Может ли вероятность события принять значение — 3.5? Обоснуйте ответ.
6. Когда события называются зависимыми?
7. Запишите формулу полной вероятности.
8. Как называются вероятности, рассчитанные по формуле Байеса?

Глава 2

СЛУЧАЙНЫЕ ВЕЛИЧИНЫ

2.1 Дискретные случайные величины

2.1.1 Закон распределения дискретной случайной величины

Одним из важнейших основных понятий теории вероятностей является понятие о случайной величине.



.....
Случайной величиной называется величина, которая в результате опыта может принять то или иное значение, причем неизвестно заранее, какое именно.
.....

Например, опыт — три выстрела по мишени. Случайная величина — количество попаданий. Она может принимать значения 0, 1, 2, 3.

Такие случайные величины, принимающие только отделенные друг от друга значения, которые можно заранее перечислить, называются *дискретными* случайными величинами [7].

Чтобы задать дискретную случайную величину, необходимо указать, какие значения и с какими вероятностями она принимает.

Пусть дискретная случайная величина X принимает значения $x_1, x_2, \dots, x_n$ с вероятностями $p_1, p_2, \dots, p_n$ соответственно.



.....
*Соотношение, устанавливающее связь между значениями дискретной величины и их вероятностями, называется **законом распределения** дискретной случайной величины.*
.....

Закон распределения удобно представить в виде таблицы распределения случайной величины (табл. 2.1).


Таблица 2.1 – Закон распределения дискретной случайной величины

x_i	x_1	x_2	$\dots$	x_n
p_i	p_1	p_2	$\dots$	p_n

Значения, которые может принимать случайная величина, в таблице обычно располагаются в порядке возрастания.

Основным свойством таблицы распределения является то, что сумма вероятностей равна 1: $\sum_{i=1}^n p_i = 1$.

Рассмотрим пример дискретной случайной величины.



Пусть опыт — два выстрела по мишени. Случайная величина X — количество попаданий. Она может принимать значения 0 (ни одного попадания), 1 (одно попадание) и 2 (оба раза выстрелы были точными). Определим вероятности всех значений случайной величины, пользуясь классическим определением вероятности:

$$P(X = 0) = \frac{1}{4}; \quad P(X = 1) = \frac{2}{4} = \frac{1}{2}; \quad P(X = 2) = \frac{1}{4}.$$

Обозначим для удобства записи попадание — П (попал), а промах — М (мимо). Тогда пространство элементарных исходов нашего эксперимента будет состоять из четырех исходов: $\Omega = \{ММ, МП, ПМ, ПП\}$, причем все исходы равновозможны.

Составим таблицу распределения (табл. 2.2).

Таблица 2.2 – Закон распределения заданной случайной величины

Множество Ω	ММ	МП	ПМ	ПП
Значение X	0	1	1	2
Вероятность значения X	1/4	1/2	1/2	1/4

Проверим выполнение основного свойства таблицы распределения:

$$\frac{1}{4} + \frac{1}{2} + \frac{1}{4} = 1.$$

Свойство выполняется, сумма вероятностей равна 1.

.....

Для наглядного, визуального представления закона распределения случайной величины можно строить *многоугольник распределения* (рис. 2.1). Для его построения по оси абсцисс откладывают значения случайной величины, по оси ординат — вероятности значений, точки с координатами $(x_i; p_i)$ соединяют отрезками прямой.




Рис. 2.1 – Многоугольник распределения

Построим многоугольник распределения для случайной величины из нашего примера — построим точки с координатами $(x_i; p_i)$ и соединим их. Полученный многоугольник изображен на рисунке 2.2.




Рис. 2.2 – Многоугольник заданного распределения

Закон распределения случайной величины может быть задан с помощью функции распределения.



.....
Функцией распределения случайной величины X называется функция $F(x)$, выражающая вероятность того, что X примет значение, меньшее заданного числа x :

$$F(x) = P(X < x).$$

.....

Чтобы найти значение функции распределения в точке x , нужно просуммировать вероятности значений x_i , которые лежат левее точки x :

$$F(x) = \sum_{x_i < x} p_i.$$

Графиком функции распределения дискретной случайной величины является ступенчатая функция, причем высота «ступеньки» с абсциссой в точке x_i равна вероятности p_i (рис. 2.3).




Рис. 2.3 – График функции распределения

Свойства функции распределения:

1. Функция распределения ограничена: $0 \leq F(x) \leq 1$.
2. Предельные значения: $F(-\infty) = 0$, $F(+\infty) = 1$.
3. Функция распределения не убывает.
4. Функция распределения непрерывна слева.
5. Вероятность попадания случайной величины X в промежуток от α до β (включая α) выражается формулой:

$$P(\alpha \leq X < \beta) = F(\beta) - F(\alpha).$$

Запишем функцию распределения для случайной величины X из примера.

Пользуясь таблицей распределения случайной величины X , найдем значения функции распределения:

$$F(x) = \begin{cases} 0, & \text{если } x \leq 0; \\ 0.25, & \text{если } 0 < x \leq 1; \\ 0.75, & \text{если } 1 < x \leq 2; \\ 1, & \text{если } x > 2. \end{cases}$$

Пользуясь свойствами функции распределения, можно находить вероятности для различных значений случайной величины. Например, вероятность попадания случайной величины X в промежуток $[0, 1.5)$ найдем, применив свойство 5 функции распределения:

$$P(0 \leq X < 1.5) = F(1.5) - F(0) = 0.75 - 0 = 0.75.$$

2.1.2 Операции над случайными величинами

Над случайными величинами можно выполнять простые арифметические операции: сумма, произведение, прибавление константы, умножение на константу.

Сумма случайных величин



.....

Суммой случайных величин X и Y называется новая случайная величина Z , значения которой получаются в результате сложения всех значений величины X со всеми значениями величины Y , а соответствующие вероятности перемножаются.

.....



Пример

Например (табл. 2.3, 2.4, 2.5) [5].

Таблица 2.3 – Исходные случайные величины

x_i	0	1	2	3
p_i	0.1	0.4	0.3	0.2

y_j	-1	0	1
p_j	0.2	0.3	0.5

Выполним сложение.

Таблица 2.4 – Сложение случайных величин

z_k	0 - 1	0 + 0	0 + 1	1 - 1	1 + 0	1 + 1
p_k	0.02	0.03	0.05	0.08	0.12	0.2

z_k	2 - 1	2 + 0	2 + 1	3 - 1	3 + 0	3 + 1
p_k	0.06	0.09	0.15	0.04	0.06	0.1

Одинаковые значения полученной случайной величины можно записать один раз, предварительно сложив соответствующие вероятности.

Таблица 2.5 – Сумма случайных величин

z_i	-1	0	1	2	3	4
p_i	0.02	0.11	0.23	0.33	0.21	0.1

Заметим, что сумма вероятностей всех значений случайной величины получилась равной 1. Основное свойство таблицы распределения выполняется.

.....

Произведение случайных величин



.....
Произведение случайных величин X и Y — это новая случайная величина, значения которой получаются перемножением всех значений величины X и всех значений величины Y , а соответствующие вероятности перемножаются.

Операция произведения выполняется аналогично операции сложения.

Прибавление константы



.....
 При **прибавлении** к случайной величине X некоторой константы C получается случайная величина Y , каждое значение которой вычисляется путем прибавления C к каждому значению величины X , а вероятности остаются неизменными.



Пример

Например, случайная величина X задана таблицей распределения (табл. 2.6).

Таблица 2.6 – Случайная величина X

x_i	0	1	2	3
p_i	0.1	0.4	0.3	0.2

Зададим случайную величину $Y = X + 2$. Получим таблицу распределения (табл. 2.7):

Таблица 2.7 – Прибавление константы

y_i	2	3	4	5
p_i	0.1	0.4	0.3	0.2

Умножение на константу



.....
 Чтобы **умножить** случайную величину X на некоторую константу C , нужно каждое значение величины X умножить на C , а вероятности оставить неизменными.

Операция выполняется аналогично добавлению константы.

Используя рассмотренные операции над случайными величинами, можно строить различные новые величины.

2.1.3 Числовые характеристики случайных величин

Как уже известно, закон распределения полностью характеризует случайную величину. Однако часто закон распределения неизвестен и приходится ограничиваться меньшими сведениями. Иногда даже выгоднее пользоваться числами, которые описывают случайную величину суммарно; такие числа называют *числовыми характеристиками* случайной величины.

В теории вероятностей и математической статистике применяется большое количество различных числовых характеристик, имеющих различное назначение и различные области применения. Из них в настоящем курсе мы введем только некоторые, наиболее часто применяемые. Различают для дискретной случайной величины: характеристики положения — математическое ожидание и мода; характеристики рассеяния — дисперсия и среднее квадратическое отклонение.



.....
Математическим ожиданием дискретной случайной величины называют сумму произведений всех ее возможных значений на их вероятности.

Пусть случайная величина X принимает значения x_i с вероятностями p_i , $i = 1, 2, \dots, n$. Математическим ожиданием случайной величины X называется число

$$M(X) = x_1p_1 + x_2p_2 + \dots + x_np_n = \sum_{i=1}^n x_ip_i.$$

Для того чтобы сделать понятие математического ожидания более наглядным, обратимся к механической интерпретации распределения дискретной случайной величины. Пусть на оси абсцисс расположены точки с абсциссами $x_1, x_2, \dots, x_n$, в которых сосредоточены соответственно массы $p_1, p_2, \dots, p_n$, причем $\sum_{i=1}^n p_i = 1$. Тогда, очевидно, математическое ожидание $M[X]$ есть не что иное, как абсцисса центра тяжести данной системы материальных точек.

Математическое ожидание приближенно равно (тем точнее, чем больше число испытаний) среднему арифметическому наблюдаемых значений случайной величины. Такая связь между средним арифметическим и математическим ожиданием составляет содержание одной из форм закона больших чисел, который мы рассмотрим позднее.

Свойства математического ожидания:

1. Математическое ожидание постоянной величины равно этой постоянной величине: $M(C) = C$.
2. Постоянный множитель можно выносить за знак математического ожидания: $M(kX) = kM(X)$.

3. Для любых случайных величин X и Y математическое ожидание суммы равно сумме математических ожиданий: $M(X + Y) = M(X) + M(Y)$.
4. Для независимых случайных величин X и Y математическое ожидание произведения равно произведению математических ожиданий: $M(XY) = M(X) \cdot M(Y)$ [1].



.....
Мода $M_0(X)$ распределения — это значение случайной величины, имеющее наиболее вероятное значение.

Заметим, что таких значений (с наибольшей вероятностью и при этом равновероятных) может быть несколько. В таком случае закон распределения случайной величины называется полимодальным.



.....
Дисперсией дискретной случайной величины называется математическое ожидание квадрата отклонения случайной величины от ее математического ожидания $M(X) = a$.

$$D(X) = M(X - a)^2 = \sum_{i=1}^n (x_i - a)^2 p_i.$$

Дисперсия служит для характеристики рассеяния случайной величины относительно своего математического ожидания. Для чего определяют дисперсию? Приведем пример.

Пусть заданы две случайные величины X и Y (табл. 2.8) [4].

Таблица 2.8 – Законы распределения случайных величин X и Y

x_i	-1	1
p_i	0.5	0.5

y_i	-100	100
p_i	0.5	0.5

Вычислим математические ожидания этих величин:

$$M(X) = -1 \cdot 0.5 + 1 \cdot 0.5 = 0, \quad M(Y) = -100 \cdot 0.5 + 100 \cdot 0.5 = 0.$$

Математические ожидания равны, но величины явно различны, причем X имеет возможные значения, близкие к математическому ожиданию, а Y — далекие от своего математического ожидания. Таким образом, зная лишь математическое ожидание случайной величины, еще нельзя судить ни о том, какие возможные значения она принимает, ни о том, как они рассеяны вокруг математического ожидания. Иными словами, математическое ожидание полностью случайную величину не характеризует, необходимость в других характеристиках очевидна.

Свойства дисперсии:

1. Дисперсия постоянной величины равна нулю: $D(c) = 0$.
2. Постоянный множитель можно вынести из-под знака дисперсии, возведя его в квадрат: $D(kX) = k^2 D(X)$.

3. Если случайные величины X и Y независимы, то дисперсия суммы равна сумме дисперсий: $D(X + Y) = D(X) + D(Y)$.
4. Для дисперсии справедлива вычислительная формула:

$$D(X) = M(X^2) - (M(X))^2.$$

Для оценки рассеяния возможных значений случайной величины вокруг ее среднего значения, кроме дисперсии, служат и некоторые другие характеристики. К их числу относится среднее квадратическое отклонение.



.....
Средним квадратическим отклонением называют квадратный корень из дисперсии:

$$\sigma(X) = \sqrt{D(X)}.$$

.....

По определению дисперсии понятно, что она имеет размерность, равную квадрату размерности случайной величины. Так как среднее квадратическое отклонение равно квадратному корню из дисперсии, то размерность $\sigma(X)$ совпадает с размерностью X . Поэтому в тех случаях, когда требуется, чтобы оценка рассеяния имела размерность случайной величины, вычисляют среднее квадратическое отклонение, а не дисперсию. Например, если X выражается в линейных метрах, то $\sigma(X)$ будет выражаться в линейных метрах, дисперсия — в квадратных метрах.

В приведенном нами выше примере вычислим дисперсию и среднее квадратическое отклонение случайных величин X и Y , учитывая, что математические ожидания обеих случайных величин равны 0.

$$D(X) = (-1 - 0)^2 \cdot 0.5 + (1 - 0)^2 \cdot 0.5 = 1;$$

$$D(Y) = (-100 - 0)^2 \cdot 0.5 + (100 - 0)^2 \cdot 0.5 = 10000.$$

Определим теперь средние квадратические отклонения.

$$\sigma(X) = 1; \quad \sigma(Y) = 100.$$

Видно, что для второй случайной величины среднее квадратическое отклонение описывает рассеяние более точно, чем дисперсия. Это происходит потому, что среднее квадратическое отклонение имеет размерность того же порядка, что и случайная величина.

2.1.4 Биномиальное распределение

Существует особый тип экспериментов, проводя которые, мы предполагаем, что определенное событие либо произойдет, либо нет. Наступление события мы считаем «успехом», а не наступление — «неудачей». Приведем примеры таких экспериментов [6]:

- 1) эксперимент — проведение футбольного матча. «Успех» — выигрыш, а ничья или проигрыш — это «неудача»;

- 2) эксперимент — выстрел по мишени. «Успех» — попадание, а «неудача» — промах;
- 3) эксперимент — бросание игральной кости. Выпадение шести очков — это «успех», а выпадение остальных пяти цифр — это «неудача».

Такого рода эксперименты имеют некоторые общие условия проведения:

1. Испытания независимы друг от друга (выигрыш в одном матче не зависит от выигрыша в другом; попадания в мишень при различных выстрелах независимы; выпадение шестерки при одном броске кубика не влияет на выпадение цифры при другом броске).
2. Каждое испытание имеет два взаимоисключающих исхода: «успех» и «неудача».
3. Вероятность «успеха» p от испытания к испытанию в эксперименте постоянна, вероятность «неудачи» равна $1 - p$ (вероятность выигрыша в футбольном матче равна $1/3$, вероятность других исходов — $2/3$; вероятность попадания в мишень равна $1/2$, вероятность промаха — тоже $1/2$; шесть очков на игральной кости выпадет с вероятностью $1/6$, другое число очков — с вероятностью $5/6$).

Схема проведения эксперимента при соблюдении этих трех условий называется *схемой Бернулли*.



.....
Биномиальным законом распределения называется закон распределения случайной величины X — числа появлений «успеха» в схеме из n испытаний Бернулли.

Вероятность того, что в схеме из n испытаний Бернулли успех наступит ровно k раз, вычисляется по формуле:

$$P_n(X = k) = C_n^k p^k q^{n-k} = \frac{n!}{(n-k)!k!} p^k q^{n-k}.$$

Легко убедиться, что числовые характеристики для биномиального распределения вычисляются по формулам:

$$M(X) = np; \quad D(X) = npq.$$

Для этого достаточно подставить в формулы для вычисления математического ожидания и дисперсии правило вычисления вероятностей при биномиальном распределении и провести расчеты.

Рассмотрим пример.



..... **Пример**

Вероятность того, что покупатель совершит покупку в магазине, равна 0.4. Магазин посетило 3 покупателя. Случайная величина X — число покупателей, совершивших покупку [2].

Запишем закон распределения в виде таблицы, построим многоугольник распределения, определим числовые характеристики.

Вероятность «успеха» $p = 0.4$, значит, вероятность «неудачи» $q = 0.6$. Количество испытаний $n = 3$. Случайная величина X может принимать значения 0, 1, 2, 3. Рассчитаем вероятности, которые соответствуют значениям случайной величины.

$$P_3(X = 0) = C_3^0 \cdot 0.4^0 \cdot 0.6^{3-0} = \frac{3!}{(3-0)! \cdot 0!} \cdot 0.4^0 \cdot 0.6^3 = 0.216,$$

$$P_3(X = 1) = C_3^1 \cdot 0.4^1 \cdot 0.6^{3-1} = \frac{3!}{(3-1)! \cdot 1!} \cdot 0.4^1 \cdot 0.6^2 = 0.432,$$

$$P_3(X = 2) = C_3^2 \cdot 0.4^2 \cdot 0.6^{3-2} = \frac{3!}{(3-2)! \cdot 2!} \cdot 0.4^2 \cdot 0.6^1 = 0.288,$$

$$P_3(X = 3) = C_3^3 \cdot 0.4^3 \cdot 0.6^{3-3} = \frac{3!}{(3-3)! \cdot 3!} \cdot 0.4^3 \cdot 0.6^0 = 0.064.$$

Занесем полученные данные в таблицу распределения (табл. 2.9).

Таблица 2.9 – Закон распределения случайной величины X

x_i	0	1	2	3
p_i	0.216	0.432	0.288	0.064

Сумма вероятностей $0.216 + 0.432 + 0.288 + 0.064 = 1$, закон распределения записан верно.

Построим теперь многоугольник распределения (рис. 2.4).




Рис. 2.4 – Многоугольник биномиального распределения

Видно, что наиболее вероятное значение случайной величины равно 1, ее вероятность 0.432. Это значение и будет являться модой.

Вычислим математическое ожидание, дисперсию и среднее квадратическое отклонение.

$$M(X) = n \cdot p = 3 \cdot 0.4 = 1.2;$$

$$D(X) = n \cdot p \cdot q = 3 \cdot 0.4 \cdot 0.6 = 0.72;$$

$$\sigma(X) = \sqrt{D(X)} = \sqrt{0.72} = 0.85.$$

.....

Аналогично другим дискретным случайным величинам для величины, распределенной по биномиальному закону, можно записать функцию распределения и построить ее график.

2.2 Непрерывные случайные величины

2.2.1 Понятие непрерывной случайной величины

До сих пор мы рассматривали дискретные случайные величины, которые обладают тем свойством, что все их значения можно перенумеровать натуральными числами, а каждому значению сопоставить отличную от нуля вероятность. Однако так можно описать не все случайные величины. Например, время службы электрической лампочки может принимать любые действительные значения от нуля до бесконечности. И если лампочка вначале была исправна, то вероятность того, что время ее службы будет в точности совпадать с заранее заданным значением, равна нулю. Ненулевыми будут только вероятности сложных событий (время службы лампочки — от одного до двух месяцев). Подобные случайные величины не могут быть описаны с помощью таблицы распределения. Для их описания используется функция распределения.

Функция распределения дискретной случайной величины ступенчатая, она возрастает скачком в тех точках, вероятности которых положительны.



.....
Случайную величину X называют **непрерывной**, если ее функция распределения $F(X) = P(X < x)$ непрерывна и имеет производную.
.....

Функция распределения непрерывной случайной величины применяется для вычисления вероятностей попадания случайной величины в заданный промежуток:

$$P(\alpha < X < \beta) = F(\beta) - F(\alpha),$$

причем для непрерывной случайной величины не имеет значения, включаются в этот промежуток его границы или нет:

$$P(\alpha < X < \beta) = P(\alpha \leq X < \beta) = P(\alpha \leq X \leq \beta).$$



.....
Плотностью распределения непрерывной случайной величины называется функция

$$f(x) = F'(x),$$

производная от функции распределения.
.....

Свойства плотности распределения:

1. Плотность распределения случайной величины неотрицательна — ($f(x) \geq 0$) при всех значениях x .

2. Условие нормировки:

$$\int_{-\infty}^{\infty} f(x) dx = 1.$$

Геометрический смысл условия нормировки: площадь под кривой плотности распределения равна единице.

3. Вероятность попадания случайной величины X в промежуток от α до β может быть вычислена по формуле:

$$P(\alpha < X < \beta) = \int_{\alpha}^{\beta} f(x) dx.$$

Геометрически вероятность попадания непрерывной случайной величины X в промежуток (α, β) равна площади криволинейной трапеции под кривой плотности распределения, опирающейся на этот промежуток.

4. Функция распределения выражается через плотность следующим образом:

$$F(x) = \int_{-\infty}^x f(t) dt.$$

Значение плотности распределения в точке x не равно вероятности принять это значение, для непрерывной случайной величины речь может идти только о вероятности попадания в заданный интервал. Пусть $[x, x + \Delta x)$ — интервал произвольно малой длины $\Delta x > 0$. Вероятность попадания случайной величины в этот интервал приближенно равна произведению значения плотности распределения в точке x на длину этого интервала: $f(x)\Delta x$, то есть вероятность пропорциональна длине интервала, причем коэффициент пропорциональности равен значению плотности распределения в точке x .

2.2.2 Числовые характеристики непрерывной случайной величины

Числовые характеристики непрерывной случайной величины находятся по формулам, похожим на формулы для дискретной случайной величины, но везде знак суммы заменяется на знак интеграла, а вероятность p_i на дифференциальный элемент вероятности $f(x) dx$.

Математическое ожидание непрерывной случайной величины равно

$$M(X) = \int_{-\infty}^{\infty} xf(x) dx.$$

Дисперсия непрерывной случайной величины есть

$$D(X) = \int_{-\infty}^{\infty} (x - M(x))^2 f(x) dx.$$

Все свойства математического ожидания и дисперсии, сформулированные для дискретных случайных величин, сохраняются и для непрерывных случайных величин.

2.2.3 Равномерное распределение

Одним из часто используемых примеров непрерывной случайной величины является случайная величина X , равномерно распределенная на интервале $(a; b)$.



.....
 Говорят, что случайная величина X **равномерно распределена** на промежутке $(a; b)$, если ее плотность распределения постоянна на этом промежутке:

$$f(x) = \begin{cases} c, & \text{при } x \in (a; b), \\ 0, & \text{при } x \notin (a; b). \end{cases}$$

.....

Из условия нормировки (свойство 2 плотности распределения) определим значение константы c . Площадь под кривой плотности распределения должна быть равна единице, но в нашем случае — это площадь прямоугольника с основанием $(b - a)$ и высотой c , как показано на рисунке 2.5.




Рис. 2.5 – Плотность распределения случайной величины, равномерно распределенной на промежутке (a, b)

Отсюда находим значение постоянной c :

$$(b - a) \cdot c = 1; \quad c = \frac{1}{b - a}.$$

Итак, плотность равномерно распределенной случайной величины равна

$$f(x) = \begin{cases} \frac{1}{b - a}, & \text{при } x \in (a; b), \\ 0, & \text{при } x \notin (a; b). \end{cases}$$

Найдем теперь функцию распределения $F(x) = \int_{-\infty}^x f(t) dt$:

$$1) \text{ для } x \leq a \quad f(x) = 0 \text{ и } F(x) = \int_{-\infty}^x f(t) dt = \int_{-\infty}^x 0 \cdot dt = 0;$$

$$2) \text{ для } a < x < b \quad F(x) = \int_{-\infty}^x f(t) dt = \int_{-\infty}^a 0 \cdot dt + \int_a^x \frac{1}{b-a} \cdot dt = \frac{x-a}{b-a};$$

$$3) \text{ для } x \geq b \quad F(x) = \int_{-\infty}^x f(t) dt = \int_{-\infty}^a f(t) dt + \int_a^b f(t) dt + \int_b^x f(t) dt = 0 + 1 + 0 = 1.$$

Таким образом,

$$F(x) = \begin{cases} 0, & \text{при } x \leq a, \\ \frac{x-a}{b-a}, & \text{при } a < x < b, \\ 1, & \text{при } x \geq b. \end{cases}$$

Функция распределения непрерывна и не убывает. График функции распределения приведен на рисунке 2.6.




Рис. 2.6 – График функции распределения случайной величины, равномерно распределенной на промежутке (a, b)

Найдем математическое ожидание равномерно распределенной случайной величины по формуле $M(X) = \int_{-\infty}^{\infty} xf(x) dx$. Поскольку функция плотности распределения принимает различные значения, в зависимости от того, попадает текущая точка x в промежуток (a, b) , вычисление математического ожидания сводится к вычислению суммы трех интегралов:

$$M(X) = \int_{-\infty}^a x \cdot 0 dx + \int_a^b \frac{x}{b-a} dx + \int_b^{+\infty} x \cdot 0 dx = \frac{1}{b-a} \cdot \frac{x^2}{2} \Big|_a^b = \frac{a+b}{2}.$$

Дисперсия равномерного распределения рассчитывается по формуле

$$D(X) = \int_{-\infty}^{\infty} (x - M(x))^2 f(x) dx,$$

аналогично вычислению математического ожидания, вычисляется как сумма трех интегралов. Нетрудно убедиться, что дисперсия равна $D(X) = \frac{(b-a)^2}{12}$ [7].

2.2.4 Нормальное распределение

Другим примером непрерывной случайной величины является нормально распределенная случайная величина.



.....
 Говорят, что случайная величина X имеет **нормальное распределение** с параметрами a и σ , если ее плотность распределения задается формулой:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-a)^2}{2\sigma^2}}, \quad -\infty < x < +\infty.$$

.....

При этом параметр a характеризует положение графика функции на числовой оси, параметр σ ($\sigma > 0$) – степень сжатия или растяжения графика плотности, как показано на рисунке 2.7.




Рис. 2.7 – Плотность нормального распределения

Математическое ожидание нормально распределенной случайной величины равно $M(X) = a$, дисперсия $D(X) = \sigma^2$.

Нормальное распределение относится к числу наиболее распространенных и важных, оно применяется для приближенного описания многих случайных явлений. Например, с помощью нормального распределения описывают рассеяние снарядов при стрельбе по цели; отклонение фактического размера изделия от заданного; оно применяется и во многих других ситуациях, когда на интересующий нас признак действует большое количество независимых случайных факторов.



Контрольные вопросы по главе 2

1. Чем отличаются между собой дискретная и непрерывная случайные величины?
2. Каким образом можно задать дискретную случайную величину?
3. Могут ли несколько значений случайной величины иметь одинаковые значения?
4. При сложении двух дискретных случайных величин их значения складываются. Что при этом происходит с их вероятностями?
5. Назовите числовые характеристики случайных величин.
6. Покажите связь между плотностью распределения и функцией распределения непрерывной случайной величины.
7. Чем равномерное распределение отличается от всех других распределений?

Глава 3

ОПИСАТЕЛЬНАЯ СТАТИСТИКА

3.1 Основные понятия описательной статистики

3.1.1 Задачи математической статистики

Математические законы теории вероятностей не являются беспредметными абстракциями, лишенными физического содержания; они представляют собой математическое выражение реальных закономерностей, фактически существующих в массовых случайных явлениях природы и общества.

До сих пор, говоря о законах распределения случайных величин, мы не затрагивали вопроса о том, откуда берутся, на каком основании устанавливаются эти законы распределения. В основе всех этих характеристик лежит опыт; каждое исследование случайных явлений, выполняемое методами теории вероятностей, прямо или косвенно опирается на экспериментальные данные. Таким образом, установление закономерностей, которым подчинены массовые случайные явления, основано на изучении статистических данных — результатов наблюдений.

Первая задача математической статистики — указать способы сбора и группировки статистических сведений, полученных в результате наблюдений или в результате специально поставленных экспериментов.

Вторая задача математической статистики — разработать методы анализа статистических данных в зависимости от целей исследования [3].

Современная математическая статистика разрабатывает способы определения числа необходимых испытаний до начала исследования (планирование эксперимента), в ходе исследования (последовательный анализ) и решает многие другие задачи.

Итак, задача математической статистики состоит в создании методов сбора и обработки статистических данных для получения научных и практических выводов.

Разработка методов регистрации, описания и анализа статистических экспериментальных данных, получаемых в результате наблюдения массовых случайных явлений, составляет предмет математической статистики.

Основная цель математической статистики — это получение и обработка данных для статистически значимой поддержки процесса принятия решения, например при решении задач планирования, управления, прогнозирования.

3.1.2 Генеральная совокупность и выборка

Пусть требуется изучить совокупность однородных объектов относительно некоторого качественного или количественного признака, характеризующего эти объекты. Например, если имеется партия деталей, то качественным признаком может служить соответствие деталей стандарту, а количественным — контролируемый размер детали.

Иногда проводят сплошное обследование, т.е. обследуют каждый из объектов совокупности относительно признака, которым интересуются. Примером такого сплошного обследования может служить перепись населения. На практике, однако, сплошное обследование применяют сравнительно редко. Например, если совокупность содержит очень большое число объектов, то провести сплошное обследование физически невозможно. В таких случаях случайно отбирают из всех совокупностей ограниченное число объектов и подвергают их изучению [3].



.....
Выборочной совокупностью, или просто **выборкой**, называют совокупность случайно отобранных объектов.
.....



.....
Генеральной совокупностью называется совокупность объектов, из которых производится выборка.
.....

Объем совокупности (выборочной или генеральной) — это число объектов этой совокупности. Принято обозначать объем генеральной совокупности N , а объем выборки — n . Например, если из 1000 работников предприятия опрашивают с какой-либо целью 100 человек, то $N = 1000$ (объем генеральной совокупности), а $n = 100$ (объем выборки).

Выборка может быть составлена двумя способами. Первый способ называется случайным *повторным* отбором. При этом отобранный элемент выборки перед выбором следующего возвращается в генеральную совокупность.

Второй способ — случайный *бесповторный* отбор. При этом отобранный объект не возвращается в генеральную совокупность. Если объем генеральной совокупности велик и выборка составляет лишь незначительную часть всей совокупности, то различие между двумя способами отбора невелико. Но при любом способе отбор должен быть *случайным* — каждый элемент генеральной совокупности должен иметь одинаковую вероятность попасть в выборку.

Для того чтобы по данным выборки можно было достаточно уверенно судить об интересующем признаке генеральной совокупности, необходимо, чтобы объекты выборки правильно его представляли. Другими словами, выборка должна правильно представлять структуру генеральной совокупности. Это требование коротко формулируют так: выборка должна быть репрезентативной (представительной). Например, требуется изучить некоторый продукт жителей определенного города. Генеральная совокупность в данном случае очень большая, и ее не имеет смысл обследовать полностью, но для наибольшей достоверности выборку желательно построить таким образом, чтобы она отображала структуру генеральной совокупности, то есть была репрезентативной. По данным последней переписи населения можно судить о процентном соотношении в городе мужчин и женщин; жителей со средним, средним специальным и высшим образованием; соотношение возрастных категорий, социальных слоев, групп населения с различным уровнем дохода и т. п. Эти данные позволяют построить выборку таким образом, чтобы все эти соотношения в ней соблюдались. Тем не менее отбор будет все равно случайный, так как все жители города имеют равные шансы попасть в выборку.

3.2 Способы представления статистических данных

3.2.1 Дискретный ряд величин

Пусть X — некоторый признак изучаемого объекта или явления (срок службы электролампы, вес поросенка, диаметр шарика для подшипника и т. п.).

Генеральной совокупностью является множество всех возможных значений этого признака, а результаты n наблюдений над признаком X дадут нам выборку $x_1, x_2, \dots, x_n$ объема n , где x_1 — результат первого наблюдения за признаком, x_2 — второго и т. д.

Итак, первоначальные статистические данные — это значения $x_1, x_2, \dots, x_n$ — в общем случае, ряд чисел, расположенных в беспорядке.

Для удобства обработки выборку преобразуют в *вариационный ряд*, располагая результаты наблюдений в порядке неубывания: $x_1 \leq x_2 \leq \dots \leq x_n$. Каждый член x_i вариационного ряда называется *вариантой*.

Построив вариационный ряд, можно легко определить, какие значения принимает исследуемый признак, а также сколько раз то или иное значение встретилось в выборке, то есть можно построить *статистический ряд* или ряд распределения. Для построения такого ряда нужно указать для каждой варианты количество ее вхождений в выборку. Это количество называется *частотой* варианты (n_i), а вели-

чина $v_i = \frac{n_i}{n}$ — *относительной частотой*.

Заметим, что в теории вероятностей под распределением понимают соответствие между возможными значениями случайной величины и их вероятностями. В математической статистике — соответствие между наблюдаемыми вариантами и их частотами или относительными частотами.



Пример

В результате тестирования группа из 24-х человек набрала баллы:

4, 0, 3, 4, 1, 0, 3, 1, 0, 4, 0, 0, 3, 1, 0, 1, 1, 3, 2, 3, 1, 2, 1, 2.

Построим вначале вариационный ряд, то есть упорядочим выборку, начиная с самой маленькой по значению варианты. Получим:

0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 3, 3, 3, 3, 3, 4, 4, 4.

По вариационному ряду легко выделить группы одинаковых значений вариантов и определить частоту каждой варианты. Выполним эти действия и построим статистический ряд, задав тем самым закон распределения статистической случайной величины. Оформим ряд в виде таблицы и построим его в двух вариантах, используя в первом варианте частоты, а во втором — относительные частоты (табл. 3.1, 3.2).

Таблица 3.1 – Статистический ряд частот

x_i (балл)	0	1	2	3	4
n_i (число студентов)	6	7	3	5	3

Отметим, что сумма частот статистического ряда равна объему выборки. Действительно, $6 + 7 + 3 + 5 + 3 = 24$.

Таблица 3.2 – Статистический ряд относительных частот

x_i (балл)	0	1	2	3	4
v_i (относительная частота)	$\frac{6}{24}$	$\frac{7}{24}$	$\frac{3}{24}$	$\frac{5}{24}$	$\frac{3}{24}$

В теории вероятностей мы говорили, что сумма вероятностей всех возможных значений случайной величины равна единице. В статистике — сумма относительных частот тоже должна быть равна единице.

Дискретные статистические ряды изображают графически с помощью полигона. Полигон частот обеспечивает наглядность представления данных и позволяет делать предположения о близости распределения исследуемого признака к тому или иному закону распределения.

Полигон частот — это ломаная линия, отрезки которой соединяют точки (x_1, n_1) , (x_2, n_2) , ..., (x_k, n_k) . *Полигон относительных частот* — это ломаная линия, отрезки которой соединяют точки (x_1, v_1) , (x_2, v_2) , ..., (x_k, v_k) .

Полигоны частот для нашего примера изображены на рисунке 3.1.




Рис. 3.1 – Полигон частот (а) и полигон относительных частот (б)

Еще одним наглядным способом представления статистических данных является эмпирическая функция распределения. В теории вероятностей функция распределения — основная форма описания закона распределения случайной величины — показывает вероятность попадания данной случайной величины X левее фиксированного значения x :

$$F(x) = P(X < x).$$

Статистическим аналогом графика функции распределения является кривая накопленных частот.

Накопленной частотой n_x называется число вариантов выборки, меньших данного числа x . Построим таблицу накопленных частот для рассматриваемого нами в этом пункте примера (табл. 3.3).

Таблица 3.3 – Накопленные частоты

x_i (значения вариант)	0	1	2	3	4
n_x (накопленная частота)	6	13	16	21	24



.....
Относительная накопленная частота — это отношение накопленной частоты n_x к объему выборки n . Графическое изображение относительных накопленных частот в виде ступенчатой линии называется **эмпирической (кумулятивной) функцией распределения**. Отметим, что эмпирическая функция распределения определена для любых действительных значений x [5].

Построим таблицу накопленных относительных частот (табл. 3.4) и график эмпирической функции распределения (рис. 3.2).

Таблица 3.4 – Накопленные относительные частоты

x_i (значения вариант)	0	1	2	3	4
v_x (накопленная относительная частота)	$\frac{6}{24}$	$\frac{13}{24}$	$\frac{16}{24}$	$\frac{21}{24}$	$\frac{24}{24}$




Рис. 3.2 – Эмпирическая функция распределения

3.2.2 Непрерывный (интервальный) ряд величин

При большом числе наблюдений (порядка сотен) или при наблюдении непрерывного признака статистический ряд перестает быть удобной формой записи статистического материала — он становится слишком громоздким и мало наглядным. Для придания ему большей компактности и наглядности статистический материал должен быть подвергнут дополнительной обработке — строится так называемый сгруппированный статистический ряд.

Для построения такого ряда весь интервал делится на некоторое количество промежутков (интервалов) и определяется количество вариантов, попавших в каждый из этих промежутков (частота интервала).

Число интервалов, на которые следует группировать статистический материал, не должно быть слишком большим (тогда ряд распределения становится невыразительным, и частоты в нем обнаруживают незакономерные колебания); с другой стороны, оно не должно быть слишком малым (при малом числе разрядов свойства распределения описываются статистическим рядом слишком грубо). Длины разрядов могут быть как одинаковыми, так и различными. Проще, разумеется, брать их одинаковыми.

Для определения оптимального количества интервалов применяют *коэффициент Старджеса*, значение которого зависит только от количества наблюдаемых значений и вычисляется по формуле:

$$k = 1 + 3.3 \cdot \lg n.$$

Определив количество интервалов, можно легко вычислить длину каждого интервала:

$$d = \frac{x_{\max} - x_{\min}}{k},$$

где $x_{\max}$ и $x_{\min}$ наибольшее и наименьшее значение вариантов соответственно.

Для определенности будем считать левый конец интервала закрытым, а правый — открытым. Получим сгруппированный статистический ряд (табл. 3.5):

Таблица 3.5 – Сгруппированный статистический ряд

Интервал	$[x_1; x_2)$	$[x_2; x_3)$	...	$[x_{k-1}; x_k)$
Частота	n_1	n_2	...	n_k



Пример

С некоторого прибора в течение часа каждые две минуты снимали показания. Получили выборку из 30 чисел:

20.1, 21.0, 21.3, 22.1, 21.6, 20.3, 22.0, 21.5, 20.9, 20.0,
 21.4, 21.2, 22.0, 21.5, 20.8, 21.7, 21.6, 22.3, 20.6, 21.8,
 21.2, 21.3, 20.5, 21.4, 21.8, 20.9, 22.1, 21.9, 21.1, 22.2.

Если мы построим обычный статистический ряд, то он будет достаточно громоздким, так как различных значений вариант много, то есть наглядного представления о распределении мы не получим, даже если построим полигон частот. В данном случае удобно выборку сгруппировать.

Определим количество интервалов. Используем для этого коэффициент Старджеса.

$$k = 1 + 3.3 \cdot \lg 30 \approx 5.875.$$

Поскольку количество интервалов — целое число, нужно округлить полученное значение в большую сторону. Таким образом, количество интервалов $k = 6$.

Вычислим теперь длину интервала.

Наименьшее значение выборки равно 20.0, наибольшее — 22.3. Для получения длины интервала нам нужно разность между наибольшим (22.3) и наименьшим (20.0) значениями разделить на $k = 6$. Число получится не слишком удобное для вычислений, поэтому мы немного расширим диапазон значений и будем считать, что наибольшим числом является 22.4. Это действие правомерно, так как мы не уменьшаем диапазон, а увеличиваем, не теряя ни одного из наблюдаемых значений. Таким образом, получим длину интервала:

$$d = \frac{22.4 - 20.0}{6} = 0.4.$$

Таблица 3.6 – Сгруппированный статистический ряд для выборки

Интервал	$[20.0, 20.4)$	$[20.4, 20.8)$	$[20.8, 21.2)$	$[21.2, 21.6)$	$[21.6, 22.0)$	$[22.0, 22.4)$
Частота n_i	2	3	5	8	6	6
Относительная частота v_i	0.07	0.1	0.17	0.26	0.2	0.2

Построим теперь сгруппированный статистический ряд — таблицу (табл. 3.6), в которой в первой строке укажем интервалы, на которые разделен весь диапазон значений, а во второй — количество вариантов, попавших в соответствующий интервал. Добавим сразу третью строку — строку относительных частот каждого интервала, которые получаются делением частоты n_i на общее количество наблюдений, то есть на 30.

.....

Графически сгруппированный статистический ряд представляют в виде гистограммы частот и гистограммы относительных частот.

Гистограмма частот — это ступенчатая фигура, состоящая из прямоугольников, основанием каждого из которых является интервал группировки длиной d , а высотой — величина $h_i = \frac{n_i}{d}$. Площадь каждого прямоугольника равна $d \cdot \frac{n_i}{d} = n_i$, сумма площадей всех прямоугольников равна сумме частот, то есть объему выборки.

Гистограммой относительных частот называется также ступенчатая фигура, состоящая из прямоугольников с такими же основаниями, что и в гистограмме частот, но высоты этих прямоугольников равны $\frac{v_i}{d}$. Площадь каждого прямоугольника

в гистограмме равна $d \cdot \frac{v_i}{d} = v_i$. Сумма всех площадей равна единице.

Гистограмма частот в нашем примере приведена на рисунке 3.3.




Рис. 3.3 – Гистограмма частот

Гистограмма относительных частот строится аналогично.

По сгруппированному ряду так же, как и по обычному статистическому ряду, можно построить таблицу накопленных частот и эмпирическую функцию распределения. Для сгруппированного статистического ряда определяется накопленная частота m_i — число вариантов, меньших правой границы i -го интервала. Относительная накопленная частота — это отношение накопленной частоты m_i к объему выборки n .

Построим таблицу накопленных частот и график эмпирической функции распределения (табл. 3.7, рис. 3.4).

Таблица 3.7 – Таблица накопленных частот

Интервал	[20.0, 20.4)	[20.4, 20.8)	[20.8, 21.2)	[21.2, 21.6)	[21.6, 22.0)	[22.0, 22.4)
Накоплен- ная частота m_i	2	5	10	18	24	30
Относитель- ная накоп- ленная частота	0.07	0.17	0.34	0.6	0.8	1




Рис. 3.4 – График эмпирической функции распределения

3.3 Числовые характеристики выборки

Вариационные и статистические ряды, рассмотренные нами выше, дают первичное и не совсем полное представление об исследуемом распределении. Далее необходимо рассмотреть числовые характеристики выборки. Они во многом аналогичны числовым характеристикам случайной величины. Так, например, имеют место характеристики положения и характеристики рассеяния. К ним добавляются еще характеристики симметрии.

Мы будем рассматривать эти характеристики, используя данные примера из п. 3.2.2. Приведем их здесь снова, но для удобства обработки уже в виде вариационного ряда, расположив варианты выборки в порядке неубывания:

0, 20.1, 20.3, 20.5, 20.6, 20.8, 20.9, 20.9, 21.0, 21.1,

2, 21.2, 21.3, 21.3, 21.4, 21.4, 21.5, 21.5, 21.6, 21.6,

7, 21.8, 21.8, 21.9, 22.0, 22.0, 22.1, 22.1, 22.2, 22.3,

а также сгруппированный статистический ряд (табл. 3.8):

Таблица 3.8 – Сгруппированный статистический ряд

Интервал	[20.0, 20.4)	[20.4, 20.8)	[20.8, 21.2)	[21.2, 21.6)	[21.6, 22.0)	[22.0, 22.4)
Частота n_i	2	3	5	8	6	6

3.3.1 Характеристики положения

К характеристикам положения относят различными способами определяемые центры выборки, а также медиану и квантили.



Наиболее простой, хотя и очень «грубой» характеристикой центра выборки считается **полусумма крайних**. Она вычисляется по формуле

$$\frac{x_{\min} + x_{\max}}{2}.$$



Одной из самых распространенных характеристик положения является **среднее арифметическое**, которое рассчитывается по формуле $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ или, для сгруппированного ряда, $\bar{x} = \frac{1}{n} \sum_{j=1}^k n_j z_j$, где n — объем выборки, k — количество интервалов, z_j — середина j -го интервала, а n_j — количество вариантов, попавших в j -й интервал.

Понятно, что при определении среднего арифметического по сгруппированному ряду оно получается не таким точным, но при большом объеме выборки погрешность невелика.



В качестве характеристики середины выборки вычисляется также **геометрическое среднее**, которое определяется как корень n -й степени из произведения элементов выборки:

$$\sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}.$$

Приведем средние значения для рассматриваемого нами примера (табл. 3.9).

Таблица 3.9 – Характеристики положения

Полусумма крайних	21.15
Среднее арифметическое	21.34
Среднее геометрическое	21.33

Модой в теории вероятностей мы называли значение случайной величины, имеющее наибольшую вероятность.



.....
 В математической статистике **модой** $\hat{M}$ называют варианту с наибольшей частотой.

Закон называют унимодальным, если мода единственна.

В нашем примере мы видим девять вариантов, встречающихся в выборке по два раза: 20.9, 21.2, 21.3, 21.4, 21.5, 21.6, 21.8, 22.0, 22.1. Таким образом, закон распределения не является унимодальным.

Для определения моды по сгруппированному ряду находят модальный интервал — интервал с наибольшей частотой. В качестве моды принимают его середину.

Таким интервалом является $[21.2; 2.6)$, в него попало 8 вариант выборки, модой будет являться число 21.4.



.....
Медиана выборки — это число $x_{0.5}$ такое, что ровно половина вариант меньше этого числа, а половина — больше.

В рассматриваемой нами выборке таким числом является 21.4.

Работая со сгруппированным рядом, находят медианный интервал $[x_j; x_{j+1})$ такой, что относительная накопленная частота для x_j меньше 0.5, а для x_{j+1} — больше 0.5. Таким интервалом будет являться $[21.2; 2.6)$. Медиана равна также 21.4.

Медиана — это число, которое делит выборку на две части. Можно найти три числа, которые будут делить выборку на четыре части. Такие числа называются **квартили**. Они обозначаются $x_{0.25}$ — нижняя квартиль, $x_{0.75}$ — верхняя, а серединная совпадает с медианой и обозначается так же.

В нашем исследовании $x_{0.25} = 20.9$, $x_{0.5} = 21.4$, $x_{0.75} = 21.8$.

Аналогично можно найти девять чисел, которые разделят выборку на десять равных частей, такие числа называются **децентилями**; 99 чисел, которые поделят выборку на 100 частей — **процентилями**. Общее название таких точек деления — **квантили**.

3.3.2 Характеристики рассеяния

Простейшей характеристикой рассеяния можно назвать размах выборки, который определяется как разница между наибольшим и наименьшим значениями выборки, то есть $x_{\max} - x_{\min}$.



.....
 Более точной оценкой рассеяния данных вокруг среднего значения является **дисперсия**. Для статистического ряда она вычисляется по формуле:

$$D = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

для сгруппированного статистического ряда:

$$D = \frac{1}{n} \sum_{j=1}^k (z_j - \bar{x})^2 \cdot n_j.$$

Поскольку дисперсия — мера, характеризующая средний квадрат отклонения от центра совокупности, вычисляют *среднее квадратичное отклонение*, то есть корень квадратный из дисперсии $\sigma = \sqrt{D}$, чтобы получить меру рассеяния той же размерности, что и данные [5].

Для рассматриваемого нами примера определим характеристики рассеяния по сгруппированному статистическому ряду:

Размах выборки:

$$x_{\max} - x_{\min} = 22.3 - 20.0 = 2.3.$$

Дисперсия:

$$D = \frac{1}{30} ((20.2 - 21.34)^2 \cdot 2 + (20.6 - 21.34)^2 \cdot 3 + (21.0 - 21.34)^2 \cdot 5 + (21.4 - 21.34)^2 \cdot 8 + (21.8 - 21.34)^2 \cdot 6 + (22.2 - 21.34)^2 \cdot 6).$$

$$D = 10.556.$$

Среднее квадратическое отклонение:

$$\sigma = \sqrt{10.556} = 3.25.$$

Полученное отклонение означает, что в среднем показания прибора в течение часа отличаются от среднего на 3.25.



Контрольные вопросы по главе 3

1. Назовите способы отбора элементов из генеральной совокупности в выборку.
2. Какие Вы знаете способы представления статистических данных?
3. Почему данные некоторых наблюдений целесообразно группировать?
4. Может ли закон распределения наблюдаемого признака иметь две или больше мод? Объясните ответ.
5. К каким характеристикам относится среднее арифметическое? А среднее квадратическое отклонение?

Глава 4

ПРЕДЕЛЬНЫЕ ТЕОРЕМЫ И ВАЖНЫЕ ЗАКОНЫ РАСПРЕДЕЛЕНИЯ

4.1 Теорема Чебышева и теорема Бернулли

В предыдущих разделах мы оперировали понятиями «генеральная совокупность», «выборка», «закон распределения», «числовые характеристики» и др. В случаях, когда исследование всей генеральной совокупности невозможно или нецелесообразно, из нее случайным образом извлекалась часть — выборка — и по ней делались различные выводы и заключения относительно всей генеральной совокупности. Почему можно считать сделанные по выборке выводы верными? Ответ на этот вопрос дает закон больших чисел. Закон больших чисел — это группа теорем, которые формулируют математические закономерности, проявляющиеся при многократном наблюдении случайных явлений [7].

Для независимых случайных величин общий закон больших чисел выражается теоремой Чебышева (1867 г.).



.....
Теорема Чебышева. Пусть $X_1, X_2, \dots, X_n, \dots$ последовательность независимых случайных величин с математическими ожиданиями $m_1, m_2, \dots, m_n, \dots$ и дисперсиями $D_1, D_2, \dots, D_n, \dots$, ограниченными одной и той же константой ($D_i \leq c, i = 1, 2, \dots$). Тогда для любого $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} \left(P \left| \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n m_i \right| < \varepsilon \right) = 1.$$

.....

Иначе это можно записать:

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{P} \frac{1}{n} \sum_{i=1}^n m_i,$$

т. е. теорема Чебышева устанавливает, что при достаточно больших n с вероятностью, близкой к единице, среднее арифметическое случайных величин $\bar{X} = \frac{1}{n}(X_1 + X_2 + \dots + X_n)$ как угодно мало колеблется около постоянного числа $\frac{1}{n}(m_1 + m_2 + \dots + m_n)$ — среднего арифметического математических ожиданий этих случайных величин.

Проводя анализ выборочных данных, мы рассматриваем независимые статистические копии одной и той же случайной величины X . Поэтому, согласно теореме Чебышева, среднее арифметическое таких статистических копий при большом числе слагаемых оказывается практически постоянной (не случайной) величиной, которая и указывает нам «центр» генеральной совокупности.

Теорема Бернулли впервые была сформулирована в XVIII веке Яковом Бернулли. Сейчас принято доказывать ее как следствие теоремы Чебышева.

Рассмотрим последовательность испытаний по схеме Бернулли, т. е. последовательность независимых испытаний, в каждом из которых вероятность интересующего нас случайного события A («успеха») одна и та же и равна p . Определим относительную частоту успеха как отношение числа успешных испытаний к общему их числу в серии из n испытаний и обозначим ее p^* . В этих условиях разность между относительной частотой p^* события A и вероятностью p этого события становится сколь угодно малой, если число испытаний неограниченно возрастает.



.....
Теорема Бернулли. В последовательности испытаний по схеме Бернулли относительная частота события сходится по вероятности к вероятности этого события:

$$p^* \xrightarrow[n \rightarrow \infty]{P} p.$$

.....

Теорема Бернулли позволяет обосновывать близость гистограммы, построенной по выборке большого объема, к теоретической плотности распределения (плотности распределения генеральной совокупности). Отметим, что сама эта теорема не гарантирует устойчивости относительных частот в конкретной практической задаче, она позволяет сделать вывод, если такая устойчивость частот имеется (выполняются условия схемы испытаний Бернулли).

4.2 Нормальное распределение и центральная предельная теорема

В п. 2.2.4 мы уже кратко ознакомились с нормальным законом распределения случайной величины. Здесь рассмотрим такие величины подробнее.

Напомним, что случайная величина X называется распределенной по нормальному закону с параметрами a и σ (будем писать $X \sim N(a, \sigma)$), если функция ее плотности распределения имеет вид

$$f(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot e^{-\frac{(x-a)^2}{2\sigma^2}}, \quad x \in (-\infty; +\infty).$$

При этом математическое ожидание $M(x) = a$, дисперсия $D(x) = \sigma^2$. График плотности распределения симметричен относительно прямой $x = a$ и имеет точки перегиба при $x = a \pm \sigma$. Схематически он показан на рисунке 4.1.




Рис. 4.1 – График плотности нормального распределения

Нормальный закон распределения играет исключительно важную роль в теории вероятностей и занимает среди других законов распределения особое положение. Это — наиболее часто встречающийся на практике закон распределения. Главная особенность, выделяющая нормальный закон среди других законов, состоит в том, что он является предельным законом, к которому приближаются другие законы распределения при весьма часто встречающихся типичных условиях.



.....
Нормальное распределение с параметрами $a = 0$, $\sigma = 1$ называется стандартным нормальным распределением.

Нормальная случайная величина $X \sim N(a, \sigma)$ связана со стандартной $X_0 \sim N(0, 1)$ линейной зависимостью: $X = a + \sigma X_0$.

При вычислении вероятностей, связанных с нормальным законом распределения, мы будем пользоваться функцией Лапласа $\Phi(x)$, значения которой табулированы (Приложение А):

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_0^x e^{-\frac{t^2}{2}} dt.$$

В курсе теории вероятностей доказываются свойства функции Лапласа:

1. $\Phi(0) = 0$.
2. $\Phi(-x) = -\Phi(x)$ (нечетность).
3. $\Phi(+\infty) = \frac{1}{2}$.

Расчет вероятностей для случайной величины $X \sim N(a, \sigma)$ ведется по формуле:

$$P(\alpha < X < \beta) = \Phi\left(\frac{\beta - a}{\sigma}\right) - \Phi\left(\frac{\alpha - a}{\sigma}\right),$$

которая в частном случае ($\alpha = a - \varepsilon$, $\beta = a + \varepsilon$) принимает вид:

$$P(a - \varepsilon < X < a + \varepsilon) = P(|X - a| < \varepsilon) = 2\Phi\left(\frac{\varepsilon}{\sigma}\right).$$



Пример

Слон поглощает в среднем 300 кг растительного корма в сутки. Предположим, что количество корма — случайная величина, распределенная по нормальному закону со средним квадратическим отклонением 50 кг.

Определить вероятность того, что слон употребит в случайно выбранные сутки:

- а) больше, чем 330 кг корма;
- б) меньше, чем 290 кг корма;
- в) от 260 до 310 кг корма;
- г) количество корма отклонится от среднего не больше чем на 30 кг;
- д) количество корма отклонится от среднего не меньше чем на 30 кг.

Решение:

В условии задачи указано среднее потребление корма в сутки, значит, математическое ожидание $a = 300$ кг. Среднее квадратическое отклонение $\sigma = 50$ кг.

В случае а нас интересует вероятность того, что вес X потребленного в случайно взятые сутки корма окажется в интервале $(330; +\infty)$.

По формуле нахождения вероятностей для нормального распределения имеем:

$$\begin{aligned} P(330 < X < +\infty) &= \Phi\left(\frac{+\infty - 300}{50}\right) - \Phi\left(\frac{330 - 300}{50}\right) = \\ &= \Phi(+\infty) - \Phi(0.6) = 0.5 - 0.2257 = 0.2743. \end{aligned}$$

Для определения значений Φ мы воспользовались таблицами функции Лапласа (Приложение А) и ее свойством 3.

В случае б применим формулу расчета вероятностей при $\alpha = -\infty$, $\beta = 290$, математическое ожидание и среднее квадратическое отклонение остаются те же.

$$\begin{aligned} P(-\infty < X < 290) &= \Phi\left(\frac{290 - 300}{50}\right) - \Phi\left(\frac{-\infty - 300}{50}\right) = \\ &= \Phi\left(-\frac{1}{5}\right) - \Phi(-\infty) = -\Phi\left(\frac{1}{5}\right) + \Phi(\infty). \end{aligned}$$

Здесь мы применили свойство нечетности функции Лапласа, а также снова свойство 3. Найдем теперь табличное значение $\Phi\left(\frac{1}{5}\right)$. Оно равно 0.0793. Искомая вероятность — $P(-\infty < X < 290) = -0.0793 + 0.5 = 0.4207$.

В случае ϵ :

$$\begin{aligned} P(260 < X < 310) &= \Phi\left(\frac{310 - 300}{50}\right) - \Phi\left(\frac{260 - 300}{50}\right) = \\ &= \Phi\left(\frac{1}{5}\right) - \Phi\left(-\frac{4}{5}\right) = \Phi\left(\frac{1}{5}\right) + \Phi\left(\frac{4}{5}\right) = 0.0793 + 0.2881 = 0.3674. \end{aligned}$$

Вероятность того, что в случайно наблюдаемые сутки слон употребит от 260 кг до 310 кг корма, составляет 0.3674.

Вероятность того, что количество корма в сутки отклонится от математического ожидания меньше, чем на 30 кг (случай ϵ), определим по формуле для вычисления вероятностей в частном случае:

$$P(|X - 300| < 30) = 2\Phi\left(\frac{30}{50}\right) = 2\Phi(0.6) = 2 \cdot 0.2257 = 0.4514.$$

Найдем вероятность того, что суточное потребление корма отклонится от математического ожидания больше, чем на 30 кг. По свойствам вероятностей противоположных событий:

$$P(|X - 300| > 30) = 1 - P(|X - 300| < 30) = 1 - 0.4514 = 0.5486.$$

.....

Почему нормальный закон распределения является одним из важнейших в теории вероятностей и математической статистике? Объяснение этому дает *центральная предельная теорема*. Согласно ей сумма большого количества независимых случайных величин, каждая из которых оказывает незначительное влияние на всю сумму, распределена приблизительно по нормальному закону. А почти все явления случайного характера, встречающиеся на практике, представляют собой результат наложения множества отдельных влияний: тепловое движение электронов в проводнике, атмосферные помехи, волны в океане — слагаются под воздействием многих случайных возмущений. Поэтому независимо от вида плотности вероятностей отдельных составляющих (а часто они и неизвестны) можно ожидать, что плотность распределения наблюдаемого возмущения будет нормальной. Центральная предельная теорема дает математическое обоснование этому предположению, а эксперименты практически всегда подтверждают его правильность [7].



.....
Центральная предельная теорема. Пусть $X_1, X_2, \dots, X_n, \dots$ независимые одинаково распределенные случайные величины с математическим ожиданием m и конечной дисперсией σ^2 . Тогда при неограниченном увеличении n закон распределения случайной величины $\frac{1}{\sqrt{n}\sigma} \left(\sum_{i=1}^n X_i - n \cdot m \right)$ неограниченно приближается к стандартному нормальному закону.

Таким образом, рассматривая сумму независимых одинаково распределенных случайных величин, мы можем считать ее распределенной приблизительно по нормальному закону $N(n \cdot m, \sqrt{n} \cdot \sigma)$.

Следствия из центральной предельной теоремы (теоремы Муавра—Лапласа) позволяют применять нормальный закон распределения к частоте (относительной частоте) события, наблюдавшегося в серии из n независимых опытов. Пусть X — число успехов, наблюдавшихся в серии n испытаний Бернулли (частота успехов). Величину X можно рассматривать как сумму $X = \sum_{i=1}^n X_i$ независимых случайных величин X_i , принимающих значение 1, если в i -ом испытании наблюдался успех, и 0 — в противном случае. Случайные величины X_i независимы и одинаково распределены (по закону Бернулли) с математическим ожиданием p (вероятность успеха) и дисперсией $p \cdot (1 - p)$. Тогда случайную величину X можно считать распределенной приблизительно нормально с параметрами $a = np$ и $\sigma = \sqrt{np(1 - p)}$. Это позволяет рассчитывать вероятности, связанные с частотой, по формулам, связанным с нормальным распределением.

Эти формулы применимы и к относительной частоте p^* , которую при большом числе опытов можно считать распределенной приближенно по нормальному закону:

$$p^* \sim N\left(p, \sqrt{\frac{p \cdot (1 - p)}{n}}\right).$$



Пример

Подлежат исследованию 400 проб руды. Вероятность промышленного содержания металла в каждой пробе для всех проб одинакова и равна 0.8. Найти вероятность того, что доля проб с промышленным содержанием металла отклонится от вероятности промышленного содержания металла в каждой пробе не более чем на 0.05.

Решение:

Математической моделью задачи является схема из $n = 400$ испытаний Бернулли с вероятностью успеха $p = 0.8$. Доля проб с промышленным содержанием металла — это относительная частота успехов p^* (количество успехов, деленное на количество испытаний). В задаче требуется определить вероятность отклонения частоты p^* от ее математического ожидания $M(p^*) = p$ на заданную величину $\varepsilon = 0.05$, т. е. $P(|p^* - p| < 0.05) = ?$

Считая случайную величину p^* распределенной нормально с параметрами $a = np = 320$ и $\sigma = \sqrt{np(1 - p)} = \sqrt{400 \cdot 0.8 \cdot 0.2} = 8$, получаем:

$$P(|p^* - p| < 0.05) = 2\Phi\left(\frac{0.05}{0.02}\right) = 2\Phi(2.5) = 2 \cdot 0.494 = 0.988.$$

Вероятность того, что доля проб с промышленным содержанием металла отклонится от вероятности промышленного содержания металла в каждой пробе не более чем на 0.05, составляет 0.988.

Проиллюстрируем решение задачи графически (рис. 4.2). Мы рассматривали нормально распределенную случайную величину $p^* \sim N(0.8; 0.02)$. Применяя формулу для вычисления вероятности при малом отклонении от среднего, мы преобразовали p^* к стандартной нормальной величине $z = \frac{p^* - 0.8}{0.02} \sim N(0; 1)$, график плотности которой симметричен относительно оси ординат, а точка $z = 0$ соответствует $p^* = 0.8$. Площадь заштрихованной области составляет 98.8% от всей площади под кривой плотности распределения, а интервал $(-2.5; 2.5)$ для случайной величины z соответствует интервалу $(0.8 - 0.05; 0.8 + 0.05)$ для случайной величины p^* .




Рис. 4.2 – Графическое представление области решения

4.3 Распределения математической статистики

4.3.1 Стандартное нормальное распределение

Рассмотрим случайную величину X , распределенную по закону $N(a, \sigma)$. Стандартное нормальное распределение $u \sim N(0, 1)$ получим с помощью преобразования $u = \frac{X - a}{\sigma}$. В статистике квантиль порядка p для этого распределения называется также правосторонней *критической точкой* $u_{кр}$, соответствующей вероятности $\alpha = 1 - p$. На рисунке 4.3 эта область показана стрелкой. Доля площади, лежащая правее точки $u_{кр}$, составляет $100 \cdot \alpha\%$ (в качестве α рассматриваются обычно малые вероятности 0.05, 0.01 и т. п.).

Как найти критическую точку, пользуясь таблицами функции Лапласа (Приложение А)?




Рис. 4.3 – Критическая точка

Значение функции Лапласа $\Phi(x)$ равно площади под кривой плотности стандартного распределения на промежутке $(0; x)$ (на рисунке 4.4 это заштрихованная область). Поэтому значение критической точки $u_{кр}$, соответствующее заданному α ,

находится из уравнения $\Phi(u_{кр}) = \frac{1}{2} - \alpha$.




Рис. 4.4 – Значение функции Лапласа



Пример

Пользуясь таблицей значений функции Лапласа, найти критическую точку, соответствующую вероятности $\alpha = 0.05$.

Решение:

Критическая точка $u_{кр}$ является границей, правее которой лежит 5% площади под кривой плотности стандартного нормального распределения. Значит, площадь под этой кривой на интервале $(0; u_{кр})$ составляет 45%, и в таблице значений функции Лапласа (Приложение А) ищем значение $\Phi(x) = 0.45$. Это значение достигается при $x = 1.65$, т. е. критическая точка $u_{кр} = 1.65$ (с точностью до 0.01).

4.3.2 Распределение «хи-квадрат»

Пусть $U_1, U_2, \dots, U_k$ — независимые стандартные нормальные величины. Распределение случайной величины $K = U_1^2 + U_2^2 + \dots + U_k^2$ называется распределением «хи-квадрат» с k степенями свободы (пишут $K \sim \chi_{(k)}^2$). Это унимодальное распределение с положительной асимметрией и следующими характеристиками: мода $M = k - 2$, математическое ожидание $m = k$, дисперсия $D = 2k$. Схематический график функции плотности распределения для различных k изображен на рисунке 4.5. При достаточно большом значении параметра k распределение $\chi_{(k)}^2$ имеет приближенно нормальное распределение с параметрами $N(k, \sqrt{2k})$ [7].

При решении задач математической статистики используются критические точки $\chi_{(k)}^2$, зависящие от заданной вероятности α и числа степеней свободы k (Приложение Б). Критическая точка $\chi_{кр}^2 = \chi^2(k; \alpha)$ является границей области, правее которой лежит $100 \cdot \alpha\%$ площади под кривой плотности распределения. Вероятность того, что значение случайной величины $K \sim \chi_{(k)}^2$ при испытаниях попадет правее точки $\chi_{кр}^2$, не превышает α : $P(K \geq \chi_{кр}^2) \leq \alpha$. Например, для случайной величины $K \sim \chi_{(20)}^2$ зададим вероятность $\alpha = 0.05$. По таблице критических точек распре-

деления «хи-квадрат» (Приложение Б) находим $\chi_{кр}^2 = \chi^2(20, 0.05) = 31.4$. Значит, вероятность этой случайной величине K принять значение, большее 31.4, меньше 0.05.




Рис. 4.5 – Распределение «хи-квадрат»

4.3.3 Распределение Стьюдента

Пусть U и K — независимые случайные величины, причем U имеет стандартное нормальное распределение $N(0, 1)$, а K — распределение $\chi_{(k)}^2$ с k степенями

свободы. Распределение величины $T = \frac{U}{\sqrt{\frac{K}{k}}}$ называется распределением Стьюдента с k степенями свободы.

График плотности этого распределения симметричен относительно оси ординат и напоминает график плотности стандартного нормального распределения, но отличается более «массивными хвостами» (т. е. значения плотности распределения Стьюдента медленнее убывают при удалении от начала координат). На рисунке 4.6 график плотности нормального распределения показан пунктиром, а распределения Стьюдента — сплошной линией [7].




Рис. 4.6 – Распределение Стьюдента

Математическое ожидание распределения Стьюдента $M(T) = 0$, дисперсия $D(T) = 1 + \frac{2}{k-2}(k > 2)$, и для значений $k > 30$ распределение Стьюдента практически не отличается от стандартного нормального.

Критические точки распределения Стьюдента (Приложение В) могут быть односторонними и двусторонними.

Например, для случайной величины X , распределенной по закону Стьюдента с $k = 9$ степенями свободы при $\alpha = 0.05$ находим по таблице (Приложение В) одностороннюю критическую точку $t_{кр} = t(k, \alpha) = t(9; 0.05) = 1.83$. Это означает, что при испытаниях вероятность наблюдать значение этой случайной величины, большее $t_{кр} = 1.83$, меньше $\alpha = 0.05$ будет равна $P(X > t_{кр}) < \alpha$, т.е. площадь под кривой плотности распределения, лежащая правее критической точки, составляет $100 \cdot \alpha\%$ от всей площади. Схематически это показано на рисунке 4.7.




Рис. 4.7 – Правосторонняя критическая область для распределения Стьюдента

Двусторонняя критическая точка обозначается $t_{кр} = t(k, \alpha)$, и для нее $P(|X| > t_{кр}) = \alpha$, т.е. величина α равна вероятности наблюдать значение случайной величины X вне интервала $(-t_{кр}; t_{кр})$. График плотности распределения и двусторонняя критическая область проиллюстрированы на рисунке 4.8.




Рис. 4.8 – Двусторонняя критическая область для распределения Стьюдента

4.3.4 Распределение Фишера

Пусть K_1 и K_2 независимые случайные величины, распределенные по закону χ^2 с числом степеней свободы k_1 и k_2 соответственно. Распределение случайной величины

$$F = \frac{K_1/k_1}{K_2/k_2}$$

называется распределением Фишера с k_1 и k_2 степенями свободы. распределение не является симметричным, его математическое ожидание близко к единице $M(F) = \frac{k_2}{k_2 - 2}$, $k_2 > 2$. График плотности распределения Фишера приведен на рисунке 4.9.




Рис. 4.9 – Распределение Фишера

Критические точки распределения Фишера (Приложение Г) имеют следующий смысл. Если X — случайная величина, распределенная по закону Фишера с параметрами k_1 и k_2 ($X \sim F(k_1, k_2)$), и задана вероятность α , то при проведении наблюдений вероятность получить значение случайной величины X , лежащее правее критической точки $F_{кр} = F(k_1, k_2; \alpha)$, меньше α : $P(X > F_{кр}) < \alpha$.

Например, пусть $X \sim F(8, 10)$ и $\alpha = 0.01$. Критическая точка

$$F_{кр} = F(8, 10; 0.01) = 5.06,$$

т. е. вероятность получить значение X , большее 5.06, меньше 0.01. В среднем в 99 случаях из 100 будем наблюдать значения, меньшие 5.06 [7].



Контрольные вопросы по главе 4

1. О чем говорит теорема Чебышева?
2. Почему нормальное распределение является одним из самых важных распределений статистики?
3. Сформулируйте свойства функции Лапласа.
4. Что такое критическая точка? От чего зависит ее значение?
5. Какие еще распределения, кроме нормального, часто используются в статистике?

Глава 5

СТАТИСТИЧЕСКОЕ ОЦЕНИВАНИЕ

5.1 Точечная оценка параметров генеральной совокупности

В предыдущих разделах мы уже рассмотрели некоторые задачи математической статистики, относящиеся к обработке опытных данных. Это были главным образом задачи о нахождении законов распределения случайных величин по результатам опытов. Чтобы найти закон распределения, нужно располагать достаточно обширным статистическим материалом, порядка нескольких сотен опытов (наблюдений). Однако на практике часто приходится иметь дело со статистическим материалом весьма ограниченного объема — с двумя-тремя десятками наблюдений, часто даже меньше. Это обычно связано с дороговизной и сложностью постановки каждого опыта. Такого ограниченного материала явно недостаточно для того, чтобы найти заранее неизвестный закон распределения случайной величины; но все же этот материал может быть обработан и использован для получения некоторых сведений о случайной величине. Например, на основе ограниченного статистического материала можно определить — хотя бы ориентировочно — важнейшие числовые характеристики случайной величины: математическое ожидание, дисперсию. На практике часто бывает, что вид закона распределения известен заранее, а требуется найти только некоторые параметры, от которых он зависит. Например, если заранее известно, что закон распределения случайной величины нормальный, то задача обработки сводится к определению двух его параметров μ и σ . В некоторых задачах вид закона распределения вообще несуществен, а требуется знать только его числовые характеристики. В данном разделе мы рассмотрим ряд задач об определении неизвестных параметров, от которых зависит закон распределения случайной величины, по ограниченному числу опытов [3].

Прежде всего нужно отметить, что любое значение искомого параметра, вычисленное на основе ограниченного числа опытов, всегда будет содержать элемент случайности. Такое приближенное, случайное значение мы будем называть

оценкой параметра. Для определенности будем называть неизвестный параметр генеральной совокупности генеральным (например, генеральная дисперсия), а параметр, рассчитанный по имеющимся экспериментальным данным, — выборочным (выборочная дисперсия). Например, оценкой для математического ожидания может служить среднее арифметическое наблюдаемых значений случайной величины в n независимых опытах. При очень большом числе опытов среднее арифметическое будет с большой вероятностью весьма близко к математическому ожиданию. Если же число опытов n невелико, то замена математического ожидания средним арифметическим приводит к какой-то ошибке. Эта ошибка в среднем тем больше, чем меньше число опытов. Так же будет обстоять дело и с оценками других неизвестных параметров. Любая из таких оценок случайна; при пользовании ею неизбежны ошибки. Желательно выбрать такую оценку, чтобы эти ошибки были по возможности минимальными.

Рассмотрим задачу в общем случае. Имеется случайная величина X , закон распределения которой содержит неизвестный параметр θ . Требуется найти подходящую оценку для параметра θ по результатам n независимых опытов, в каждом из которых величина X приняла определенное значение.

Пусть в n наблюдениях случайная величина X приняла значения $X_1, X_2, \dots, X_n$.

Их можно рассматривать как n «экземпляров» случайной величины X , то есть n независимых случайных величин, каждая из которых распределена по тому же закону, что и случайная величина X .

Обозначим $\hat{\theta}$ оценку для параметра θ . Любая оценка, вычисляемая на основе значений $X_1, X_2, \dots, X_n$, должна представлять собой функцию этих величин: $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ и, следовательно, сама является величиной случайной. Закон распределения $\hat{\theta}$ зависит, во-первых, от закона распределения величины X (и, в частности, от самого неизвестного параметра θ); во-вторых, от числа опытов n . В принципе этот закон распределения может быть найден известными методами теории вероятностей.

Предъявим к оценке $\hat{\theta}$ ряд требований, которым она должна удовлетворять, чтобы быть в каком-то смысле «доброкачественной» оценкой.



.....
Естественно потребовать от оценки $\hat{\theta}$, чтобы при увеличении числа опытов n она приближалась (сходилась по вероятности) к параметру θ . Оценка, обладающая таким свойством, называется **состоятельной**.
.....



.....
Кроме того, необходимо, чтобы, пользуясь величиной $\hat{\theta}$ вместо θ , мы по крайней мере не делали систематической ошибки в сторону завышения или занижения, т. е. чтобы выполнялось условие

$$M(\hat{\theta}) = \theta.$$

Оценка, удовлетворяющая такому условию, называется **несмещенной**.
.....



.....
Наконец, желательно, чтобы выбранная несмещенная оценка обладала по сравнению с другими наименьшей дисперсией, т. е.

$$D(\hat{\theta}) = \min.$$

*Оценка, обладающая таким свойством, называется **эффективной**.*

.....

Например, для неизвестного параметра a нормальной генеральной совокупности $N(a, \sigma)$ в качестве несмещенной оценки можно взять и выборочное среднее арифметическое, и выборочную медиану. Но дисперсия выборочной медианы примерно в 1.6 раза больше, чем дисперсия среднего арифметического. Поэтому более эффективной оценкой является выборочное среднее арифметическое.

На практике не всегда удается удовлетворить всем этим требованиям. Например, может оказаться, что, даже если эффективная оценка существует, формулы для ее вычисления оказываются слишком сложными, и приходится удовлетворяться другой оценкой, дисперсия которой несколько больше. Иногда применяются — в интересах простоты расчетов — незначительно смещенные оценки. Однако выбору оценки всегда должно предшествовать ее критическое рассмотрение со всех перечисленных выше точек зрения.

Рассмотрим основные числовые характеристики случайных величин и определим, какие оценки для них будут являться несмещенными.

Выше было сказано, что для оценки математического ожидания a , как генерального среднего, чаще всего используют выборочное среднее арифметическое. Покажем, что эта оценка является несмещенной.

Выборочное среднее арифметическое вычисляется по формуле:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

По определению несмещенности оценки математическое ожидание выборочного среднего должно быть равно математическому ожиданию генеральной совокупности, то есть генеральному среднему.

$$M(\bar{X}) = M\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n M(X_i) = \frac{1}{n} \cdot n \cdot a = a.$$

Здесь мы воспользовались свойствами математического ожидания.

Покажем, что выборочная дисперсия $\hat{D} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ — смещенная оценка генеральной дисперсии D . Выполним преобразования:

$$\begin{aligned} \hat{D} &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m + m - \bar{X})^2 = \\ &= \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 + 2 \frac{1}{n} (m - \bar{X}) \sum_{i=1}^n (X_i - m) + \frac{1}{n} \sum_{i=1}^n (m - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2 - (m - \bar{X})^2. \end{aligned}$$

Поскольку $M(X_i - m)^2 = \sigma^2$, $M(m - \bar{X})^2 = D(\bar{X}) = \frac{\sigma^2}{n}$, получим

$$M(\hat{D}) = \frac{1}{n} \sum_{i=1}^n \sigma^2 - \frac{\sigma^2}{n} = \sigma^2 - \frac{\sigma^2}{n} = \frac{n-1}{n} \sigma^2.$$

Несмещенной оценкой генеральной дисперсии является оценка

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Рассмотрим теперь точечную оценку генеральной доли.

Пусть в схеме n испытаний Бернулли событие A («успех») наступает X раз. Случайная величина X имеет биномиальное распределение с неизвестным параметром p . В качестве оценки параметра p возьмем относительную частоту наступления события A , т.е. $\theta = p$, $\hat{\theta} = \frac{X}{n}$. Математическое ожидание этой статистики равно

$$M(\hat{\theta}) = M\left(\frac{X}{n}\right) = \frac{1}{n} M(X) = \frac{1}{n} \cdot np = p.$$

Относительная частота события является несмещенной оценкой вероятности этого события [7].

5.2 Интервальное оценивание параметров

5.2.1 Доверительный интервал и доверительная вероятность

Пусть теперь задача точечного оценивания параметра генеральной совокупности решена: найдена оценка $\hat{\theta}$ для неизвестного параметра θ .

В ряде задач требуется не только найти для параметра θ подходящее численное значение, но и оценить его точность и надежность. Требуется знать — к каким ошибкам может привести замена параметра θ его точечной оценкой $\hat{\theta}$ и с какой степенью уверенности можно ожидать, что эти ошибки не выйдут за известные пределы?

Такого рода задачи особенно актуальны при малом числе наблюдений, когда точечная оценка $\hat{\theta}$ в значительной мере случайна и приближенная замена θ на $\hat{\theta}$ может привести к серьезным ошибкам.

Чтобы дать представление о точности и надежности оценки $\hat{\theta}$, в математической статистике пользуются так называемыми доверительными интервалами и доверительными вероятностями.

Пусть для параметра θ получена из опыта несмещенная оценка $\hat{\theta}$. Мы хотим оценить возможную при этом ошибку. Назначим некоторую достаточно большую вероятность γ (например, 0.9, 0.95 или 0.99) и условимся считать событие, происходящее с вероятностью γ , практически достоверным.

Далее найдем такое значение ε , для которого

$$P(|\hat{\theta} - \theta| < \varepsilon) = \gamma.$$

Это означает, что с вероятностью γ (мы заранее назначаем ее достаточно большой) отклонение параметра от его оценки не будет превосходить ε . Диапазон практически возможных значений ошибки, возникающей при замене θ на $\hat{\theta}$, будет $\pm\varepsilon$; большие по абсолютной величине ошибки будут появляться только с малой вероятностью $\alpha = 1 - \gamma$.

Иначе говоря:

$$P(\hat{\theta} - \varepsilon < \theta < \hat{\theta} + \varepsilon) = \gamma,$$

то есть истинное значение параметра θ с вероятностью γ попадет в интервал вида $(\hat{\theta} - \varepsilon; \hat{\theta} + \varepsilon)$.



.....
 При этом заранее выбранная вероятность γ называется **доверительной вероятностью** (или **надежностью**), а сам интервал $(\hat{\theta} - \varepsilon; \hat{\theta} + \varepsilon)$ — **доверительным интервалом** (или **интервальной оценкой**) для параметра θ .

Дадим еще одно истолкование понятию доверительного интервала: его можно рассматривать как интервал значений параметра θ , совместимых с опытными данными и не противоречащих им. Действительно, если условиться считать событие с вероятностью $\alpha = 1 - \gamma$ практически невозможным, то те значения параметра θ , для которых $|\hat{\theta} - \theta| > \varepsilon$, нужно признать противоречащими опытному данным, а те, для которых $|\hat{\theta} - \theta| < \varepsilon$, — совместимыми с ними [3].

Отметим, что чем уже доверительный интервал для оценки неизвестного параметра, тем лучше. Длина доверительного интервала существенно зависит от объема выборки n (уменьшается с ростом n) и от величины доверительной вероятности γ (увеличивается с приближением γ к единице).

5.2.2 Интервальное оценивание генерального среднего

Пусть выборка объема n извлечена из нормальной генеральной совокупности $X \sim N(a, \sigma)$ с неизвестным параметром a (который нужно оценить) и известным σ . Параметр a является математическим ожиданием (генеральным средним) случайной величины X . В качестве точечной оценки параметра a принимают, как мы уже говорили, среднее арифметическое, рассчитанное по выборке: $\hat{a} = \bar{x}$. Для уточнения оценки параметра a построим доверительный интервал, накрывающий этот параметр с заданной доверительной вероятностью γ .

Если выборка объема n извлекается из нормальной генеральной совокупности $N(a, \sigma)$, то статистика $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ имеет нормальное распределение с параметрами:

$$\bar{X} \sim N\left(a, \frac{\sigma}{\sqrt{n}}\right).$$

Поэтому доверительная вероятность γ удовлетворяет соотношению:

$$\gamma = P(|\hat{a} - a| < \varepsilon) = P(|\bar{X} - a| < \varepsilon) = 2\Phi\left(\frac{\varepsilon}{\sigma(\bar{X})}\right) = 2\Phi\left(\frac{\varepsilon \cdot \sqrt{n}}{\sigma}\right).$$

В этом соотношении неизвестной величиной является точность оценки ε . Обозначим $u_{кр} = \frac{\varepsilon\sqrt{n}}{\sigma}$, отсюда

$$\varepsilon = u_{кр} \cdot \frac{\sigma}{\sqrt{n}}.$$

Значение $u_{кр}$ найдем с помощью таблицы функции Лапласа, учитывая, что $\Phi(u_{кр}) = \frac{\gamma}{2}$.

Доверительный интервал для генерального среднего будет иметь вид

$$\left(\bar{x} - u_{кр} \cdot \frac{\sigma}{\sqrt{n}}; \bar{x} + u_{кр} \cdot \frac{\sigma}{\sqrt{n}} \right).$$

Этот метод построения доверительного интервала применяется и в случае, если генеральная совокупность X не является нормальной. Согласно центральной предельной теореме, для выборки достаточно большого объема выборочное среднее $\bar{X}$ будет иметь приближенно нормальное распределение с параметрами $M(\bar{X}) = a$ и $\sigma(\bar{X}) = \frac{\sigma}{\sqrt{n}}$, где a и σ — соответствующие параметры генеральной совокупности. В этом случае для построения доверительного интервала используют ту же формулу, определяя значение $u_{кр}$ по таблицам функции Лапласа, если $n > 30$. При $n \leq 30$ значение $u_{кр}$ заменяют на $t_{кр}$, которое определяют по таблице распределения Стьюдента (Приложение В), и доверительный интервал принимает вид:

$$\left(\bar{x} - t_{кр} \cdot \frac{\sigma}{\sqrt{n}}; \bar{x} + t_{кр} \cdot \frac{\sigma}{\sqrt{n}} \right),$$

где $t_{кр} = t(k; \alpha)$, $k = n - 1$, $\alpha = 1 - \gamma$ (область двусторонняя).

Если значение параметра σ неизвестно, то доверительный интервал строят, заменяя параметр σ с его оценкой

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Величина $\frac{\sigma}{\sqrt{n}}$ называется средней ошибкой выборки и зависит от способа отбора: в случае конечной генеральной совокупности объема N вносится поправка на «бесповторность отбора», равная $\sqrt{1 - \frac{n}{N}}$, то есть при бесповторном отборе

$$\varepsilon = u_{кр} \cdot \frac{\sigma}{\sqrt{n}} \cdot \sqrt{1 - \frac{n}{N}}.$$



Пример

С помощью случайной выборки изучалось время выполнения производственной операции рабочими бригады. На основании 60 наблюдений было установлено, что в среднем на выполнение операции затрачивалось 0.5 часа при среднем квадратическом отклонении 0.12 часа. Считая время выполнения операции нормально распределенной случайной величиной, определить границы, в которых находится среднее время выполнения операции всех рабочих с доверительной вероятностью 0.9, если отбор был а) повторным; б) бесповторным и на предприятии 600 рабочих [1].

Решение:

В условиях данного примера мы имеем дело с задачей построения доверительного интервала для генерального среднего. Генеральная совокупность нормальна с неизвестным параметром μ и известным средним квадратическим отклонением $\sigma = 0.12$. Доверительная вероятность γ , с которой нужно построить интервал, равна 0.9. Поскольку отбор в случае а) повторный, для определения предельной ошибки выборки ε нам необходимо определить только значение критической точки. Так как объем выборки $n = 60$ больше 30, то воспользуемся таблицей значений функции Лапласа.

$$\Phi(u_{\text{кр}}) = \frac{\gamma}{2} = \frac{0.9}{2} = 0.45; \quad u_{\text{кр}} = 1.65.$$

Вычислим ε :

$$\varepsilon = u_{\text{кр}} \cdot \frac{\sigma}{\sqrt{n}} = 1.65 \cdot \frac{0.12}{\sqrt{60}} = 1.65 \cdot 0.02 = 0.033.$$

Запишем доверительный интервал:

$$\left(\bar{x} - u_{\text{кр}} \cdot \frac{\sigma}{\sqrt{n}}; \bar{x} + u_{\text{кр}} \cdot \frac{\sigma}{\sqrt{n}} \right).$$

Получим: $(0.5 - 0.033; 0.5 + 0.033)$. Откуда искомый интервал — $(0.467; 0.533)$.

На основании выборочных данных делаем вывод, что среднее время выполнения операции для всех рабочих предприятия с вероятностью 90% будет больше 0.467 и меньше 0.533 часа.

Если выборка бесповторная (случай б), то значение ε нужно умножить на $\sqrt{1 - \frac{n}{N}}$.

$$\varepsilon = u_{\text{кр}} \cdot \frac{\sigma}{\sqrt{n}} \sqrt{1 - \frac{n}{N}} = 1.65 \cdot \frac{0.12}{\sqrt{60}} \cdot \sqrt{1 - \frac{60}{600}} = 1.65 \cdot 0.02 \cdot 0.95 = 0.031.$$

В этом случае доверительный интервал будет следующим: $(0.469; 0.531)$.

5.2.3 Интервальное оценивание генеральной доли

На практике часто приходится оценивать неизвестную вероятность p события A по его частоте p^* в n независимых опытах.

При этом величину p^* называют *выборочной долей* появлений события A , а p — *генеральной долей*.

Эта задача близко примыкает к уже рассмотренной задаче оценки генерального среднего. Действительно, частота события A в n независимых опытах есть не что иное, как среднее арифметическое наблюдаемых значений величины X , которая в каждом отдельном опыте принимает значение 1, если событие A появилось, и 0, если не появилось:

$$p^* = \frac{1}{n} \sum_{i=1}^n X_i.$$

Напомним, что математическое ожидание величины X равно p ; ее дисперсия $p \cdot (1 - p)$. Математическое ожидание среднего арифметического также равно p , т. е. оценка p^* для p является несмещенной.

Среднее квадратическое отклонение величины p^* равно

$$\sigma(p^*) = \sqrt{\frac{p(1-p)}{n}}.$$

Можно доказать, что это отклонение является минимально возможным, т. е. оценка p^* для p является эффективной.

Таким образом, в качестве точечной оценки для неизвестной вероятности p разумно во всех случаях принимать частоту p^* . Возникает вопрос о точности и надежности такой оценки, т. е. о построении доверительного интервала для вероятности p .

Хотя эта задача и представляет собой частный случай ранее рассмотренной задачи о доверительном интервале для математического ожидания, все же целесообразно решать ее отдельно. Специфика здесь в том, что величина X — дискретная случайная величина только с двумя возможными значениями: 0 и 1. Кроме того, ее математическое ожидание p и дисперсия $p \cdot (1 - p)$ связаны функциональной зависимостью. Это упрощает задачу построения доверительного интервала.

Рассмотрим сначала наиболее простой случай, когда число опытов n сравнительно велико, а вероятность p не слишком велика и не слишком мала. Тогда можно считать, что частота p^* события есть случайная величина, распределение которой близко к нормальному.

Поэтому при больших n ($n > 30$) доверительный интервал для генеральной доли можно построить, используя формулы для построения доверительного интервала при оценке генерального среднего:

$$\left(p^* - u_{\text{кр}} \cdot \sqrt{\frac{p^*(1-p^*)}{n}}; p^* + u_{\text{кр}} \cdot \sqrt{\frac{p^*(1-p^*)}{n}} \right),$$

где $u_{\text{кр}}$ находится по таблицам функции Лапласа с учетом заданной доверительной вероятности γ : $2\Phi(u_{\text{кр}}) = \gamma$.

При малом объеме выборки ($n \leq 30$) предельная ошибка ε определяется по таблице распределения Стьюдента

$$\varepsilon = t_{кр} \cdot \sqrt{\frac{p^*(1-p^*)}{n}},$$

где $t_{кр} = t(k; \alpha)$ и число степеней свободы $k = (n - 1)$, вероятность $\alpha = 1 - \gamma$ (двусторонняя область).

Полученные формулы справедливы, если отбор проводился случайным повторным образом (генеральная совокупность бесконечна), в противном случае необходимо сделать поправку на бесповторность отбора.



Пример

На фирме проведен выборочный опрос 10% работников по вопросам изменения условий труда. Из 120 работников за изменение условий высказалось 55 человек. С доверительной вероятностью 0.95 определить границы, в которых будет находиться доля работников, поддерживающих изменения условий труда.

Решение:

В данной задаче требуется построить доверительный интервал для генеральной доли. Определим выборочную долю p^* .

Из 120 человек за изменение условий труда высказались 55, значит, выборочная доля таких людей составляет $p^* = 55/120 = 0.46$.

Поскольку объем выборки $n = 120 > 30$, $u_{кр}$ можно найти из таблиц Лапласа с учетом заданной доверительной вероятности γ : $2\Phi(u_{кр}) = \gamma$.

$$u_{кр} = 1.96.$$

Предельная ошибка выборки ε по имеющимся данным равна:

$$\varepsilon = u_{кр} \cdot \sqrt{\frac{p^*(1-p^*)}{n}} = 1.96 \cdot \sqrt{\frac{0.46 \cdot (1 - 0.46)}{120}} = 0.09.$$

Таким образом, доверительный интервал для генеральной доли по выборочным данным будет иметь вид:

$$(0.46 - 0.09; 0.46 + 0.09) \text{ или } (0.37; 0.55).$$

Это означает, что истинная доля работников предприятия, выступающая в поддержку изменения условий труда, с вероятностью 0.95 находится в пределах от 37% до 55%. Данный вывод сделан на основании выборочных данных.

В некоторых ситуациях бывает определена предельная ошибка, которую можно позволить себе допустить, а требуется определить минимальное количество наблюдений, которые нужно провести, чтобы с заранее заданной вероятностью не превысить эту ошибку.



Пример

Вероятность изготовления продукции высшего качества фирмой составляет 0.9. Сколько необходимо обследовать единиц продукции, чтобы с доверительной вероятностью 0.95 можно было утверждать, что доля продукции высшего качества по выборке будет отклоняться от постоянной вероятности по модулю не больше, чем на 0.03 [5]?

Решение:

В данной задаче задана предельная ошибка выборки — $\varepsilon = 0.03$.

$$\varepsilon = u_{\text{кр}} \cdot \sqrt{\frac{p^* (1 - p^*)}{n}} = 0.03.$$

Требуется определить объем выборки n . Выразим n из соотношения для ε .

$$n = \frac{u_{\text{кр}}^2 \cdot p^* \cdot (1 - p^*)}{\varepsilon^2}.$$

Подставив числовые данные задачи, получим (учитывая, что $u_{\text{кр}} = 1.96$, как и в предыдущем примере):

$$n = \frac{1.96^2 \cdot 0.9 \cdot (1 - 0.9)}{0.03^2} = 384.16.$$

Поскольку предельная ошибка не должна превышать, округляем в большую сторону до ближайшего целого. Получим, что для того, чтобы с вероятностью 0.95 отклонение от требования качества не будет превышать 0.03%, нужно обследовать не менее 385 единиц продукции.



Контрольные вопросы по главе 5

1. Какими свойствами должна обладать оценка, чтобы она считалась качественной?
2. Что является оценкой центра генеральной совокупности?
3. Является ли выборочная дисперсия несмещенной оценкой генеральной дисперсии? Обоснуйте ответ.
4. Что понимается под термином «доверительная вероятность»?
5. Если имеется две точечные оценки, то по какому признаку следует выбирать более качественную?

Глава 6

ПРОВЕРКА СТАТИСТИЧЕСКИХ ГИПОТЕЗ

6.1 Постановка задачи

В повседневной жизни используя слово «гипотеза», мы имеем в виду предположение о каком либо факте или явлении, которое по необходимости проверяется, исходя из опыта, практики, различных наблюдений и умозаключений.



.....
Статистической гипотезой называется всякое высказывание о генеральной совокупности, проверяемое по выборке.
.....

Статистические гипотезы делятся на два типа:

1. Параметрические — это гипотезы, сформулированные относительно параметров некоторого распределения: среднего значения, дисперсии, генеральной доли. При этом вид распределения известен.
2. Непараметрические — это гипотезы, сформулированные относительно вида распределения, например определение по выборке степени нормальности генеральной совокупности [3].

Не располагая сведениями о всей генеральной совокупности, высказанную гипотезу сопоставляют, по определенным правилам, с выборочными данными и делают вывод о том, можно принять гипотезу или нет. Процедура сопоставления высказанной гипотезы с выборкой называется проверкой гипотезы.



.....
*Гипотеза, которая проверяется, называется **основной** (нулевой) и обозначается H_0 . Гипотеза, которая ей противопоставляется, называется **альтернативной** (конкурирующей) и обозначается H_1 .*
.....

Нулевая и альтернативная гипотезы представляют собой две возможности выбора, осуществляемого в задачах проверки статистических гипотез. По выборке будет принято решение о справедливости для генеральной совокупности либо гипотезы H_0 , либо гипотезы H_1 .

Например, $H_0 : M(x) = 1$ (математическое ожидание генеральной совокупности равно 1); $H_1 : M(x) > 1$ или $H_1 : M(x) < 1$, или $H_1 : M(x) \neq 1$ (математическое ожидание генеральной совокупности больше 1 или меньше 1, или не равно 1).

Цель статистической проверки гипотезы состоит в том, чтобы на основании выборочных данных принять решение о справедливости основной гипотезы или отклонить ее в пользу альтернативной.

При проверке любой статистической гипотезы возможны варианты:

- гипотеза H_0 верна и ее принимают (правильное решение);
- гипотеза H_0 неверна и ее отвергают, принимая гипотезу H_1 (правильное решение);
- гипотеза H_0 верна, но ее отвергают согласно правилу проверки (неправильное решение) — это ошибка первого рода;
- гипотеза H_0 неверна, но ее принимают согласно правилу проверки (неправильное решение) — это ошибка второго рода [3].

Уровень значимости α — это вероятность ошибки первого рода, т.е. вероятность того, что будет принята гипотеза H_1 , если на самом деле для генеральной совокупности верна гипотеза H_0 . Вероятность α задается заранее малым числом, поскольку это вероятность ошибочного заключения, при этом обычно используют некоторые стандартные значения: 0.05; 0.01; 0.005; 0.001.

Вероятность ошибки второго рода обозначают β — это вероятность того, что будет принята гипотеза H_0 , если на самом деле верна гипотеза H_1 . Вероятность не совершить ошибку второго рода ($1 - \beta$), т.е. вероятность правильного отклонения неверной нулевой гипотезы, называют мощностью критерия.



.....
Статистическим критерием называют однозначно определенное правило, устанавливающее условия, при которых проверяемую гипотезу H_0 следует либо отвергнуть, либо принять.

Основу критерия составляет специально составленная выборочная характеристика K , точное или приближенное распределение которой известно.

В формулу критерия K подставляют конкретные числа, полученные в результате наблюдений, и подсчитывают числовое значение критерия. Значение критерия, вычисленное по выборке, называют наблюдаемым значением $K_{\text{набл}}$.



.....
 Значения критерия K разделяются на две части: область **допустимых значений** (область принятия гипотезы H_0) и **критическую область** (область принятия гипотезы H_1).

Критическая область состоит из тех значений критерия K , которые маловероятны при справедливости гипотезы H_0 . Если значение $K_{\text{набл}}$ критерия K , рассчитанное по выборочным данным, попадает в критическую область, то гипотеза H_0 отвергается в пользу альтернативной H_1 ; в противном случае мы утверждаем, что нет оснований отклонять гипотезу H_0 .



Пример

Для подготовки к зачету преподаватель сформулировал 100 вопросов (генеральная совокупность) и считает, что студенту можно поставить «зачтено», если тот знает 60% вопросов (критерий). Преподаватель задает студенту 5 вопросов (выборка из генеральной совокупности) и ставит «зачтено», если правильных ответов не меньше трех [7].

Решение:

Гипотеза H_0 : «студент курс усвоил, знает больше 60% вопросов».

Гипотеза H_1 : «студент курс не усвоил, знает меньше 60% вопросов».

Студент А выучил 70 вопросов из 100, но ответил правильно только на два из пяти, предложенных преподавателем, — зачет не сдан. В этом случае преподаватель совершает ошибку первого рода.

Студент Б выучил 50 вопросов из 100, но ему повезло, и он ответил правильно на 3 вопроса — зачет сдан, но совершена ошибка второго рода.

Преподаватель может уменьшить вероятность этих ошибок, увеличив количество задаваемых на зачете вопросов.

Чтобы построить критическую область, нужно знать закон распределения статистики K при условии, что гипотеза H_0 справедлива. Уровень значимости α (вероятность наблюдаемому значению $K_{\text{набл}}$ попасть в критическую область) определяет «размер» критической области, а альтернативная гипотеза H_1 — «форму» критической области.

Пусть θ — некоторый параметр генеральной совокупности, относительно которого сформулирована основная гипотеза $H_0 : \theta = \theta_0$. Тогда, в зависимости от контекста решаемой задачи, альтернативная гипотеза может быть трех видов: $H_1 : \theta > \theta_0$, $H_1 : \theta < \theta_0$ и $H_1 : \theta \neq \theta_0$. Каждая из этих альтернативных гипотез определяет свою «форму» критической области:




Рис. 6.1 – Правосторонняя критическая область

1. $H_1 : \theta > \theta_0$. Такая альтернативная гипотеза определяет «правостороннюю» критическую область. Это означает, что критическая область (на рисунке 6.1 показана штриховкой) будет лежать правее K_p — критической точки, которая определяется видом распределения и уровнем значимости α .




Рис. 6.2 – Левосторонняя критическая область

2. $H_1 : \theta < \theta_0$. Эта конкурирующая гипотеза дает нам «левостороннюю» критическую область (на рисунке 6.2 — заштрихованная часть). Если значение критерия, рассчитанное по выборке, будет лежать левее критической точки, взятой с противоположным знаком, то основную гипотезу мы отклоним в пользу альтернативной.




Рис. 6.3 – Двусторонняя критическая область

3. $H_1 : \theta \neq \theta_0$. При такой альтернативной гипотезе критическая область называется «двусторонней». В этом случае область допустимых значений критерия будет находиться между $-K_{кр}$ и $K_{кр}$. Критическая область на рисунке 6.3 выделена штриховкой.

Во всех этих случаях при заданном уровне значимости α заштрихованная площадь составляет $100 \cdot \alpha\%$ от всей площади под кривой плотности распределения статистики K .

Алгоритм проверки статистических гипотез сводится к следующему:

1. По выборочным данным формулируют основную H_0 и альтернативную H_1 гипотезы.
2. Задают уровень значимости α (0.05 или 0.01).
3. В зависимости от H_0 определяют статистический критерий K , имеющий известное распределение.
4. По выборке и формуле критерия K рассчитывают наблюдаемое значение критерия $K_{набл}$.
5. В зависимости от вида H_1 определяют вид критической области и критические точки по таблице Приложения для распределения критерия K .

6. По результатам проверки устанавливают, принадлежит ли $K_{\text{набл}}$ критической области. Если да, то основную гипотезу отвергают в пользу альтернативной, в противном случае делают вывод о принятии гипотезы H_0 .
7. Формулируют общий вывод, исходя из поставленной задачи [7].

6.2 Проверка гипотез о параметрах распределения

6.2.1 Гипотезы о генеральном среднем и генеральной дисперсии

Пусть из нормально распределенной генеральной совокупности X с неизвестным математическим ожиданием a и известной дисперсией σ^2 извлечена выборка объема n . Выдвигается нулевая гипотеза H_0 о том, что значение математического ожидания генеральной совокупности равно числу a_0 , то есть $H_0 : a = a_0$.

Для проверки нулевой гипотезы используется случайная величина

$$K = \frac{\bar{X} - a_0}{\sigma} \cdot \sqrt{n},$$

где $\bar{X}$ — выборочное среднее; σ — среднеквадратическое отклонение генеральной совокупности.

Случайная величина имеет стандартное нормальное распределение ($K \sim N(0, 1)$). Критическое значение определяется исходя из вида альтернативной гипотезы.

Эта же статистика K используется в случае, когда дисперсия генеральной совокупности σ^2 неизвестна, но объем выборки достаточно велик, $n \geq 30$. Тогда вместо σ в формулу подставляется значение оценки среднего квадратического отклонения s , найденной по выборке:

$$\hat{\sigma}^2 = s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$



Пример

На станке-автомате должны изготавливаться детали с номинальным контролируемым размером $a_0 = 12$ мм. Известно, что распределение контролируемого размера является нормальным. Были измерены размеры 36 случайно отобранных деталей. Среднее значение контролируемого размера оказалось равным $\bar{x} = 11.7$ мм, выборочное среднее квадратическое отклонение s оказалось равным 0.5 мм. Можно ли считать, что станок-автомат изготавливает детали уменьшенного размера и, следовательно, требует наладки?

Решение:

Согласно алгоритму проверки статистических гипотез сформулируем основную и альтернативную гипотезы.

По условию задачи необходимо проверить нулевую гипотезу о значении математического ожидания генеральной совокупности: $H_0 : a = 12$ мм. При этом из смысла задачи ясно, что альтернативная гипотеза будет $H_1 : a < 12$ мм (станок изготавливает уменьшенные детали).

Положим уровень значимости $\alpha = 0.05$.

Поскольку объем выборки достаточно большой ($n = 36 > 30$), то вместо истинного значения среднего квадратического отклонения можно использовать его оценку $s = 0.5$ мм, а также использовать статистику $K \sim N(0.1)$, наблюдаемое значение которой равно

$$K_{\text{набл}} = \frac{\bar{X} - a_0}{\sigma} \cdot \sqrt{n} = \frac{11.7 - 12}{0.5} \sqrt{36} = -3.6.$$

Так как альтернативная гипотеза левосторонняя, то и критическая область — левосторонняя и её границу $K_{\text{кр}}$ следует искать по таблице функции Лапласа (Приложение А) из равенства $\Phi(K_{\text{кр}}) = \frac{1}{2} - \alpha$. Так как $\alpha = 0.05$ имеем $\Phi(K_{\text{кр}}) = 0.5 - 0.05 = 0.45$ и значение $K_{\text{кр}} = 1.65$. Поскольку критическая область левосторонняя, то значение критической точки отрицательно, то есть $K_{\text{кр}} = -1.65$.

Наблюдаемое значение ($K_{\text{набл}} = -3.6$) попало в критическую область, так как $K_{\text{набл}} < K_{\text{кр}}$, следовательно, основная гипотеза отвергается в пользу альтернативной, то есть станок изготавливает уменьшенные детали и требует наладки.

Если объем выборки меньше 30, то используется статистика с распределением Стьюдента $T_{(n-1)}$ с $k = n - 1$ степенями свободы.



Пример

По паспортным данным автомобильного двигателя расход топлива на 100 км пробега составляет 10 л. В результате изменения конструкции двигателя ожидается, что расход топлива уменьшится. Для проверки были испытаны 25 случайно отобранных автомобилей с модернизированным двигателем. Средний расход топлива на 100 км пробега оказался равным $\bar{x} = 9.6$ л. Несмещенная оценка среднего квадратического отклонения расхода топлива равна 2 л. Можно ли на уровне значимости $\alpha = 0.05$ утверждать, что изменение конструкции двигателя не повлияло на расход топлива? Считать, что выборка произведена из нормальной генеральной совокупности.

Решение:

$H_0 : a = 10$ — автомобиль расходует 10 л топлива на 100 км.

$H_1 : a < 10$ — модернизированный автомобиль расходует меньше топлива.

Уровень значимости $\alpha = 0.05$.

Так как мы имеем дело с выборкой малого объема, то используем статистику Стьюдента с $k = 25 - 1 = 24$ степенями свободы.

По таблицам распределения Стьюдента (Приложение В) находим критическое значение в случае левосторонней гипотезы: $t_{\text{кр}} = -1.711$.

Вычислим наблюдаемое значение критерия:

$$T_{\text{набл}} = \frac{9.6 - 10}{2} \sqrt{25} = -1.$$

Поскольку наблюдаемое значение критерия больше критического, оно попадает в область принятия нулевой гипотезы, поэтому H_0 не отвергается, т. е. нет оснований считать, что новая конструкция двигателя позволила уменьшить расход топлива.

К гипотезе о значении генеральной дисперсии мы приходим, когда нужно проверить, например, точность какого-либо станка или прибора, иными словами, величину отклонения от заданного значения.

Пусть из нормально распределенной генеральной совокупности извлечена выборка объема n . На основании полученных данных требуется проверить нулевую гипотезу о том, что дисперсия генеральной совокупности равна числу σ_0^2 : $H_0 : \sigma^2 = \sigma_0^2$. Альтернативная гипотеза чаще всего формулируется в виде: $H_0 : \sigma^2 > \sigma_0^2$ (правосторонняя критическая область).

Если значение математического ожидания известно, то для проверки нулевой гипотезы используется случайная величина

$$K = \frac{nS^2}{\sigma_0^2},$$

имеющая распределение χ^2 с n степенями свободы.

Если математическое ожидание неизвестно, то статистика имеет вид:

$$K = \frac{(n-1)S^2}{\sigma_0^2}$$

и распределение χ^2 с $(n-1)$ степенями свободы.



Пример

Точность наладки станка-автомата, производящего некоторые детали, характеризуется дисперсией длины деталей. Если эта величина больше 400 мкм², станок останавливают для наладки. Выборочная дисперсия длины 15 случайно отобранных деталей из продукции станка оказалась равной 680 мкм². Нужно ли проводить наладку станка, если уровень значимости $\alpha = 0.01$ [5]?

Решение:

По условию задачи требуется проверить нулевую гипотезу о значении дисперсии генеральной совокупности $H_0 : \sigma^2 = 400$ мкм² против альтернативной $H_1 : \sigma^2 > 400$ (правосторонняя критическая область).

По таблице распределения χ^2 (Приложение Б), учитывая $\alpha = 0.01$ и $k = n - 1 = 14$, найдем критическое значение $K_{\text{кр}} = 29.14$. Вычислим наблюдаемое значение статистики:

$$K_{\text{набл}} = \frac{15 \cdot 680}{400} = 25.5.$$

Таким образом, нулевая гипотеза не отвергается (станок не требует наладки), так как наблюдаемое значение не попало в критическую область, $K_{\text{набл}} < K_{\text{кр}}$.

.....

6.2.2 Сравнение параметров генеральной совокупности

На практике часто требуется сравнить какие-либо параметры двух генеральных совокупностей. Например, равны ли средние показатели урожайности на двух опытных полях с применением разных типов удобрений; обеспечивают ли одинаковую точность два станка и т. п. Для такого рода анализа из обеих совокупностей извлекаются выборки, причем не обязательно одинакового объема, и формулируются гипотезы о равенстве (или не равенстве) соответствующих параметров. По результатам проверки этих гипотез делаются выводы.

Рассмотрим задачу о сравнении генеральных средних двух совокупностей.

Пусть из каждой из двух нормально распределенных генеральных совокупностей X_1 (с параметрами a_1, σ_1) и X_2 (с параметрами a_2, σ_2) извлечены выборки объема n_1 и n_2 соответственно. Требуется проверить нулевую гипотезу $H_0: a_1 = a_2$ о равенстве средних значений этих генеральных совокупностей. Альтернативная гипотеза формулируется в соответствии с условиями задачи или эксперимента.

Если генеральные дисперсии известны, то для проверки нулевой гипотезы используют случайную величину

$$K = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}},$$

где $\bar{x}_1$ и $\bar{x}_2$ — выборочные средние первой и второй выборок соответственно. Статистика K имеет нормальное распределение с математическим ожиданием, равным нулю, и дисперсией, равной единице. Критическое значение выбирается в соответствии с задаваемым уровнем значимости по таблице значений функции Лапласа (Приложение А).

Если же дисперсии неизвестны, но предполагается, что они равны, то применяется статистика

$$K = \frac{\bar{x}_1 - \bar{x}_2}{S} \cdot \sqrt{\frac{n_1 \cdot n_2}{n_1 + n_2}},$$

имеющая распределение Стьюдента с $k = n_1 + n_2 - 2$ степенями свободы.

При этом

$$s^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2},$$

где s_1^2 и s_2^2 — выборочные несмещенные оценки σ_1 и σ_2 соответственно.



Пример

Рабочий в начале смены настроил два станка-автомата: X и Y . Предварительным анализом было установлено, что размер диаметра валиков, изготовленных каждым автоматом, имеет нормальный закон распределения с дисперсией 5 мм^2 для станка X и 7 мм^2 для станка Y . В конце смены был проведен выборочный контроль 14 деталей, обработанных на станке X , и 9 деталей — на станке Y . Средние диаметры валиков соответственно составили: для автомата X — 182 мм, для Y — 185 мм. Проверить гипотезу о том, что два станка-автомата настроены на один размер [5].

Решение:

$H_0 : a_X = a_Y$ — станки настроены на один размер.

$H_1 : a_X < a_Y$ — средний размер для станка меньше среднего размера для станка Y .

Примем уровень значимости $\alpha = 0.01$.

Поскольку генеральные дисперсии известны, то используем критерий

$$K = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}.$$

Вычислим наблюдаемое значение критерия

$$K_{\text{набл}} = \frac{182 - 185}{\sqrt{\frac{5}{14} + \frac{7}{9}}} = -2.82.$$

Согласно альтернативной гипотезе, критическая область левосторонняя. Учитывая, что $\Phi(K_{\text{кр}}) = \frac{1}{2} - \alpha$, имеем $K_{\text{кр}} = -2.32$.

Так как $K_{\text{набл}} < K_{\text{кр}}$, нулевая гипотеза на уровне значимости 0,01 отвергается.

Вывод: различие выборочных средних не случайно и станки не настроены на один размер.

Кроме генеральных средних сравнивают также и генеральные дисперсии.

Пусть по двум независимым выборкам $x_1, x_2, \dots, x_{n_1}$ и $y_1, y_2, \dots, y_{n_2}$, извлеченным из нормальных генеральных совокупностей $X \sim N(a_1, \sigma_1)$ и $Y \sim N(a_2, \sigma_2)$ найдены несмещенные оценки дисперсий σ_1^2 и σ_2^2 :

$$s_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^n (x_i - \bar{x})^2 \text{ и } s_2^2 = \frac{1}{n_2 - 1} \sum_{j=1}^m (y_j - \bar{y})^2.$$

Для того, чтобы на данном уровне значимости α проверить гипотезу о равенстве генеральных дисперсий $H_0 : \sigma_1^2 = \sigma_2^2$, используют статистику, имеющую распределение Фишера с числами степеней свободы $k_1 = n_1 - 1$ и $k_2 = n_2 - 1$. Наблюдаемое значение этой статистики обычно вычисляют, рассматривая отношение

большей оценки $\max(s_1^2, s_2^2)$ к меньшей $\min(s_1^2, s_2^2)$, поэтому альтернативная гипотеза и критическая область являются правосторонними.



Пример

Проведены измерения пульса у 10 больных, подвергнутых некоторой лечебной процедуре, а также у 12 больных контрольной группы. Статистическая обработка результатов показала, что несмещенная оценка дисперсии частоты пульса больных первой группы составила 9 (уд/мин)², у больных второй группы — 8 (уд/мин)². Предполагая, что значения пульса у подобных больных распределены по нормальному закону, при уровне значимости $\alpha = 0.05$ проверить значимость различия между оценками дисперсий.

Решение:

Итак, необходимо проверить нулевую гипотезу $H_0 : \sigma_1^2 = \sigma_2^2$ относительно альтернативной $H_1 : \sigma_1^2 \neq \sigma_2^2$. Так как исправленная выборочная дисперсия значений пульса у больных первой группы превышает соответствующую оценку для больных второй группы, то по формуле для статистики F получим:

$$F_{\text{набл}} = \frac{9}{8} = 1.125.$$

Поскольку альтернативная гипотеза задает двустороннюю критическую область, число степеней свободы числителя равно $k_1 = n_1 - 1 = 10 - 1 = 9$, а знаменателя — $k_2 = n_2 - 1 = 12 - 1 = 11$, для $\alpha = 0.05$ по таблице распределения Фишера (Приложение Г) найдем критическое значение статистики: $F_{\text{кр}} = 2.9$.

Наблюдаемое значение критерия меньше критического (попало в область принятия нулевой гипотезы), следовательно, проверяемая гипотеза не противоречит опытным данным, и при уровне значимости $\alpha = 0.05$ имеющееся различие в оценках дисперсии следует считать незначимым.

6.2.3 Гипотезы о генеральной доле

Пусть проведено некоторое количество испытаний по схеме Бернулли (испытания независимы, вероятность наступления события A постоянна). Требуется проверить нулевую гипотезу о том, что вероятность появления «успеха» в каждом испытании равна числу p_0 . По выборке объема n определяют относительную частоту p^* появления события A : $p^* = \frac{m}{n}$, где m — количество появлений события A в серии из n испытаний. Если объем выборки достаточно велик, то для проверки нулевой гипотезы используется статистика, имеющая стандартное нормальное распределение:

$$K = \frac{p^* - p_0}{\sqrt{p_0(1 - p_0)}} \cdot \sqrt{n}.$$

Вид альтернативной гипотезы определяется из условий задачи.



Пример

Игральную кость подбросили 600 раз, шестерка появилась 125 раз. Можно ли утверждать, что кость правильная? Принять $\alpha = 0.05$ [6].

Решение:

Вероятность выпадения шестерки при подбрасывании игральной кости равна $\frac{1}{6}$. Значит, требуется проверить нулевую гипотезу $H_0: p = \frac{1}{6}$.

Если нулевая гипотеза верна, то есть кость правильная, то математическое ожидание числа появлений шестерки в $n = 600$ бросаниях равно

$$M = n \cdot p = \frac{1}{6} \cdot 600 = 100.$$

Так как $125 > 100$, то альтернативную гипотезу сформулируем в виде:

$$H_1: p > \frac{1}{6}.$$

Следовательно, критическая область — правосторонняя. Для заданного $\alpha = 0.05$ находим критическое значение $K_{кр}$ с помощью таблицы из Приложения А и условия:

$$\Phi(K_{кр}) = \frac{1}{2} - \alpha.$$

$$K_{кр} = 1.65.$$

Наблюдаемое значение статистики K :

$$K_{набл} = \frac{\frac{125}{600} - \frac{1}{6}}{\sqrt{\frac{1}{6} \cdot \left(1 - \frac{1}{6}\right)}} \cdot \sqrt{600} \approx 2.73.$$

Наблюдаемое по выборке значение критерия больше критического, следовательно, нулевая гипотеза отвергается в пользу альтернативной. Игральную кость нельзя считать правильной.

На практике часто встречается задача сравнения долей признака (вероятностей) в двух совокупностях. Например, если выборочная доля признака в одной совокупности отличается от такой же доли в другой совокупности, то можно ли считать, что наличие признака в одной совокупности действительно вероятнее или полученное расхождение является случайным? Для проверки гипотезы из двух генеральных совокупностей составляют выборки достаточно большого объема ($n > 30$) и по ним определяют выборочные доли, которые являются точечными оценками

неизвестных генеральных долей: $p_1^* = \frac{m_1}{n_1}$ и $p_2^* = \frac{m_2}{n_2}$. В качестве критерия проверки используют величину, которая зависит от выборочных данных и по значению которой можно судить о близости выборочных долей двух распределений:

$$K = \frac{p_1^* - p_2^*}{\sqrt{\bar{p}(1 - \bar{p})}} \cdot \sqrt{\frac{n_1 n_2}{n_1 + n_2}}.$$

Выбранный критерий при выполнении нулевой гипотезы подчиняется стандартному нормальному закону распределения. Выборочная доля объединенной выборки определяется по формуле:

$$\bar{p} = \frac{m_1 + m_2}{n_1 + n_2}.$$



Пример

В результате выборочной проверки качества однотипных изделий оказалось, что из 300 изделий фирмы А бракованных — 30, а из 400 фирмы В — 52 изделия. Можно ли считать, что различия в качестве изделий различных фирм существенны? Уровень значимости принять $\alpha = 0.05$.

Решение:

По условию задачи мы имеем дело с двумя генеральными совокупностями, из которых извлечены выборки объемом $n_1 = 300$ и $n_2 = 400$. Количества появления события А (деталь бракованная) равны $m_1 = 30$ и $m_2 = 52$ соответственно. Значит, выборочные доли — $p_1^* = \frac{30}{300}$ и $p_2^* = \frac{52}{400}$.

Сформулируем основную и альтернативную гипотезы:

- $H_0 : p_1 = p_2$ — различия в качестве незначительны и случайны;
- $H_1 : p_1 < p_2$ — качество изделий первой фирмы лучше.

Согласно виду альтернативной гипотезы критическая область — левосторонняя. Для заданного $\alpha = 0.05$ находим критическое значение $K_{кр}$ с помощью таблицы из Приложения А и условия:

$$\Phi(K_{кр}) = \frac{1}{2} - \alpha.$$

$$K_{кр} = -1.65.$$

Для определения наблюдаемого значения вычислим вначале выборочную долю объединенной выборки:

$$\bar{p} = \frac{30 + 52}{300 + 400} = 0.103.$$

Наблюдаемое значение по выборкам равно:

$$K_{набл} = \frac{\frac{30}{300} - \frac{52}{400}}{\sqrt{0.103 \cdot (1 - 0.103)}} \cdot \sqrt{\frac{300 \cdot 400}{300 + 400}} = -1.29.$$

Так как $K_{\text{набл}} = -1.29 > K_{\text{кр}} = -1.65$, нулевая гипотеза не противоречит опытным данным и принимается при уровне значимости 0.05.

Вывод: различия в качестве изделий фирм A и B несущественны (случайны).

6.3 Непараметрические гипотезы

6.3.1 Проверка гипотез о виде распределения

При проверке гипотез о параметрах генеральной совокупности закон распределения предполагался заранее известным. Однако существуют задачи, в которых требуется определить, по какому закону распределены данные генеральной совокупности. Для решения таких задач по выборке строят полигон частот или гистограмму и делают предположение о виде распределения. Однако это предположение далее следует проверять. Для проверки гипотез о виде распределения служат специальные критерии — *критерии согласия*. Они отвечают на вопрос: согласуются ли результаты экспериментов с предположением о том, что генеральная совокупность имеет заданное распределение.

Приведем пример, на котором рассмотрим один из таких критериев — *критерий согласия Пирсона*.

В этом критерии мерой расхождения между гипотетическим (предполагаемым) и эмпирическим распределением служит статистика

$$K = \sum_{j=1}^k \frac{(n_j - np_j)^2}{np_j},$$

где n — объем выборки; k — количество интервалов (групп наблюдений); n_j — количество наблюдений, попавших в j -й интервал; p_j — вероятность попадания в j -й интервал случайной величины, распределенной по гипотетическому закону.

Если предположение о виде закона распределения справедливо, то статистика Пирсона распределена по закону «хи-квадрат» с числом степеней свободы $k - r - 1$ (r — число параметров распределения, оцениваемых по выборке): $K \sim \chi^2_{(k-r-1)}$.



Пример

При измерении веса 30 новорожденных (с точностью до 10 г) получили выборку 3.7, 3.85, 3.7, 3.78, 3.6, 4.45, 4.2, 3.87, 3.33, 3.76, 3.75, 4.03, 3.8, 4.75, 3.25, 4.1, 3.55, 3.35, 3.38, 3.05, 3.56, 4.05, 3.24, 4.08, 3.58, 3.98, 3.4, 3.8, 3.06, 4.38. На уровне значимости проверить гипотезу о нормальном распределении веса новорожденных [7].

Решение:

Сгруппируем выборку (табл. 6.1), определив количество интервалов с помощью коэффициента Старджеса.

$$k = 1 + 3.3 \lg n = 1 + 3.3 \cdot \lg 30 \approx 5.875 \approx 6.$$

Длина интервала — $d = \frac{x_{(n)} - x_{(1)}}{k} = \frac{4.8 - 3}{6} = 0.3$.

Для удобства вычислений мы немного расширили границы выборки. В п. 3.2.2 правомерность такого расширения обсуждалась.

Таблица 6.1 – Сгруппированный статистический ряд

Интервалы	[3; 3.3)	[3.3; 3.6)	[3.6; 3.9)	[3.9; 4.2)	[4.2; 4.5)	[4.5; 4.8)
Частоты, n_i	4	7	10	5	3	1
Относительные частоты, v_i	0.133	0.233	0.3	0.167	0.1	0.033

Сформулируем основную и альтернативную гипотезы.

$H_0 : X \sim N(\hat{a}, \hat{\sigma})$ — случайная величина X (вес новорожденных) подчиняется нормальному закону с параметрами $\hat{a}$ и $\hat{\sigma}$. Так как истинных значений параметров a и σ мы не знаем, возьмем их оценки, рассчитанные по выборке: $\hat{a} = 3.746$, $\hat{\sigma} = 0.399$.

H_1 : случайная величина X не подчиняется нормальному закону с данными параметрами.

Рассчитаем наблюдаемое значение $K_{\text{набл}}$ статистики Пирсона. Эмпирические частоты n_j уже известны, а для вычисления вероятностей p_j (в предположении, что гипотеза H_0 справедлива) используем формулу:

$$p_j = P(a_j < X < a_{j+1}) = \Phi\left(\frac{a_{j+1} - \hat{a}}{\hat{\sigma}}\right) - \Phi\left(\frac{a_j - \hat{a}}{\hat{\sigma}}\right), j = 1, 2, \dots, k$$

и таблицу функции Лапласа (Приложение А). Для наглядности сведем полученные результаты в таблицу 6.2.

Таблица 6.2 – Сводные результаты проверки гипотезы

№ п/п	Интервалы группировки $[a_j; a_{j+1})$	Наблюдаемая частота n_j	Вероятность p_j попадания в j -й интервал	Ожидаемая частота $n \cdot p_j$	Слагаемые статистики Пирсона $\frac{(n_j - np_j)^2}{np_j}$
1.	[3; 3.3)	4	0.101	3.032	0.309
2.	[3.3; 3.6)	7	0.225	6.761	0.008
3.	[3.6; 3.9)	10	0.295	8.79	0.166
4.	[3.9; 4.2)	5	0.222	6.665	0.416
5.	[4.2; 4.5)	3	0.098	2.946	0.001
6.	[4.5; 4.8)	1	0.025	0.758	0.077
Σ	—	30	0.965	28.95	$K_{\text{набл}} = 0.978$.

Проведя все необходимые вычисления, получим наблюдаемое значение статистики Пирсона, равное $K_{\text{набл}} = 0.978$.

Определим границу критической области. Так как статистика Пирсона измеряет разницу между эмпирическим и теоретическим распределениями, то чем больше ее наблюдаемое значение $K_{\text{набл}}$, тем сильнее довод против основной гипотезы. Поэтому критическая область для этой статистики всегда правосторонняя:

$[K_{кр}; +\infty)$. Её границу $K_{кр} = \chi^2_{(k-r-1; \alpha)}$ находим по таблицам распределения «хи-квадрат» (Приложение Б) и заданным значениям $\alpha = 0.025$, $k = 6$ (число интервалов), $r = 2$ (параметры a и σ оценены по выборке): $K_{кр} = \chi^2(6 - 2 - 1; 0.025) = \chi^2(3; 0.025) = 9.4$.

Наблюдаемое значение статистики Пирсона не попадает в критическую область: $K_{набл} < K_{кр}$, поэтому нет оснований отвергать основную гипотезу.

Вывод: на уровне значимости 0.025 справедливо предположение о том, что вес новорожденных имеет нормальное распределение.

6.3.2 Проверка гипотезы об однородности данных

На практике часто возникает задача сравнения двух методов обработки, двух рационов питания, двух методик обучения и т. п. В статистике эту задачу можно решить с помощью критериев однородности.

Критерий знаков

Рассмотрим вначале случай парных наблюдений: для каждого объекта измеряются два значения интересующего нас признака (например, до воздействия и после). Результатом будут две группы наблюдений: $x_1, x_2, \dots, x_n$ и $y_1, y_2, \dots, y_n$.

Основная гипотеза имеет вид: $H_0 : F_1(x) = F_2(x)$ — закон распределения генеральной совокупности X , из которой извлечена первая выборка, тот же самый, что и закон распределения Y . Предполагается, что разности $x_i - y_i$ взаимно независимы: ($i = 1, 2, \dots, n$) и $P(x_i < y_i) = P(x_i > y_i) = 0.5$.

Для каждой разности $x_i - y_i$ определим ее знак и подсчитаем $K_{набл}$ — количество тех знаков, которых меньше в данной выборке. Критическим значением $K_{кр}$ будем считать такое, что при заданном уровне значимости α $P(K \leq K_{кр}) \leq \alpha$.

Некоторые значения критических точек приведены в таблице 6.3 [7].

Таблица 6.3 – Критические точки для критерия знаков

Уровень значимости α	Объем выборки n					
	5	10	15	20	25	30
0.01	0	0	2	3	5	7
0.05	0	1	3	5	7	9
0.1	0	1	3	5	7	10



Пример

Для желающих похудеть была предложена специальная диета. У десяти участников эксперимента измеряли вес до применения диеты (X , кг) и после применения (Y , кг). Результаты исследования приведены в таблице 6.4 [7].

Оказывает ли диета какое-либо существенное влияние на вес?

Таблица 6.4 – Экспериментальные данные

X	68	80	92	81	70	79	78	66	57	76
Y	60	84	87	79	74	71	72	67	56	70

Решение:

Сформулируем основную и альтернативную гипотезы:

- $H_0 : F_1(x) = F_2(x)$ – выборочные данные однородны, выборки извлечены из генеральных совокупностей с одинаковыми распределениями. Применительно к условиям: диета не оказывает существенного влияния на вес тела.
- $H_1 : F_1(x) \neq F_2(x)$ – выборки неоднородны; распределения генеральных совокупностей X и Y различны; диета оказывает влияние на вес.

Запишем последовательность знаков разностей $x_i - y_i$: +, −, +, −, −, +, +, −, +, +. Знак «+» в этой последовательности встречается 6 раз, а «−» — 4 раза, поэтому $K_{\text{набл}}$ равно количеству знаков «минус»: $K_{\text{набл}} = 4$.

Для данного объема выборки $n = 10$ критическое значение $K_{\text{кр}} = 1$ при $\alpha = 0.05$ и $\alpha = 0.1$, поэтому наблюдаемый результат $K_{\text{набл}} = 4$ не является маловероятным при условии, что гипотеза H_0 справедлива, вероятность этого события больше 0.1.

Следовательно, на уровне значимости 0.1 нет оснований отвергать гипотезу H_0 , диета не оказывает существенного влияния на вес.

.....

Заметим, что если среди пар значений x_i и y_i есть равные $x_i = y_i$, то их следует отбросить, соответственно уменьшив объем выборки n .

Критерий знаков применяется для выборок малого объема, его основное достоинство — простота.

Критерий Вилкоксона

Этот критерий используется для проверки однородности двух независимых выборок $x_1, x_2, \dots, x_{n_1}$ и $y_1, y_2, \dots, y_{n_2}$. Он применяется к случайным величинам, распределения которых неизвестны, но являются непрерывными.

Основная гипотеза имеет вид $H_0 : F_1(x) = F_2(x)$, а альтернативная гипотеза может быть левосторонней, правосторонней или двусторонней.

При использовании критерия Вилкоксона все вычисления проводятся не для самих наблюдаемых значений x_i, y_i , а для их рангов.



.....
Ранг — это порядковый номер наблюдения в данной выборке, если наблюдаемые значения расположены по возрастанию.



Пример

Например, выборке $x_1 = 12.6, x_2 = 11.4, x_3 = 13.1, x_4 = 11.9$ соответствует последовательность рангов $r_1 = 3, r_2 = 1, r_3 = 4, r_4 = 2$. Если в выборке встречаются несколько одинаковых значений, то им ставится в соответствие одинаковый ранг — среднее арифметическое порядковых номеров. Так, для выборки $x_1 = 10, x_2 = 9.5, x_3 = 11, x_4 = 10.5, x_5 = 9.5, x_6 = 8, x_7 = 11, x_8 = 11$ последовательность рангов имеет вид: $r_1 = 4, r_2 = 2.5, r_3 = 7, r_4 = 5, r_5 = 2.5, r_6 = 1, r_7 = 7, r_8 = 7$. Здесь ранг значения 9.5 равен $2.5 = (2 + 3)/2$, а ранг значения 11 равен $7 = (6 + 7 + 8)/3$.

Последовательность действий при проверке гипотезы однородности с помощью критерия Вилкоксона следующая:

- 1) составляем объединение выборок $x_1, x_2, \dots, x_{n_1}$ и $y_1, y_2, \dots, y_{n_2}$;
- 2) находим ранги объединенной выборки (обозначим ранги первой выборки $r_1, r_2, \dots, r_{n_1}$, а ранги второй — $s_1, s_2, \dots, s_{n_2}$);
- 3) вычисляем наблюдаемое значение статистики Вилкоксона $K = s_1 + s_2 + \dots + s_{n_2}$, равную сумме рангов второй выборки.

Если распределение второй выборки сдвинуто вправо относительно первой (альтернативная гипотеза) $H_1 : F_1(x) < F_2(x)$, то статистика K будет принимать значения, большие критического $K_{кр} = K(n_1, n_2; \alpha)$, и гипотеза H_0 отвергается в пользу альтернативы H_1 .

Если рассматривается альтернатива $H_1 : F_1(x) \neq F_2(x)$, то гипотеза H_0 отвергается, если выполняется одно из двух условий:

$$K_{\text{набл}} \geq K_{\text{кр}} = K\left(n_1, n_2; \frac{\alpha}{2}\right) \text{ или } K_{\text{набл}} = n_2(n_2 + n_1 + 1) - K\left(n_1, n_2; \frac{\alpha}{2}\right).$$

Некоторые критические точки критерия Вилкоксона для уровня значимости $\alpha = 0.05$ приведены в таблице 6.5 [7]:

Таблица 6.5 – Критические точки для критерия Вилкоксона

n_2	n_1			
	5	7	9	10
5	36	44	51	54



Пример

В биохимическом исследовании, проведенном методом меченных атомов, по результатам изучения 8 препаратов опытной группы получены следующие показания счетчика импульсов (в импульсах в минуту): 340, 343, 322, 332, 320, 313, 304. Результаты контрольной группы: 318, 321, 318, 301, 312.

Можно ли считать, что полученные значения опытной и контрольной групп различны ($\alpha = 0.05$)?

Решение:

Сформулируем основную и альтернативную гипотезы.

$H_0 : F_1(x) = F_2(x)$ — выборки однородны; различия в результатах опытной и контрольной групп можно отнести на счет случайных воздействий.

$H_1 : F_1(x) \neq F_2(x)$ — выборки извлечены из генеральных совокупностей с разными распределениями; различие между контрольной и опытной группами существенно.

Объединим выборки и расположим полученные данные в порядке возрастания: 301, 304, 312, 313, 318, 318, 320, 321, 322, 332, 340, 343 — здесь подчеркнуты элементы второй выборки (контрольной группы). Занумеровав все элементы в порядке возрастания, получим ранговую последовательность: 1, 2, 3, 4, 5.5, 5.5, 7, 8, 9, 10, 11, 12 — подчеркнуты ранги контрольной группы.

Наблюдаемое значение статистики Вилкоксона равно

$$K_{\text{набл}} = 1 + 3 + 5.5 + 5.5 + 8 = 23.$$

Критическая область является двусторонней, ее правая граница при $\alpha = 0.1$

$$K_{\text{пр}} = K\left(n_1, n_2; \frac{\alpha}{2}\right) = K(7.5; 0.05) = 44;$$

левая граница

$$K_{\text{лев}} = n_2(n_2 + n_1 + 1) - K_{\text{пр}} = 5 \cdot 14 - 44 = 26.$$

Наблюдаемое значение попадает в критическую область: $K_{\text{набл}} < K_{\text{лев}}$, поэтому основная гипотеза отвергается в пользу альтернативной.

Итак, на уровне значимости 0.1 можно утверждать, что разница между показаниями счетчика в контрольной и опытной группах существенна.

.....

При больших объемах выборки статистика Вилкоксона аппроксимируется нормальным законом распределения.



Контрольные вопросы по главе 6

1. Как называются гипотезы, в которых идет речь о видах распределения?
2. Для чего нужно формулировать альтернативную гипотезу?
3. От чего зависит размер критической области? А вид?
4. Перечислите виды параметрических гипотез.
5. Объясните суть критерия знаков для проверки гипотез.
6. Для проверки каких гипотез используется критерий Вилкоксона?

Глава 7

КОРРЕЛЯЦИОННЫЙ И РЕГРЕССИОННЫЙ АНАЛИЗ

7.1 Основные задачи

В этом разделе мы рассмотрим виды и формы связей, различаемые в статистике. Связи между различными явлениями и их признаками можно разделить на два типа: функциональные и стохастические. Если два признака X и Y связаны функциональной зависимостью, то по значению одного из них можно точно указать значение другого. Например, зная рост X в сантиметрах наугад взятого человека, можно указать его рост Y в метрах. Стохастическая связь проявляется не в каждом отдельном случае, а в среднем при большом числе наблюдений. Если X — рост наугад взятого человека в сантиметрах, то $Y = X - 100$ — вес в килограммах. Изучение такого вида связей — предмет исследования корреляционного и регрессионного анализа. При этом независимый признак X называется *фактором*, а зависимый Y — *откликом*.

Основные задачи корреляционного анализа [7]:

- 1) выяснить, есть ли связь между двумя признаками;
- 2) измерить силу этой связи;
- 3) отобрать факторы, оказывающие наиболее сильное влияние на отклик.

В задачи регрессионного анализа входят следующие:

- 1) описание формы зависимости;
- 2) нахождение коэффициентов уравнения, описывающего зависимость, и оценка их точности;
- 3) оценка качества полученной зависимости (адекватность модели).

7.2 Коэффициент корреляции Пирсона

Коэффициент корреляции Пирсона r_{XY} измеряет тесноту линейной связи между переменными X и Y

$$r_{XY} = \frac{M((X - m_X)(Y - m_Y))}{\sigma_X \sigma_Y}$$

и обладает следующими свойствами:

1. Для любых переменных X и Y его абсолютная величина не превосходит единицы: $-1 \leq r_{XY} \leq 1$.
2. Значение коэффициента корреляции равно +1 или -1 тогда и только тогда, когда между переменными X и Y существует линейная функциональная связь $Y = a + bX$.
3. Если переменные X и Y независимы, то $r_{XY} = 0$.

Если $r_{XY} = 0$, то переменные X и Y называются *некоррелированными*. Некоррелированность переменных означает отсутствие между ними линейной зависимости, но не означает отсутствия связи вообще.

Точечной оценкой коэффициента корреляции r_{XY} является выборочный коэффициент корреляции $\hat{r}_{XY}$, который можно рассчитывать по формулам:

$$\hat{r}_{XY} = \frac{\frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \cdot \bar{y}}{s_X s_Y} \quad \text{или} \quad \hat{r}_{XY} = \frac{\sum_{i=1}^n x_i y_i - n \cdot \bar{x} \cdot \bar{y}}{\sqrt{\left(\sum_{i=1}^n x_i^2 - n \bar{x}^2 \right) \left(\sum_{j=1}^n y_j^2 - n \bar{y}^2 \right)}},$$

где (x_i, y_i) , $i = 1, 2, \dots, n$ — независимая выборка объема n из двумерной генеральной совокупности; $\bar{x}$, $\bar{y}$ — средние арифметические значения (выборочные средние) переменных X и Y ; s_X , s_Y — оценки средних квадратических отклонений переменных X и Y .

Коэффициент корреляции $\hat{r}$, рассчитанный по выборке, является значением случайной величины $\hat{R}$. С увеличением числа наблюдений (свыше 500) распределение величины $\hat{R}$ стремится к нормальному. С уменьшением числа наблюдений надежность этой оценки падает. Поэтому после вычисления оценки $\hat{r}$ встает вопрос о значимости коэффициента корреляции.

Значимость коэффициента корреляции проверяется с помощью статистики, имеющей распределение Стьюдента с $(n - 2)$ степенями свободы:

$$K = \frac{\hat{r}_{XY} \sqrt{n - 2}}{\sqrt{1 - \hat{r}_{XY}^2}}.$$



Пример

Проводится изучение зависимости массы монеты Y в граммах от времени обращения X (число лет обращения). Полученные данные представлены в таблице 7.1 [7].

Таблица 7.1 – Экспериментальные данные

i	1	2	3	4	5	6	7	8	9	10
x_i (лет)	5	9	14	17	23	31	35	42	46	50
y_i (г)	2.82	2.85	2.8	2.8	2.79	2.78	2.77	2.79	2.75	2.72

По результатам десяти наблюдений выяснить, значима ли корреляция между массой монеты и временем ее обращения.

Решение:

Объем выборки равен 10. Для вычисления оценки коэффициента корреляции необходимы выборочные значения: $\bar{x} = \hat{m}_X$, $\bar{y} = \hat{m}_Y$ — оценки средних и $s_X^2 = \hat{\sigma}_X^2$, $s_Y^2 = \hat{\sigma}_Y^2$ — оценки дисперсии.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = 27.2; \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = 2.787;$$

$$s_X^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = 254.178; \quad s_Y^2 = 0.001.$$

Подставив полученные значения оценок в формулу для вычисления выборочного коэффициента корреляции, получим $r_{XY} = -0.792$. По значению коэффициента можно предположить довольно сильную линейную отрицательную зависимость между массой монеты и временем ее обращения, то есть чем старше монета, тем меньше ее масса. Поскольку выборка малого объема, необходимо проверить значимость выборочного коэффициента корреляции.

Основная гипотеза H_0 состоит в том, что коэффициент корреляции r_{XY} незначим $H_0 : r_{XY} = 0$, то есть между переменными X и Y нет линейной зависимости; альтернативная гипотеза $H_1 : r_{XY} < 0$ — коэффициент корреляции значим, переменные связаны сильной линейной отрицательной зависимостью.

Наблюдаемое значение статистики K равно:

$$K_{\text{набл}} = \frac{\hat{r}_{XY} \sqrt{n-2}}{\sqrt{1 - \hat{r}_{XY}^2}} = \frac{-0.792 \cdot \sqrt{10-2}}{\sqrt{1 - (-0.792)^2}} = -\frac{0.792 \cdot \sqrt{8}}{\sqrt{1 - 0.627}} = -3.668.$$

Зададим уровень значимости $\alpha = 0.01$ и определим границу критической области по таблице распределения Стьюдента. По виду альтернативной гипотезы заключаем, что критическая область является левосторонней, число степеней свободы равно 8, значит, $K_{\text{кр}} = -2.9$.

Наблюдаемое значение $K_{\text{набл}} = -3.668$ попадает в критическую область, поэтому основную гипотезу следует отвергнуть в пользу альтернативной: связь между переменными X и Y значима.

Вывод: Данные наблюдений на уровне значимости $\alpha = 0.01$ говорят о том, что масса монеты в среднем линейно убывает при увеличении возраста монеты.

.....

7.3 Ранговая корреляция

При анализе некоторых данных, например различных психических и физических способностей человека, используются измерения, в которых важно не значение исследуемого признака, а взаимный порядок произведенных наблюдений. Например, признак X — скорость реакции человека на световой сигнал, а признак Y — скорость реакции на звуковой сигнал. Проведя n независимых наблюдений, мы получим выборку — множество пар (x_i, y_i) . Нас интересуют не столько значения чисел x_i и y_i , сколько порядок их следования. Назовем *рангом* i -го наблюдения его порядковый номер в вариационном ряду. Так, для выборки из пяти наблюдений

2.51 2.32 2.56 3.01 2.69

соответствующая последовательность рангов будет иметь вид:

2 1 3 5 4.

Поскольку величина признаков X и Y нас не интересует, то от пар значений (x_i, y_i) можно перейти к парам их рангов (r_i, s_i) . Чем больше связаны признаки X и Y , тем в большей степени последовательность рангов $r_1, r_2, \dots, r_n$ предопределяет последовательность $s_1, s_2, \dots, s_n$.

Близость двух рядов рангов отражает величина $S = \sum_{i=1}^n (r_i - s_i)^2$.

Она принимает наименьшее возможное значение $S = 0$ тогда и только тогда, когда последовательности рангов полностью совпадают. Наибольшее возможное значение $S = \frac{1}{3}(n^3 - n)$ величина S принимает, когда эти последовательности полностью противоположны. Поэтому в качестве меры монотонной зависимости признаков X и Y рассматривают *коэффициент ранговой корреляции Спирмена*:

$$r_S = 1 - \frac{6S}{n^3 - n}.$$

Коэффициент корреляции Спирмена может принимать значения между -1 и 1 , при этом крайние значения (± 1) он принимает в случае полной предсказуемости одной ранговой последовательности по другой.

Проверка значимости коэффициента корреляции Спирмена проводится с помощью той же статистики, что и для коэффициента корреляции Пирсона (п. 7.2).



Пример

По данным примера из п. 7.2 (изучение зависимости массы монеты от времени ее обращения) рассчитаем коэффициент корреляции Спирмена. Построим ранговую таблицу. При ее построении учитываем, что одинаковым значениям признака Y будет соответствовать одинаковый (средний) ранг (таблица 7.2).

Таблица 7.2 – Ранговая таблица

i	1	2	3	4	5	6	7	8	9	10
r_i	1	2	3	4	5	6	7	8	9	10
s_i	9	10	7.5	7.5	5.5	4	3	5.5	2	1
$r_i - s_i$	-8	-8	-4.5	-3.5	-0.5	2	4	2.5	7	9

Величина S равна

$$S = \sum_{i=1}^{10} (r_i - s_i)^2 = (-8)^2 + (-8)^2 + (-4.5)^2 + (-3.5)^2 + (-0.5)^2 + 2^2 + 4^2 + 2.5^2 + 7^2 + 9^2 = 317.$$

Коэффициент корреляции Спирмена соответственно равен

$$r_S = 1 - \frac{6 \cdot 317}{10^3 - 10} = -0.9.$$

Значение коэффициента корреляции Спирмена близко к -1 , поэтому между признаками X и Y есть сильная отрицательная корреляционная связь. Этот результат согласуется с результатом применения коэффициента корреляции Пирсона.

7.4 Регрессионные модели

Предположим, что нам необходимо описать в виде некоторой функции взаимосвязь двух переменных X и Y (X — фактор, независимая переменная; Y — отклик, зависимая переменная): $Y = f(X)$. По результатам наблюдений мы можем оценить эту зависимость приближенно (в силу воздействия неучтенных факторов, случайных причин, ошибок измерения): $y = f(x) + \varepsilon$, где ε — случайная переменная, называемая *возмущением*. Предполагается, что среднее значение возмущения равно нулю: $M(\varepsilon) = 0$. При этом для каждого значения $X = x$ мы имеем случайную переменную Y со средним значением (математическим ожиданием) $f(x)$. Функция $f(x)$ называется *функцией регрессии* случайной переменной X на Y , а график этой функции — *линией регрессии*. Уравнение регрессии позволяет определить, каким в среднем будет значение отклика Y при том или ином значении фактора X .

Форма регрессионной зависимости (вид функции $f(x)$) определяется по *диаграмме рассеяния*, которую получают, нанося экспериментальные точки (x_1, y_1) , (x_2, y_2) , ..., (x_n, y_n) на координатную плоскость (рис. 7.1).




Рис. 7.1 – Диаграмма рассеяния при линейной (а) и квадратичной (б) зависимости переменных X и Y

По диаграмме рассеяния подбирают некоторую гладкую кривую таким образом, чтобы она располагалась как можно «ближе» к экспериментальным точкам. Часто в качестве такой кривой выбирают прямую линию (рис. 7.1, а) $y = b_0 + b_1x$ или многочлен (рис. 7.1, б) $y = b_0 + b_1x + b_2x^2$.

Пусть по диаграмме рассеяния выбран вид зависимости $y = f(x; b_0, b_1, \dots, b_k)$. Неизвестные коэффициенты $b_0, b_1, \dots, b_k$ этой модели подбираются по *методу наименьших квадратов*. Согласно этому методу сумма квадратов отклонений экспериментальных значений y_i от модельных $f(x_i; b_0, b_1, \dots, b_k)$ должна быть минимальной:

$$Q(b_0, b_1, \dots, b_k) = \sum_{i=1}^n (y_i - f(x_i; b_0, b_1, \dots, b_k))^2 \rightarrow \min.$$

7.5 Уравнение линейной регрессии

Пусть по диаграмме рассеяния на основе выборочных данных $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ определена форма зависимости между X и Y в виде прямой линии: $y = b_0 + b_1x$. Оценки коэффициентов b_0 и b_1 , найденные методом наименьших квадратов, имеют вид:

$$\begin{aligned}\hat{b}_1 &= \hat{r}_{XY} \cdot \frac{s_Y}{s_X}; \\ \hat{b}_0 &= \bar{y} - \hat{b}_1 \cdot \bar{x},\end{aligned}$$

где $\bar{x}, \bar{y}$ — средние значения переменных X и Y , рассчитанные по выборке; s_X, s_Y — несмещенные оценки дисперсий; $\hat{r}_{XY}$ — оценка коэффициента корреляции Пирсона.



Пример

Предположим, что нас интересует выручка от продажи некоторого напитка в магазинах города в течение дня. При исследовании 20 магазинов получены следующие данные (табл. 7.3) [5]:

Таблица 7.3 – Экспериментальные данные

№ п.п.	Число посетителей	Выручка (у.е.)	№ п.п.	Число посетителей	Выручка (у.е.)
1	907	11.20	11	679	7.63
2	926	11.05	12	872	9.43
3	506	6.84	13	924	9.46
4	741	9.21	14	607	7.64
5	789	9.42	15	452	6.92
6	889	10.08	16	729	8.95
7	874	9.45	17	794	9.33
8	510	6.73	18	844	10.23
9	529	7.24	19	1010	11.77
10	420	6.12	20	621	7.41

Построить регрессионную модель зависимости выручки магазина от числа посетителей.

Решение:

Независимой переменной (фактором) в данной задаче является X — число посетителей магазина; зависимой переменной (откликом) Y — выручка от продажи напитка. Построим диаграмму рассеяния по имеющимся данным (рис. 7.2).




Рис. 7.2 – Диаграмма рассеяния для данных примера

По виду диаграммы есть основания предполагать линейную зависимость выручки от числа посетителей магазина, то есть уравнение регрессии будет вида $y = b_0 + b_1x$.

Для расчета коэффициентов регрессии найдем промежуточные данные.

Средние значения:

$$\bar{x} = \frac{1}{20} \sum_{i=1}^{20} x_i = 731.15; \quad \bar{y} = \frac{1}{20} \sum_{i=1}^{20} y_i = 8.806.$$

Несмещенные оценки дисперсий:

$$s_X^2 = \frac{1}{20-1} \sum_{i=1}^{20} (x_i - \bar{x})^2 = 32348; \quad s_Y^2 = \frac{1}{20-1} \sum_{i=1}^{20} (y_i - \bar{y})^2 = 2.703.$$

Оценка коэффициента корреляции Пирсона:

$$r_{XY} = \frac{\frac{1}{20} \sum_{i=1}^{20} x_i y_i - \bar{x} \bar{y}}{s_X s_Y} = 0.955.$$

Близость коэффициента корреляции к единице свидетельствует о тесной положительной линейной связи между выручкой магазина и числом посетителей.

Рассчитаем теперь оценки коэффициентов регрессии:

$$\hat{b}_1 = 0.955 \cdot \frac{\sqrt{2.703}}{\sqrt{32348}} = 0.009; \quad \hat{b}_0 = 8.806 - 0.009 \cdot 731.15 = 2.123.$$

Таким образом, уравнение регрессии Y на X имеет вид:

$$y = 2.123 + 0.009x.$$

Коэффициент b_1 характеризует наклон линии регрессии, и значение $\hat{b}_1 = 0.009$ показывает, что при увеличении X на единицу ожидаемое значение Y возрастет на 0.009. Это означает, что каждый новый посетитель магазина увеличивает выручку на 0.009 у.е.; или можно сказать, что при привлечении в магазин 100 дополнительных покупателей даст ожидаемый прирост выручки на 9 у.е. Отсюда, b_1 может интерпретироваться как прирост ежедневной выручки, который меняется в зависимости от числа посетителей магазина.

Свободный член b_0 в уравнении регрессии — это значение Y при $X = 0$. Поскольку маловероятно число посетителей магазина, равное нулю, то можно рассматривать b_0 как меру влияния на величину ежедневной выручки других факторов, не учтенных в регрессионной модели, — погодные условия, будние и праздничные дни и т. п.

.....

7.6 Линейная регрессия и прогноз

Регрессионная модель может быть использована в задачах прогнозирования. Например, мы хотим использовать модель, построенную в п. 7.5, для предсказания средней выручки магазина, который посетят 600 покупателей. Подставив $x = 600$ в уравнение регрессии, получим предполагаемое среднее значение Y : $\bar{y}(600) = 2.123 + 0.009 \cdot 600 = 7.523$ — прогнозируемая средняя дневная выручка магазина с 600 покупателями равна 7.523 у.е. Насколько можно доверять такой точечной оценке? Для ответа на этот вопрос нужно построить для нее доверительный интервал.

Стандартная ошибка оценки для уравнения регрессии рассчитывается по формуле:

$$s_e = \sqrt{\frac{1}{n-2} \sum_{i=1}^n (y_i - (b_0 + b_1 x_i))^2}.$$

И характеризует отклонение фактических данных от модельных.

Доверительный интервал для неизвестного генерального среднего Y при фиксированном значении x имеет вид:

$$(\bar{y}(x) - t_{кр} \cdot s_{\varepsilon} \sqrt{h(x)}; \bar{y}(x) + t_{кр} \cdot s_{\varepsilon} \sqrt{h(x)}),$$

где $\bar{y}(x) = b_0 + b_1 x$ — среднее значение Y , рассчитанное по уравнению регрессии; $t_{кр}$ — двусторонняя критическая точка распределения Стьюдента с числом степеней свободы $k = n - 2$ и уровнем значимости α , $h(x) = \frac{1}{n} + \frac{(x - \bar{x})^2}{n \cdot s_x^2}$.

Очевидно, что ширина доверительного интервала зависит от заданного значения x : чем ближе x к $\bar{x}$, тем уже доверительный интервал.

Ширина интервала зависит также от объема выборки n и уровня доверительной вероятности $\gamma = 1 - \alpha$.



Пример

Рассчитаем 95%-ый доверительный интервал для среднего значения дневной выручки в магазинах с числом посетителей, равным 600.

По уравнению регрессии была найдена оценка $\bar{y}(600) = 7.523$.

Критическую точку $t_{кр}$ находим по таблице распределения Стьюдента (Приложение В) с числом степеней свободы $k = n - 2 = 20 - 2 = 18$ и уровнем значимости $\alpha = 1 - \gamma = 1 - 0.95 = 0.05$ (двусторонняя область). $t_{кр} = 2.1$.

По формуле для расчета стандартной ошибки для уравнения регрессии получаем $s_{\varepsilon} = 0.501$.

При $x = 600$, $\bar{x} = 731.15$ и $s_x^2 = 32348$ вычисляем $h(x)$:

$$h(600) = \frac{1}{20} + \frac{(600 - 731.15)^2}{20 \cdot 32348} = 0.077.$$

Теперь определяем границы доверительного интервала:

$$\bar{y}(600) - t_{кр} \cdot s_{\varepsilon} \cdot \sqrt{h(600)} = 7.523 - 0.291 = 7.232;$$

$$\bar{y}(600) + t_{кр} \cdot s_{\varepsilon} \cdot \sqrt{h(600)} = 7.523 + 0.291 = 7.814.$$

Следовательно, 95%-ый доверительный интервал для уравнения регрессии при $X = 600$ имеет вид $(7.232; 7.814)$ — с вероятностью 0.95 мы можем утверждать, что средняя дневная выручка всех магазинов с 600 посетителями находится между 7.232 и 7.814 у.е. [7].



Контрольные вопросы по главе 7

1. Как Вы понимаете фразу: «Между данными переменными не существует корреляционной зависимости»?
2. Что означает близость коэффициента корреляции Пирсона к единице?
3. Чем ранговая корреляция отличается от классической?
4. Почему нужно проверять значимость коэффициента корреляции?
5. Для чего служит регрессионная модель?
6. Каким образом по регрессионной модели можно построить прогноз?

ЗАКЛЮЧЕНИЕ

В первых трех разделах настоящего пособия рассмотрены теоретические и практические вопросы теории вероятностей и начала математической статистики (описательная статистика). В процессе обучения мы получили навыки решения вероятностных задач, действий со случайными величинами, а также рассмотрели первичные приемы обработки статистических данных.

В последующих разделах приведены уже более серьезные способы изучения и анализа статистических данных, методы построения доверительных интервалов, а также проверки гипотез. Мы научились по имеющимся данным не только делать определенные заключения для принятия решений, но и строить прогноз.

Совершенно очевидно, что при решении реальных практических задач в условиях развития современной вычислительной техники для обработки эмпирических данных широко используются как общеизвестные программы (MS Excel, MathCad и т. п.), так и специализированные пакеты для работы со статистическими данными (STATISTICA, StatSoft и др.). Применение таких программ значительно упрощает и ускоряет процесс обработки и анализа экспериментальных данных, что, в свою очередь, облегчает принятие решения.

Тем не менее, несмотря на широко используемую автоматизацию процессов изучения статистических данных, весьма полезно понимать смысл и значение тех или иных рассчитываемых автоматически параметров. В овладении знаниями и навыками для получения результатов обработки данных и правильной интерпретации этих результатов и состоит цель изучения дисциплины «Теория вероятностей и математическая статистика».

ЛИТЕРАТУРА

- [1] Вентцель Е. С. Теория вероятностей : учебник для вузов / Е. С. Вентцель. — 8-е изд., стер. — М : Высшая школа, 2002. — 576 с.
- [2] Вентцель Е. С. Задачи и упражнения по теории вероятностей : учеб. пособие для вузов / Е. С. Вентцель, Л. С. Овчаров. — 3-е изд., стер. — М. : Высшая школа, 2000. — 366 с.
- [3] Гмурман В. Е. Теория вероятностей и математическая статистика : учеб. пособие для вузов / В. Е. Гмурман. — 8-е изд., стер. — М. : Высшая школа, 2002. — 480 с.
- [4] Гмурман В. Е. Руководство к решению задач по теории вероятностей и математической статистике : учеб. пособие для вузов / В. Е. Гмурман. — 5-е изд., стер., — М. : Высшая школа, 2000. — 400 с.
- [5] Горелова Г. В. Теория вероятностей и математическая статистика в примерах и задачах с применением Excel : учеб. пособие для вузов / Г. В. Горелова, И. А. Кацко. — 4-е изд. — Ростов н/Д : Феникс, 2006. — 478 с.
- [6] Кремер Н. Ш. Теория вероятностей и математическая статистика : учебник для вузов / Н. Ш. Кремер. — 2-е изд., перераб. и доп. — М. : ЮНИТИ-ДАНА, 2007. — 573 с.
- [7] Смылова З. А. Математика IV. Основы теории вероятностей и математическая статистика : учеб. пособие / З. А. Смылова. — Министерство образования Российской Федерации ; Томский государственный университет систем управления и радиоэлектроники ; Кафедра автоматизации обработки информации. — Томск : ТМЦДО, 2000. — 130 с.

ТАБЛИЦА ЗНАЧЕНИЙ ФУНКЦИИ ЛАПЛАСА

x	$F(x)$	x	$F(x)$	x	$F(x)$	x	$F(x)$
0.00	0.0000	0.32	0.1255	0.64	0.2389	0.96	0.3315
0.01	0.0040	0.33	0.1293	0.65	0.2422	0.97	0.3340
0.02	0.0080	0.34	0.1331	0.66	0.2454	0.98	0.3365
0.03	0.0120	0.35	0.1368	0.67	0.2486	0.99	0.3389
0.04	0.0160	0.36	0.1406	0.68	0.2517	1.00	0.3413
0.05	0.0199	0.37	0.1443	0.69	0.2549	1.01	0.3438
0.06	0.0239	0.38	0.1480	0.70	0.2580	1.02	0.3461
0.07	0.0279	0.39	0.1517	0.71	0.2611	1.03	0.3485
0.08	0.0319	0.40	0.1554	0.72	0.2642	1.04	0.3508
0.09	0.0359	0.41	0.1591	0.73	0.2673	1.05	0.3531
0.10	0.0398	0.42	0.1628	0.74	0.2703	1.06	0.3554
0.11	0.0438	0.43	0.1664	0.75	0.2734	1.07	0.3577
0.12	0.0478	0.44	0.1700	0.76	0.2764	1.08	0.3599
0.13	0.0517	0.45	0.1736	0.77	0.2794	1.09	0.3621
0.14	0.0557	0.46	0.1772	0.78	0.2823	1.10	0.3643
0.15	0.0596	0.47	0.1808	0.79	0.2852	1.11	0.3665
0.16	0.0636	0.48	0.1844	0.80	0.2881	1.12	0.3686
0.17	0.0675	0.49	0.1879	0.81	0.2910	1.13	0.3708
0.18	0.0714	0.50	0.1915	0.82	0.2939	1.14	0.3729
0.19	0.0753	0.51	0.1950	0.83	0.2967	1.15	0.3749
0.20	0.0793	0.52	0.1985	0.84	0.2995	1.16	0.3770
0.21	0.0832	0.53	0.2019	0.85	0.3023	1.17	0.3790
0.22	0.0871	0.54	0.2054	0.86	0.3051	1.18	0.3810
0.23	0.0910	0.55	0.2088	0.87	0.3078	1.19	0.3830
0.24	0.0948	0.56	0.2123	0.88	0.3106	1.20	0.3849

продолжение на следующей странице

x	$F(x)$	x	$F(x)$	x	$F(x)$	x	$F(x)$
0.25	0.0987	0.57	0.2157	0.89	0.3133	1.21	0.3869
0.26	0.1026	0.58	0.2190	0.90	0.3159	1.22	0.3883
0.27	0.1064	0.59	0.2224	0.91	0.3186	1.23	0.3907
0.28	0.1103	0.60	0.2257	0.92	0.3212	1.24	0.3925
0.29	0.1141	0.61	0.2291	0.93	0.3238	1.25	0.3944
0.30	0.1179	0.62	0.2324	0.94	0.3264		
0.31	0.1217	0.63	0.2357	0.95	0.3289		
1.26	0.3962	1.59	0.4441	1.92	0.4726	2.50	0.4938
1.27	0.3980	1.60	0.4452	1.93	0.4732	2.52	0.4941
1.28	0.3997	1.61	0.4463	1.94	0.4738	2.54	0.4945
1.29	0.4015	1.62	0.4474	1.95	0.4744	2.56	0.4948
1.30	0.4032	1.63	0.4484	1.96	0.4750	2.58	0.4951
1.31	0.4049	1.64	0.4495	1.97	0.4756	2.60	0.4953
1.32	0.4066	1.65	0.4505	1.98	0.4761	2.62	0.4956
1.33	0.4082	1.66	0.4515	1.99	0.4767	2.64	0.4959
1.34	0.4099	1.67	0.4525	2.00	0.4772	2.66	0.4961
1.35	0.4115	1.68	0.4535	2.02	0.4783	2.68	0.4963
1.36	0.4131	1.69	0.4545	2.04	0.4793	2.70	0.4965
1.37	0.4147	1.70	0.4554	2.06	0.4803	2.72	0.4967
1.38	0.4162	1.71	0.4564	2.08	0.4812	2.74	0.4969
1.39	0.4177	1.72	0.4573	2.10	0.4821	2.76	0.4971
1.40	0.4192	1.73	0.4582	2.12	0.4830	2.78	0.4973
1.41	0.4207	1.74	0.4591	2.14	0.4838	2.80	0.4974
1.42	0.4222	1.75	0.4599	2.16	0.4846	2.82	0.4976
1.43	0.4236	1.76	0.4608	2.18	0.4854	2.84	0.4977
1.44	0.4251	1.77	0.4616	2.20	0.4861	2.86	0.4979
1.45	0.4265	1.78	0.4625	2.22	0.4868	2.88	0.4980
1.46	0.4279	1.79	0.4633	2.24	0.4875	2.90	0.4981
1.47	0.4292	1.80	0.4641	2.26	0.4881	2.92	0.4982
1.48	0.4306	1.81	0.4649	2.28	0.4887	2.94	0.4984
1.49	0.4319	1.82	0.4656	2.30	0.4893	2.96	0.4985
1.50	0.4332	1.83	0.4664	2.32	0.4898	2.98	0.4986
1.51	0.4345	1.84	0.4671	2.34	0.4904	3.00	0.49865
1.52	0.4357	1.85	0.4678	2.36	0.4909	3.20	0.49931
1.53	0.4370	1.86	0.4686	2.38	0.4913	3.40	0.49966
1.54	0.4382	1.87	0.4693	2.40	0.4918	3.60	0.49984
1.55	0.4394	1.88	0.4699	2.42	0.4922	3.80	0.49992
1.56	0.4406	1.89	0.4706	2.44	0.4927	4.00	0.49996
1.57	0.4418	1.90	0.4713	2.46	0.4931	4.50	0.49999
1.58	0.4429	1.91	0.4719	2.48	0.4934	5.00	0.49999

КРИТИЧЕСКИЕ ТОЧКИ РАСПРЕДЕЛЕНИЯ χ^2

Число степеней свободы k	Уровень значимости α					
	0.01	0.025	0.05	0.95	0.975	0.99
1	6.6	5.0	3.8	0.0039	0.00098	0.00016
2	9.2	7.4	6.0	0.103	0.051	0.020
3	11.3	9.4	7.8	0.352	0.216	0.115
4	13.3	11.1	9.5	0.711	0.484	0.297
5	15.1	12.8	11.1	1.15	0.831	0.554
6	16.8	14.4	12.6	1.64	1.24	0.872
7	18.5	16.0	14.1	2.17	1.69	1.24
8	20.1	17.5	15.5	2.73	2.18	1.65
9	21.7	19.0	16.9	3.33	2.70	2.09
10	23.2	20.5	18.3	3.94	3.25	2.56
11	24.7	21.9	19.7	4.57	3.82	3.05
12	26.2	23.3	21.0	5.23	4.40	3.57
13	27.7	24.7	22.4	5.89	5.01	4.11
14	29.1	26.1	23.7	6.57	5.63	4.66
15	30.6	27.5	25.0	7.26	6.26	5.23
16	32.0	28.8	26.3	7.96	6.91	5.81
17	33.4	30.2	27.6	8.67	7.56	6.41
18	34.8	31.5	28.9	9.39	8.23	7.01
19	36.2	32.9	30.1	10.1	8.91	7.63
20	37.6	34.2	31.4	10.9	9.59	8.26
21	38.9	35.5	32.7	11.6	10.3	8.90
22	40.3	36.8	33.9	12.3	11.0	9.54
продолжение на следующей странице						

Число степеней свободы k	Уровень значимости α					
	0.01	0.025	0.05	0.95	0.975	0.99
23	41.6	38.1	35.2	13.1	11.7	10.2
24	43.0	39.4	36.4	13.8	12.4	10.9
25	44.3	40.6	37.7	14.6	13.1	11.5
26	45.6	41.9	38.9	15.4	13.8	12.2
27	47.0	43.2	40.1	16.2	14.6	12.9
28	48.3	44.5	41.3	16.9	15.3	13.6
29	49.6	45.7	42.6	17.7	16.0	14.3
30	50.9	47.0	43.8	18.5	16.8	15.0

КРИТИЧЕСКИЕ ТОЧКИ РАСПРЕДЕЛЕНИЯ СТЬЮДЕНТА

Число степеней свободы k	Уровень значимости α (двусторонняя критическая область)					
	0.10	0.05	0.02	0.01	0.002	0.001
1	6.31	12.7	31.82	63.7	318.3	637.0
2	2.92	4.30	6.97	9.92	22.33	31.6
3	2.35	3.18	4.54	5.84	10.22	12.9
4	2.13	2.78	3.75	4.60	7.17	8.61
5	2.01	2.57	3.37	4.03	5.89	6.86
6	1.94	2.45	3.14	3.71	5.21	5.96
7	1.89	2.36	3.00	3.50	4.79	5.40
8	1.86	2.31	2.90	3.36	4.50	5.04
9	1.83	2.26	2.82	3.25	4.30	4.78
10	1.81	2.23	2.76	3.17	4.14	4.59
11	1.80	2.20	2.72	3.11	4.03	4.44
12	1.78	2.18	2.68	3.05	3.93	4.32
13	1.77	2.16	2.65	3.01	3.85	4.22
14	1.76	2.14	2.62	2.98	3.79	4.14
15	1.75	2.13	2.60	2.95	3.73	4.07
16	1.75	2.12	2.58	2.92	3.69	4.01
17	1.74	2.11	2.57	2.90	3.65	3.95
18	1.73	2.10	2.55	2.88	3.61	3.92
19	1.73	2.09	2.54	2.86	3.58	3.88
20	1.73	2.09	2.53	2.85	3.55	3.85
21	1.72	2.08	2.52	2.83	3.53	3.82
продолжение на следующей странице						

Число степеней свободы k	Уровень значимости α (двусторонняя критическая область)					
	0.10	0.05	0.02	0.01	0.002	0.001
22	1.72	2.07	2.51	2.82	3.51	3.79
23	1.71	2.07	2.50	2.81	3.59	3.77
24	1.71	2.06	2.49	2.80	3.47	3.74
25	1.71	2.06	2.49	2.79	3.45	3.72
26	1.71	2.06	2.48	2.78	3.44	3.71
27	1.71	2.05	2.47	2.77	3.42	3.69
28	1.70	2.05	2.46	2.76	3.40	3.66
29	1.70	2.05	2.46	2.76	3.40	3.66
30	1.70	2.04	2.46	2.75	3.39	3.65
40	1.68	2.02	2.42	2.70	3.31	3.55
60	1.67	2.00	2.39	2.66	3.23	3.46
120	1.66	1.98	2.36	2.62	3.17	3.37
∞	1.64	1.96	2.33	2.58	3.09	3.29
	0.05	0.025	0.01	0.005	0.001	0.0005
	Уровень значимости α (односторонняя критическая область)					

Приложение Г

КРИТИЧЕСКИЕ ТОЧКИ РАСПРЕДЕЛЕНИЯ ФИШЕРА

k_1 — число степеней свободы большей дисперсии, k_2 — число степеней свободы меньшей дисперсии.

Уровень значимости $\alpha = 0.01$

$k_2 \backslash k_1$	1	2	3	4	5	6	7	8	9	10	11	12
1	4052	4999	5403	5625	5764	5889	5928	5981	6022	6056	6082	6106
2	98.49	99.01	90.17	99.25	99.33	99.30	99.34	99.36	99.36	99.40	99.41	99.42
3	34.12	30.81	29.46	28.71	28.24	27.91	27.67	27.49	27.34	27.23	27.13	27.05
4	21.20	18.00	16.69	15.98	15.52	15.21	14.98	14.80	14.66	14.54	14.45	14.37
5	16.26	13.27	12.06	11.39	10.97	10.67	10.45	10.27	10.15	10.05	9.96	9.89
6	13.74	10.92	9.78	9.15	8.75	8.47	8.26	8.10	7.98	7.87	7.79	7.72
7	12.25	9.55	8.45	7.85	7.46	7.19	7.00	6.84	6.71	6.62	6.54	6.47
8	11.26	8.65	7.59	7.01	6.63	6.37	6.19	6.03	5.91	5.82	5.74	5.67
9	10.56	8.02	6.99	6.42	6.06	5.80	5.62	5.47	5.35	5.26	5.18	5.11
10	10.04	7.56	6.55	5.99	5.64	5.39	5.21	5.06	4.95	4.85	4.78	4.71
11	9.86	7.20	6.22	5.67	5.32	5.07	4.88	4.74	4.63	4.54	4.46	4.40
12	9.33	6.93	5.95	5.41	5.06	4.82	4.65	4.50	4.39	4.30	4.22	4.16
13	9.07	6.70	5.74	5.20	4.86	4.62	4.44	4.30	4.19	4.10	4.02	3.96
14	8.86	6.51	5.56	5.03	4.69	4.46	4.28	4.14	4.03	3.94	3.86	3.80
15	8.68	6.36	5.42	4.89	4.56	4.32	4.14	4.00	3.89	3.80	3.73	3.67
16	8.53	6.23	5.29	4.77	4.44	4.20	4.03	3.89	3.78	3.69	3.61	3.55
17	8.40	6.11	5.18	4.67	4.34	4.10	3.93	3.79	3.68	3.59	3.52	3.45

Уровень значимости $\alpha = 0.05$

$k_2 \backslash k_1$	1	2	3	4	5	6	7	8	9	10	11	12
1	161	200	216	225	230	234	237	239	241	242	243	244
2	18.5	19.00	19.16	19.25	19.30	19.33	19.36	19.37	19.38	19.39	19.40	19.41
3	10.13	9.55	9.28	9.12	9.01	8.94	8.88	8.84	8.81	8.78	8.76	8.74
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.93	5.91
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.78	4.74	4.70	4.68
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.03	4.00
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.63	3.60	3.57
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.34	3.31	3.28
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.13	3.10	3.07
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.97	2.94	2.91
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.86	2.82	2.79
12	4.75	3.88	3.49	3.26	3.11	3.00	2.92	2.85	2.80	2.76	2.72	2.69
13	4.67	3.80	3.41	3.18	3.02	2.92	2.84	2.77	2.72	2.67	2.63	2.60
14	4.60	3.74	3.34	3.11	2.96	2.85	2.77	2.70	2.65	2.60	2.56	2.53
15	4.54	3.68	3.29	3.06	2.90	2.79	2.70	2.64	2.59	2.55	2.51	2.48
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.45	2.42
17	4.45	3.59	3.20	2.96	2.81	2.70	2.62	2.55	2.50	2.45	2.41	2.38

ГЛОССАРИЙ

Биномиальный закон распределения — закон распределения случайной величины X — числа появлений «успеха» в схеме из n испытаний Бернулли.

Вероятность события A — отношение числа благоприятствующих этому событию исходов к общему числу всех возможных исходов эксперимента.

Выборка — совокупность случайно отобранных объектов.

Дискретная случайная величина — случайная величина, принимающая только отделенные друг от друга значения, которые можно заранее перечислить.

Дисперсия дискретной случайной величины — математическое ожидание квадрата отклонения случайной величины от ее математического ожидания $M(X) = a$.

Доверительная вероятность — заранее выбранная вероятность; событие, происходящее с такой вероятностью, считается практически достоверным.

Доверительный интервал — интервал вида $(\hat{\theta} - \varepsilon; \hat{\theta} + \varepsilon)$, который с заранее выбранной вероятностью «накроет» истинное значение параметра θ .

Зависимые события A и B — это такие события, что вероятность каждого из них зависит от того, произошло или нет другое событие.

Закон распределения случайной величины — соотношение, устанавливающее связь между значениями дискретной величины и их вероятностями.

Коэффициент Старджеса — оптимальное количество интервалов группировки непрерывных данных.

Критерии согласия — критерии для проверки гипотез о виде распределения.

Критическая область — область принятия альтернативной гипотезы.

Математическое ожидание дискретной случайной величины — это сумма произведений всех ее возможных значений на их вероятности.

Медиана выборки — это число $x_{0.5}$ такое, что ровно половина вариант меньше этого числа, а половина — больше.

Мода — варианта с наибольшей частотой.

Некоррелированность — отсутствие между переменными линейной связи. Любая другая связь может присутствовать.

Непрерывная случайная величина X — случайная величина, функция распределения которой непрерывна и имеет производную.

Несмещенность оценки — математическое ожидание точечной оценки должно быть равно истинному значению параметра.

Несовместные события — события, которые в результате одного испытания не могут произойти одновременно.

Нормальное распределение. Случайная величина X имеет нормальное распределение с параметрами a и σ , если ее плотность распределения задается формулой:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-a)^2}{2\sigma^2}}, \quad -\infty < x < +\infty.$$

Область допустимых значений — область принятия основной гипотезы.

Оценка параметра — приближенное значение параметра генеральной совокупности, рассчитанное по выборке.

Плотность распределения непрерывной случайной величины — это производная от ее функции распределения.

Произведение событий A и B — событие AB , которому соответствует множество элементарных исходов, благоприятствующих A и B одновременно.

Произведение случайных величин X и Y — это новая случайная величина, значения которой получаются перемножением всех значений величины X и всех значений величины Y , а соответствующие вероятности перемножаются.

Пространство элементарных исходов — множество всех возможных взаимоисключающих исходов эксперимента.

Противоположное событию A — событие $\bar{A}$, состоящее из элементарных исходов, неблагоприятствующих событию A .

Равновозможные события — события, которые в результате проведения эксперимента имеют одинаковые шансы на успех.

Равномерно распределенная случайная величина имеет плотность распределения, постоянную на заданном промежутке.

Ранг — это порядковый номер наблюдения в данной выборке, если наблюдаемые значения расположить по возрастанию.

Случайная величина — это величина, которая в результате опыта может принять то или иное значение, причем неизвестно заранее, какое именно.

Событие — подмножество пространства элементарных исходов.

Состоятельность оценки — свойство оценки при увеличении числа наблюдений приближаться к истинному параметру.

Среднее арифметическое выборки рассчитывается по формуле

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Среднее квадратическое отклонение — это квадратный корень из дисперсии.

Стандартное нормальное распределение — нормальное распределение с параметрами $\mu = 0$, $\sigma = 1$.

Статистическая гипотеза — всякое высказывание о генеральной совокупности, проверяемое по выборке. При этом гипотеза, которая проверяется, называется основной, а противопоставляемая ей — альтернативной.

Статистический критерий — однозначно определенное правило, устанавливающее условия, при которых проверяемую гипотезу H_0 следует либо отвергнуть, либо принять.

Сумма событий A и B — событие $A + B$, которому благоприятствуют исходы, благоприятствующие хотя бы одному из событий A или B .

Сумма случайных величин X и Y — это новая случайная величина Z , значения которой получаются в результате сложения всех значений величины X со всеми значениями величины Y , а соответствующие вероятности перемножаются.

Функция распределения случайной величины X называется функция $F(x)$, выражающая вероятность того, что X примет значение, меньшее заданного числа x :

$$F(x) = P(X < x).$$

Функция регрессии — соотношение, описывающее зависимость отклика от фактора.

Частота варианты — количество ее вхождений в выборку.

Элементарный исход — простейший неразложимый результат случайного эксперимента.

Эффективность оценки — такая оценка среди других оценок одного и того же параметра имеет наименьшую дисперсию.

Учебное издание

Синчинова Людмила Иосифовна

ТЕОРИЯ ВЕРОЯТНОСТЕЙ
И МАТЕМАТИЧЕСКАЯ СТАТИСТИКА

Учебное пособие

Корректор Осипова Е. А.

Компьютерная верстка Хомич С. Л.

Подписано в печать 18.01.16 Формат 60х84/8.

Усл. печ. л. 13,02. Тираж 200 экз. Заказ

Издано в ООО «Эль Контент»

634029, г. Томск, ул. Кузнецова д. 11 оф. 17

Отпечатано в Томском государственном университете
систем управления и радиоэлектроники.

634050, г. Томск, пр. Ленина, 40

Тел. (3822) 533018.